Tarea4_Conejeros_Gonzalez

December 19, 2022

Tarea 4: Felipe Conejeros y Mabel González

0.1 Pregunta 1

A continuación se ingresa la base de datos y se realizan los ajustes necesarios para su uso (missing values, recodificar variables, etcetera). Además, se identifican los tipos de datos, se realizan estadisticas descriptivas sobre las variables importantes y se hace una limpieza de las variables.

```
[1]: import numpy as np
     import pandas as pd
     import matplotlib.pyplot as plt
     import statsmodels.api as sm
     import statsmodels.formula.api as smf
     import sklearn
     import scipy
     from scipy.linalg import eigh, cholesky
     from scipy.stats import norm
     import linearmodels.panel as lmp
     from pylab import plot, show, axis, subplot, xlabel, ylabel, grid
     import semopy
     import seaborn as sns
     from factor_analyzer import FactorAnalyzer
     from sklearn.decomposition import PCA
     import math
     %matplotlib inline
```

```
[2]: #Base de datos
junaeb2 = pd.read_csv('../Tarea 4/junaeb2.csv')
#junaeb2.describe()
```

```
[3]: junaeb2.dtypes
```

```
[3]: sexo int64
edad int64
imce float64
vive_padre int64
```

```
int64
     sk1
     sk2
                     int64
     sk3
                     int64
     sk4
                     int64
     sk5
                     int64
     sk6
                     int64
     sk7
                     int64
     sk8
                     int64
     sk9
                     int64
     sk10
                     int64
     sk11
                     int64
     sk12
                     int64
     sk13
                     int64
     act_fisica
                   float64
     area
                     int64
     educm
                   float64
     educp
                     int64
     madre_work
                     int64
     dtype: object
[4]: sexo_alt = []
     for i in range(len(junaeb2)):
         if junaeb2["sexo"][i] not in sexo_alt:
             sexo_alt.append(junaeb2["sexo"][i])
     print("sexo", sexo_alt)
     vive_padre_alt = []
     for i in range(len(junaeb2)):
         if junaeb2["vive_padre"][i] not in vive_padre_alt:
             vive_padre_alt.append(junaeb2["vive_padre"][i])
     print("vive_padre", vive_padre_alt)
     vive_madre_alt = []
     for i in range(len(junaeb2)):
         if junaeb2["vive_madre"][i] not in vive_madre_alt:
             vive_madre_alt.append(junaeb2["vive_madre"][i])
     print("vive_madre", vive_madre_alt)
     area alt = []
     for i in range(len(junaeb2)):
         if junaeb2["area"][i] not in area_alt:
             area_alt.append(junaeb2["area"][i])
     print("area", area_alt)
     madre_work_alt = []
```

vive_madre

int64

```
for i in range(len(junaeb2)):
 if junaeb2["madre_work"][i] not in madre_work_alt:
  madre_work_alt.append(junaeb2["madre_work"][i])
print("madre_work", madre_work_alt)
act_fisica_alt = []
for i in range(len(junaeb2)):
 if junaeb2["act_fisica"][i] not in act_fisica_alt:
  act fisica alt.append(junaeb2["act fisica"][i])
print("act_fisica", act_fisica_alt)
educm_alt = []
for i in range(len(junaeb2)):
 if junaeb2["educm"][i] not in educm_alt:
  educm_alt.append(junaeb2["educm"][i])
print("educm", educm_alt)
sexo [1, 0]
vive_padre [1, 0, 2]
vive_madre [1, 0, 2]
area [0, 1]
madre_work [-1, 1, 0]
act_fisica [nan, 5.0, nan, 2.0, 1.0, 4.0, 3.0, nan, nan, nan, nan, nan, nan,
```

```
nan, nan, nan, nan, nan, nan,
educm [11.0, 8.0, 13.0, 16.0, 17.0, 20.0, 10.0, 6.0, 9.0, 12.0, 7.0, 4.0, 15.0,
19.0, 18.0, 0.0, 5.0, 3.0, nan, 22.0, nan, nan, nan, nan, nan, 14.0, nan, 2.0,
🦳, nan, nan,
, nan, nan,
```

```
[5]: k = 0
for i in range(len(junaeb2)):
    if math.isnan(junaeb2["act_fisica"][i]) == True:
        k += 1
print("Se debe borrar", k, "nan")
```

Se debe borrar 1966 nan

```
[6]: k = 0
for i in range(len(junaeb2)):
    if math.isnan(junaeb2["educm"][i]) == True:
        k += 1
print("Se debe borrar", k, "nan")
```

Se debe borrar 721 nan

Se observa que vive_padre y vive_madre son variables binarias, sin embargo, en las observaciones se tienen respuestas 1, 0 y 2 por lo que se eliminan los datos con valor 2.

[7]: [57826, 2082, 91]

[8]: [43278, 16698, 23]

Luego, dado que la variable sk7 corresponde a una pregunta negativa (al contrario que las demás), se modificarán las observaciones de tal manera que:

```
1 = 5
```

2 = 4

3 = 3

```
[9]: sk7 = []
      for i in range(len(junaeb2)):
          sk7.append(junaeb2["sk7"][i])
[10]: for i in range(len(sk7)):
          if sk7[i] == 1:
              sk7[i] = 5
          elif sk7[i] == 2:
              sk7[i] = 4
          elif sk7[i] == 4:
              sk7[i] = 2
          elif sk7[i] == 5:
              sk7[i] = 1
[11]:
      junaeb2["sk7"] = sk7
[12]: # se procede a borrar las 91 y 23 observaciones correspondientes a 2, tantou
       ⇒para vive_madre y vive_padre
      junaeb2_index_1 = junaeb2[junaeb2["vive_madre"] == 2].index
      junaeb2 = junaeb2.drop(junaeb2_index_1)
      junaeb2_index_1 = junaeb2[junaeb2["vive_padre"] == 2].index
      junaeb2 = junaeb2.drop(junaeb2_index_1)
[13]:
      junaeb2.describe()
[13]:
                                                                          vive_madre
                                    edad
                                                           vive_padre
                      sexo
                                                  imce
             59885.000000
                            59885.00000
                                          59885.000000
                                                         59885.000000
                                                                        59885.000000
      count
      mean
                 0.534992
                               81.91978
                                              1.017765
                                                             0.721683
                                                                            0.965551
      std
                 0.498778
                                3.81653
                                              1.367962
                                                             0.448174
                                                                            0.182382
      min
                 0.000000
                               62.00000
                                             -5.020000
                                                             0.000000
                                                                            0.000000
      25%
                 0.000000
                               80.00000
                                              0.110000
                                                             0.00000
                                                                            1.000000
      50%
                  1.000000
                               81.00000
                                              0.970000
                                                             1.000000
                                                                            1.000000
      75%
                  1.000000
                               83.00000
                                              1.930000
                                                             1.000000
                                                                            1.000000
                  1.000000
                              107.00000
                                              5.040000
                                                             1.000000
                                                                            1.000000
      max
                       sk1
                                      sk2
                                                     sk3
                                                                                  sk5
             59885.000000
                            59885.000000
                                           59885.000000
                                                          59885.000000
                                                                         59885.000000
      count
                                1.390682
                                               1.260299
                                                              1.253352
                                                                             1.267813
      mean
                  1.111731
      std
                 0.390792
                                0.654514
                                               0.583895
                                                              0.574491
                                                                             0.566422
      min
                  1.000000
                                1.000000
                                               1.000000
                                                              1.000000
                                                                             1.000000
      25%
                                                                             1.000000
                  1.000000
                                1.000000
                                               1.000000
                                                              1.000000
      50%
                  1.000000
                                1.000000
                                               1.000000
                                                              1.000000
                                                                             1.000000
      75%
                  1.000000
                                2.000000
                                               1.000000
                                                              1.000000
                                                                             1.000000
                 5.000000
                                5.000000
                                               5.000000
                                                              5.000000
                                                                             5.000000
      max
```

```
mean
                     1.331135
                                    1.855406
                                                   1.384170
                                                                   1.497003
                     0.664088
                                    0.941610
                                                   0.669026
                                                                   0.797208
      std
      min
                     1.000000
                                    1.000000
                                                   1.000000
                                                                   1.000000
      25%
                                    1.000000
                                                   1.000000
                                                                   1.000000
                     1.000000
      50%
                     1.000000
                                    2.000000
                                                   1.000000
                                                                   1.000000
      75%
                     1.000000
                                    2.000000
                                                   2.000000
                                                                   2.000000
                     5.000000
                                    5.000000
                                                   5.000000
                                                                   5.000000
      max
                      sk13
                               act_fisica
                                                     area
                                                                   educm
                                                                                  educp
              59885.000000
                             57922.000000
                                            59885.000000
                                                           59165.000000
                                                                          59885.000000
      count
      mean
                  1.691242
                                 2.559753
                                                0.906755
                                                              13.046463
                                                                             12.943609
      std
                  0.984356
                                 1.070258
                                                0.290778
                                                               3.328674
                                                                              3.429180
                  1.000000
                                 1.000000
                                                0.00000
                                                               0.000000
                                                                              0.000000
      min
      25%
                  1.000000
                                 2.000000
                                                1.000000
                                                              12.000000
                                                                             11.000000
      50%
                                                              13.000000
                                                                             13.000000
                  1.000000
                                 2.000000
                                                1.000000
      75%
                  2.000000
                                 3.000000
                                                1.000000
                                                              15.000000
                                                                             14.000000
                  5.000000
                                 5.000000
                                                1.000000
                                                              22.000000
                                                                             22.000000
      max
                madre_work
             59885.000000
      count
                  0.088937
      mean
      std
                  0.942739
      min
                 -1.000000
      25%
                 -1.000000
      50%
                  0.000000
      75%
                  1.000000
      max
                  1.000000
      [8 rows x 23 columns]
[14]: # Borrando los nan
      junaeb2.dropna(inplace=True) #borra los na (primera limpieza)
      junaeb2.describe()
                                                                            vive_madre
                                     edad
                                                     imce
                                                             vive_padre
                      sexo
      count
              57247.000000
                             57247.000000
                                            57247.000000
                                                           57247.000000
                                                                          57247.000000
                  0.535207
                                81.880361
                                                1.018248
                                                               0.721086
                                                                               0.975213
      mean
                  0.498763
                                 3.769133
                                                               0.448469
                                                                               0.155478
      std
                                                1.367567
                                                               0.00000
                                                                               0.000000
      min
                  0.000000
                                62.000000
                                               -5.020000
      25%
                  0.000000
                                80.000000
                                                0.110000
                                                               0.000000
                                                                               1.000000
      50%
                  1.000000
                                81.000000
                                                0.970000
                                                               1.000000
                                                                               1.000000
      75%
                  1.000000
                                83.000000
                                                1.930000
                                                               1.000000
                                                                               1.000000
      max
                  1.000000
                               107.000000
                                                5.040000
                                                               1.000000
                                                                               1.000000
                       sk1
                                      sk2
                                                     sk3
                                                                    sk4
                                                                                   sk5
```

sk9

59885.000000

count

Γ14]:

sk10

59885.000000

sk11

59885.000000

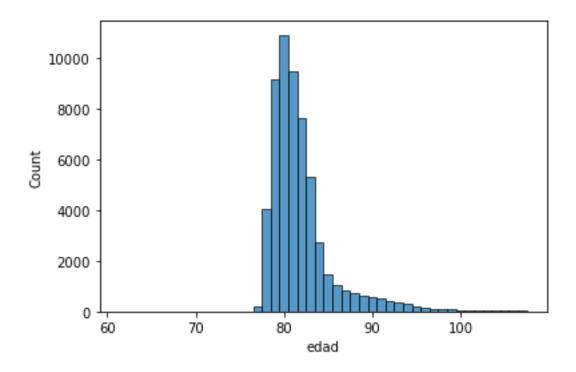
sk12

59885.000000

```
57247.000000
                       57247.000000
                                      57247.000000
                                                     57247.00000
                                                                   57247.000000
count
                                          1.253463
                                                                        1.263682
mean
            1.106434
                           1.385575
                                                         1.24686
std
            0.375705
                           0.646386
                                          0.572004
                                                         0.56263
                                                                        0.558256
min
            1.000000
                           1.000000
                                          1.000000
                                                         1.00000
                                                                        1.000000
25%
            1.000000
                           1.000000
                                          1.000000
                                                         1.00000
                                                                        1.000000
50%
            1.000000
                           1.000000
                                                         1.00000
                                                                        1.000000
                                          1.000000
75%
                           2.000000
            1.000000
                                          1.000000
                                                         1.00000
                                                                        1.000000
            5.000000
                           5.000000
                                          5.000000
                                                         5.00000
                                                                        5.000000
max
                    sk9
                                   sk10
                                                  sk11
                                                                 sk12
                                                                       \
count
           57247.000000
                          57247.000000
                                         57247.000000
                                                        57247.000000
               1.322707
                              1.845756
                                              1.376893
                                                             1.489213
mean
std
               0.651930
                              0.933075
                                             0.658222
                                                             0.786763
       •••
min
               1.000000
                              1.000000
                                              1.000000
                                                             1.000000
25%
                              1.000000
                                              1.000000
                                                             1.000000
               1.000000
50%
               1.000000
                              2.000000
                                              1.000000
                                                             1.000000
75%
                              2.000000
                                              2.000000
                                                             2.000000
               1.000000
       •••
max
               5.000000
                              5.000000
                                              5.000000
                                                             5.000000
                sk13
                         act_fisica
                                                             educm
                                                                            educp
                                               area
                       57247.000000
count
       57247.000000
                                      57247.000000
                                                     57247.000000
                                                                    57247.000000
            1.683162
                           2.559663
                                          0.907157
                                                        13.084092
                                                                        12.988855
mean
std
            0.977324
                           1.070433
                                          0.290215
                                                         3.321023
                                                                         3.420104
min
            1.000000
                           1.000000
                                          0.000000
                                                         0.000000
                                                                         0.000000
25%
                           2.000000
            1.000000
                                          1.000000
                                                        12.000000
                                                                        11.000000
50%
            1.000000
                           2.000000
                                          1.000000
                                                        13.000000
                                                                        13.000000
                                                        15.000000
75%
            2.000000
                           3.000000
                                          1.000000
                                                                        14.000000
            5.000000
                                                                        22.000000
max
                           5.000000
                                          1.000000
                                                        22.000000
         madre_work
       57247.000000
count
mean
            0.102521
std
            0.941047
min
           -1.000000
25%
           -1.000000
50%
            0.00000
75%
            1.000000
            1.000000
max
[8 rows x 23 columns]
```

[15]: junaeb2.dtypes

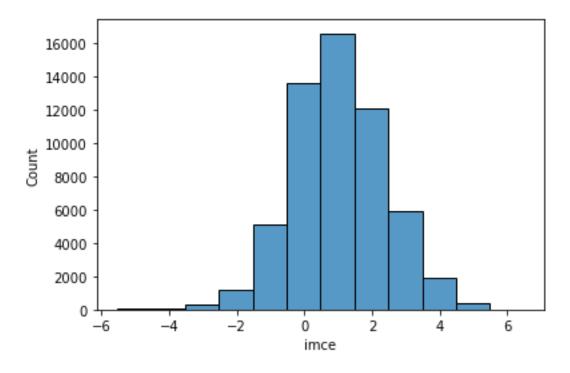
```
vive_madre
                       int64
      sk1
                       int64
                       int64
      sk2
                       int64
      sk3
      sk4
                       int64
      sk5
                       int64
      sk6
                       int64
      sk7
                       int64
      sk8
                       int64
      sk9
                       int64
      sk10
                       int64
                       int64
      sk11
      sk12
                       int64
      sk13
                       int64
      act_fisica
                    float64
      area
                       int64
      educm
                    float64
      educp
                       int64
                       int64
      madre_work
      dtype: object
[16]: junaeb2.value_counts("sexo")
[16]: sexo
      1
           30639
      0
           26608
      dtype: int64
[17]: sns.histplot(junaeb2, x = "edad", discrete=True)
[17]: <AxesSubplot:xlabel='edad', ylabel='Count'>
```



Del gráfico anterior se observa una posible distribución Poisson para la variable "edad"

```
[18]: sns.histplot(junaeb2, x = "imce", discrete=True)
```

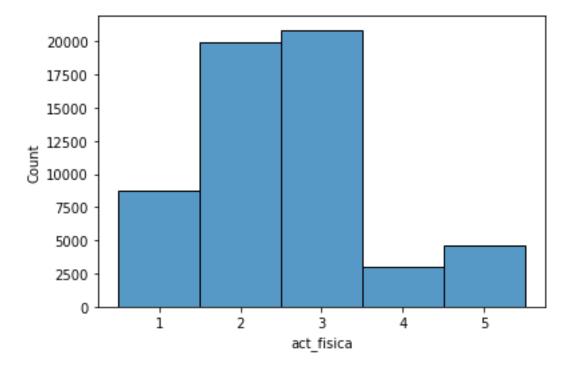
[18]: <AxesSubplot:xlabel='imce', ylabel='Count'>



Para la variable "imce" se tiene una distribución normal.

```
[19]: sns.histplot(junaeb2, x = "act_fisica", discrete=True)
```

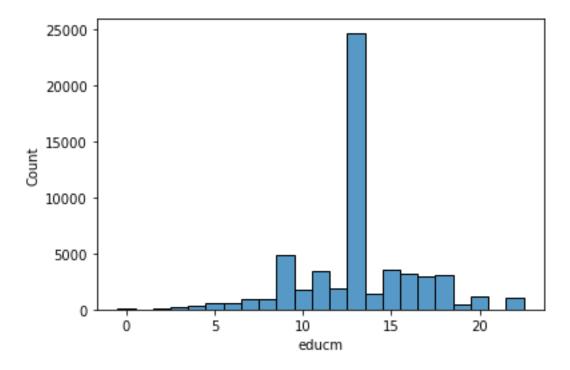
[19]: <AxesSubplot:xlabel='act_fisica', ylabel='Count'>



```
[20]: sns.histplot(junaeb2, x = "educm", discrete=True)
  junaeb2.value_counts("educm")
```

```
[20]: educm
      13.0
               24734
      9.0
                4872
      15.0
                3505
      11.0
                3411
      16.0
                3182
      18.0
                3113
      17.0
                2982
      12.0
                1884
      10.0
                1825
      14.0
                1407
      20.0
                1124
      22.0
                1014
      7.0
                 977
```

```
8.0
           946
6.0
           570
5.0
           547
19.0
           418
4.0
           311
3.0
           203
0.0
           123
2.0
            99
dtype: int64
```



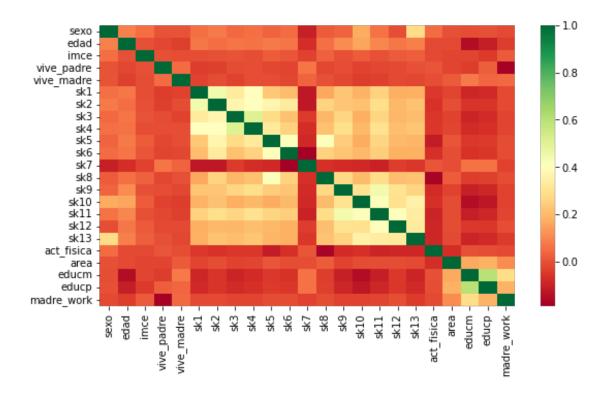
De lo anterior, se observa que la mayor cantidad de observaciones tiene padres con 13 años de escolaridad.

```
[21]: plt.figure(figsize = (9,5))

sns.heatmap(junaeb2.corr(), cmap='RdYlGn') #mapa de correlaciones entre las⊔
⇒variables

#La primera variable tiene la menor correlación con los demás
#4 está correlacionada negativamente con casi todo
```

[21]: <AxesSubplot:>



En el gráfico anterior se puede observar el mapa de correlaciones entre las variables. Donde destaca que la mayoría de las correlaciones son negativas.

0.2 Pregunta 2

0.3 PCA

A continuación se realiza un PCA para las variables sk1 a sk13 considerando 12 componentes, de donde se obtiene la proporción de la varianza que aporta cada uno de ellos.

```
[22]: var_sk = var_sk = var_sk = var_sk = var_sk1", "sk2", "sk3", "sk4", "sk5", "sk6", "sk7", "sk8", "sk9", "sk10", "sk11", "sk12", "sk13"]

pca = PCA(n_components=12)

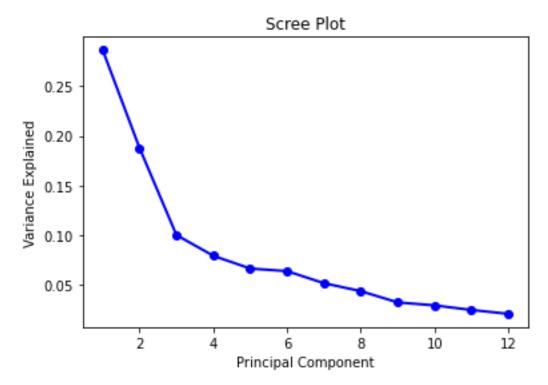
pca_features = pca.fit_transform(var_sk)

print(pca.explained_variance_ratio_)
```

```
[0.28631517 0.18770494 0.10021277 0.07934442 0.06652185 0.0639139 0.05177581 0.04378728 0.03246161 0.02948488 0.02484987 0.02097694]
```

Luego, se genera un Scree plot que muestra la proporción de varianza explicada por cada componente de donde se obtiene que todos los componentes explican la totalidad de la varianza, lo que indica que es posible representar a la data utilizando los 12 componentes.

```
[23]: PC_values = np.arange(pca.n_components_) + 1
```



También podemos usar "mle" para determinar el numero óptimo de componentes basados en la varianza de la data, al ser un método que se detiene cuando el factor adicional ya no está entregando información. De esto se obtiene que el número óptimo de componentes es 12, y se muestra la proporción de la varianza explicada por cada uno.

```
[24]: pca = PCA(n_components='mle')
pca_features = pca.fit_transform(var_sk)
print(pca.explained_variance_ratio_)
```

```
[0.28631517 0.18770494 0.10021277 0.07934442 0.06652185 0.0639139 0.05177581 0.04378728 0.03246161 0.02948488 0.02484987 0.02097694]
```

A continuación podemos ver los pesos relativos que indican cómo se relaciona cada variable con los factores.

```
[25]: #Da información acerca de en que dirección se están moviendo los componentes.

pca_vectors = pd.DataFrame(data = pca.components_)

pca_vectors.head()
```

```
[25]:
                                    2
                                                                   5
                         1
                                              3
                                                            0.252092 -0.341069
         0.104227
                   0.229226
                             0.169553
                                        0.185690
                                                  0.185365
         0.007044
                   0.030471
                             0.062588
                                        0.053250
                                                  0.039207 -0.031085
                                                                      0.926760
         0.083509
                   0.267293
                             0.183524
                                        0.190825
                                                  0.297595
                                                            0.334215
                                                                       0.114564
         0.001749 -0.023801 -0.032407 -0.027100 -0.043243
                                                            0.003667
                                                                       0.035749
      4 0.151165
                   0.289807
                             0.313649
                                        0.305867 -0.016091
                                                            0.174138
                                                                      0.037738
                                              10
               7
                         8
                                    9
                                                        11
                                                                   12
      0 0.292371
                   0.240676
                             0.405647
                                        0.288246
                                                  0.292983
                                                            0.426902
      1 0.099293
                   0.085301
                             0.164018
                                        0.100167
                                                  0.152525
                                                            0.231400
      2 0.477934
                   0.078417 -0.389646 -0.000952 -0.090333 -0.493500
      3 -0.096266
                             0.698603
                                        0.144628
                                                  0.016523 -0.682305
                   0.102175
      4 -0.755708
                   0.088409 -0.183365
                                        0.090231
                                                  0.206599 -0.076589
```

La descripción de cada factor se muestra a continuación.

```
[26]: pca_df = pd.DataFrame(data=pca_features,columns=['PC1', 'PC2', 'PC3', 'PC4', \cdots 'PC5', 'PC6', 'PC7', "PC8", "PC9", 'PC10', 'PC11', 'PC12']) #cambiar segun_\cdots factores sean

pca_df.describe().apply(lambda s: s.apply('{0:.3f}'.format))
```

[26]:		PC1	PC2	PC3	PC4	PC5	PC6	\
	count	57247.000	57247.000	57247.000	57247.000	57247.000	57247.000	
	mean	0.000	-0.000	0.000	-0.000	-0.000	-0.000	
	std	1.467	1.188	0.868	0.772	0.707	0.693	
	min	-1.903	-3.219	-4.117	-3.464	-3.921	-3.932	
	25%	-1.092	-0.724	-0.470	-0.245	-0.293	-0.400	
	50%	-0.270	0.187	0.006	-0.090	0.095	0.032	
	75%	0.786	0.814	0.454	0.516	0.339	0.273	
	max	10.919	4.589	6.316	3.692	5.210	4.580	
		PC7	PC8	PC9	PC10	PC11	PC12	
	count	57247.000	57247.000	57247.000	57247.000	57247.000	57247.000	
	mean	0.000	-0.000	-0.000	0.000	0.000	0.000	
	std	0.624	0.574	0.494	0.471	0.432	0.397	
	min	-4.605	-4.377	-4.206	-3.557	-2.454	-3.108	
	25%	-0.313	-0.289	-0.213	-0.192	-0.218	-0.056	
	50%	0.063	0.027	-0.019	0.040	0.049	0.020	
	75%	0.312	0.196	0.206	0.119	0.114	0.041	
	max	4.675	5.228	4.463	3.788	3.833	3.286	

Luego, realizamos un check de que todos los vectores son ortogonales, es decir, que no hay correlación entre ellos, lo que si se cumple.

```
[27]: pca_df.corr().apply(lambda s: s.apply('{0:.3f}'.format))
```

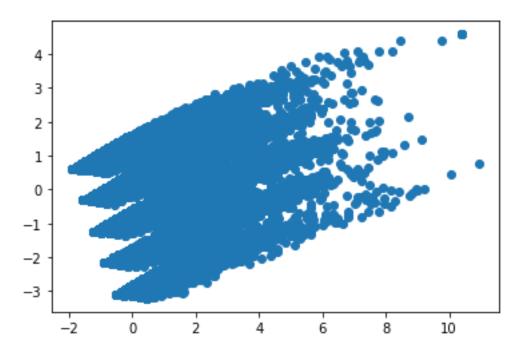
```
[27]:
                PC1
                         PC2
                                  PC3
                                           PC4
                                                    PC5
                                                            PC6
                                                                     PC7
                                                                              PC8
                                                                                       PC9
                                                                                             \
      PC1
              1.000
                       0.000
                              -0.000
                                        0.000
                                                -0.000
                                                          0.000
                                                                  -0.000
                                                                            0.000
                                                                                    -0.000
      PC2
              0.000
                       1.000
                              -0.000
                                       -0.000
                                                -0.000
                                                                            0.000
                                                         -0.000
                                                                   0.000
                                                                                    -0.000
      PC3
             -0.000
                      -0.000
                                1.000
                                       -0.000
                                                -0.000
                                                          0.000
                                                                   0.000
                                                                            0.000
                                                                                    -0.000
      PC4
              0.000
                      -0.000
                              -0.000
                                         1.000
                                                -0.000
                                                         -0.000
                                                                   0.000
                                                                           -0.000
                                                                                     0.000
      PC5
             -0.000
                      -0.000
                               -0.000
                                       -0.000
                                                 1.000
                                                          0.000
                                                                  -0.000
                                                                            0.000
                                                                                    -0.000
      PC6
              0.000
                      -0.000
                                0.000
                                       -0.000
                                                 0.000
                                                          1.000
                                                                  -0.000
                                                                           -0.000
                                                                                     0.000
      PC7
             -0.000
                       0.000
                                0.000
                                        0.000
                                                -0.000
                                                         -0.000
                                                                   1.000
                                                                            0.000
                                                                                    -0.000
      PC8
              0.000
                                0.000
                                       -0.000
                                                 0.000
                                                         -0.000
                                                                   0.000
                                                                                     0.000
                       0.000
                                                                            1.000
      PC9
             -0.000
                      -0.000
                               -0.000
                                        0.000
                                                -0.000
                                                          0.000
                                                                  -0.000
                                                                            0.000
                                                                                     1.000
      PC10
              0.000
                                       -0.000
                                                 0.000
                                                         -0.000
                                                                           -0.000
                                                                                    -0.000
                       0.000
                                0.000
                                                                   0.000
      PC11
              0.000
                      -0.000
                                0.000
                                         0.000
                                                 0.000
                                                         -0.000
                                                                  -0.000
                                                                            0.000
                                                                                     0.000
      PC12
                      -0.000
                                                          0.000
                                                                  -0.000
                                                                                     0.000
             -0.000
                               -0.000
                                         0.000
                                                -0.000
                                                                            0.000
               PC10
                        PC11
                                 PC12
      PC1
              0.000
                       0.000
                              -0.000
      PC2
              0.000
                      -0.000
                              -0.000
      PC3
              0.000
                       0.000
                              -0.000
             -0.000
      PC4
                       0.000
                                0.000
      PC5
              0.000
                       0.000
                              -0.000
      PC6
             -0.000
                      -0.000
                                0.000
      PC7
              0.000
                      -0.000
                               -0.000
      PC8
             -0.000
                       0.000
                                0.000
      PC9
             -0.000
                       0.000
                                0.000
      PC10
              1.000
                      -0.000
                               -0.000
      PC11
             -0.000
                                0.000
                       1.000
      PC12
             -0.000
                       0.000
                                1.000
```

0.4 Pregunta 3

A continuación, se presenta un Scatterplot para los primeros 3 componentes principales contra las variables: sexo, area, madre_work y act_fisica, con el fin de saber si existen diferencias significativas entre grupos. De manera general, se puede observar que no existen diferencias significativas entre grupos ya que no se observa una marcada separación entre ellos en relación a ambos ejes.

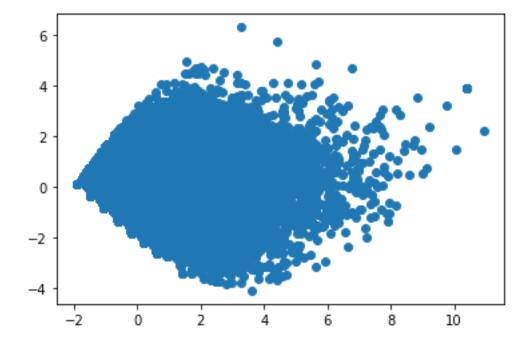
```
[57]: plt.scatter(pca_df['PC1'],pca_df['PC2'])
```

[57]: <matplotlib.collections.PathCollection at 0x2062ddd67f0>



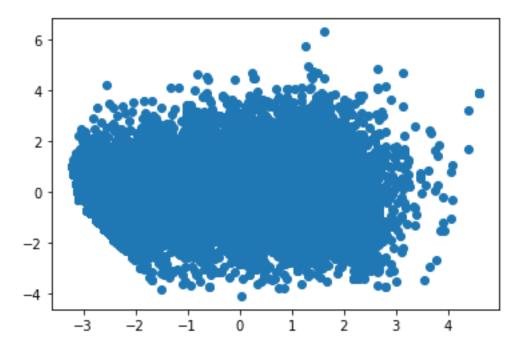
[58]: plt.scatter(pca_df['PC1'],pca_df['PC3'])

[58]: <matplotlib.collections.PathCollection at 0x2062deaadf0>



```
[59]: plt.scatter(pca_df['PC2'],pca_df['PC3'])
```

[59]: <matplotlib.collections.PathCollection at 0x2062de96d30>

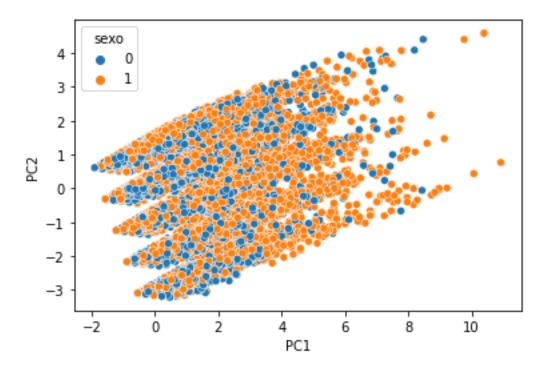


```
[60]: a = "sexo"
pca_df[a] = 0
pca_df[a] = np.where(junaeb2[a] > 0, 1, pca_df[a])
sns.scatterplot('PC1', 'PC2', data=pca_df, hue=a)
```

C:\Users\felip\anaconda3\lib\site-packages\seaborn_decorators.py:36: FutureWarning: Pass the following variables as keyword args: x, y. From version 0.12, the only valid positional argument will be `data`, and passing other arguments without an explicit keyword will result in an error or misinterpretation.

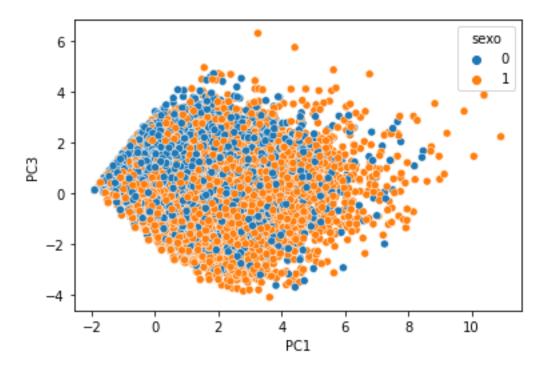
warnings.warn(

[60]: <AxesSubplot:xlabel='PC1', ylabel='PC2'>



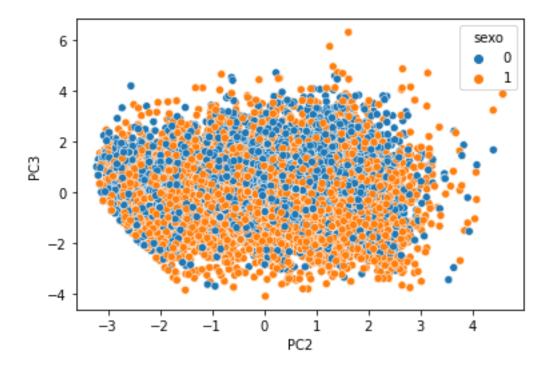
```
[62]: a = "sexo"
    pca_df[a] = 0
    pca_df[a] = np.where(junaeb2[a] > 0, 1, pca_df[a])
    sns.scatterplot('PC1', 'PC3', data=pca_df, hue=a)
```

[62]: <AxesSubplot:xlabel='PC1', ylabel='PC3'>



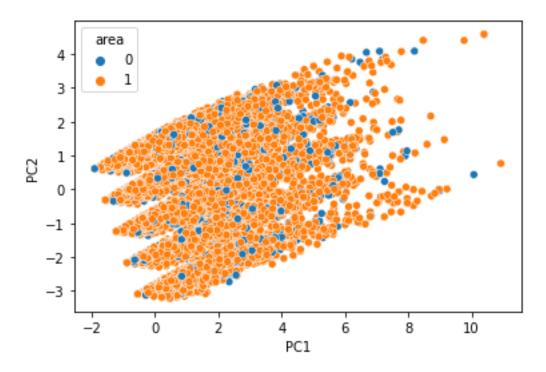
```
[63]: a = "sexo"
    pca_df[a] = 0
    pca_df[a] = np.where(junaeb2[a] > 0, 1, pca_df[a])
    sns.scatterplot('PC2', 'PC3', data=pca_df, hue=a)
```

[63]: <AxesSubplot:xlabel='PC2', ylabel='PC3'>



```
[64]: a = "area"
   pca_df[a] = 0
   pca_df[a] = np.where(junaeb2[a] > 0, 1, pca_df[a])
   sns.scatterplot('PC1', 'PC2', data=pca_df, hue=a)
```

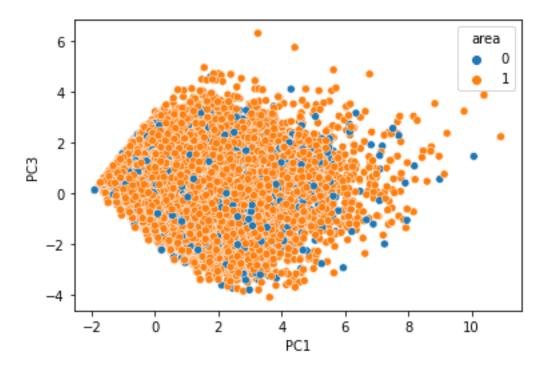
[64]: <AxesSubplot:xlabel='PC1', ylabel='PC2'>



```
[65]: a = "area"
   pca_df[a] = 0
   pca_df[a] = np.where(junaeb2[a] > 0, 1, pca_df[a])
   sns.scatterplot('PC1', 'PC3', data=pca_df, hue=a)
```

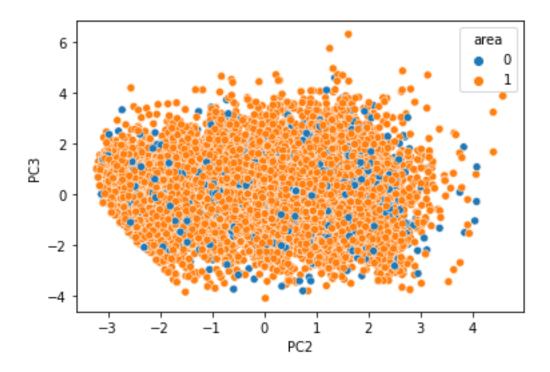
[65]: <AxesSubplot:xlabel='PC1', ylabel='PC3'>

warnings.warn(



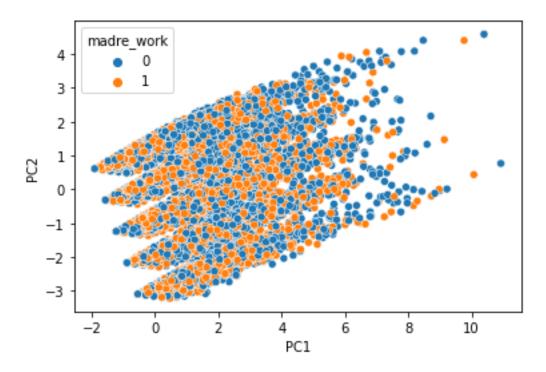
```
[66]: a = "area"
pca_df[a] = 0
pca_df[a] = np.where(junaeb2[a] > 0, 1, pca_df[a])
sns.scatterplot('PC2', 'PC3', data=pca_df, hue=a)
```

[66]: <AxesSubplot:xlabel='PC2', ylabel='PC3'>



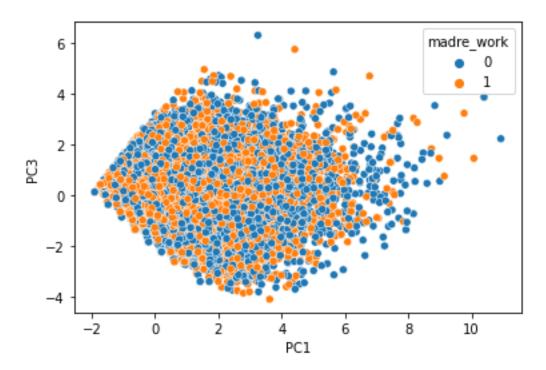
```
[67]: a = "madre_work"
    pca_df[a] = 0
    pca_df[a] = np.where(junaeb2[a] > 0, 1, pca_df[a])
    sns.scatterplot('PC1', 'PC2', data=pca_df, hue=a)
```

[67]: <AxesSubplot:xlabel='PC1', ylabel='PC2'>



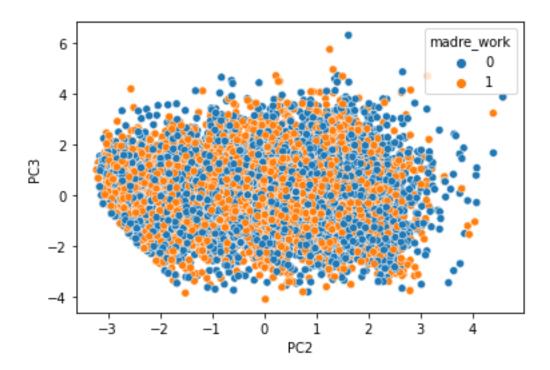
```
[68]: a = "madre_work"
    pca_df[a] = 0
    pca_df[a] = np.where(junaeb2[a] > 0, 1, pca_df[a])
    sns.scatterplot('PC1', 'PC3', data=pca_df, hue=a)
```

[68]: <AxesSubplot:xlabel='PC1', ylabel='PC3'>



```
[69]: a = "madre_work"
    pca_df[a] = 0
    pca_df[a] = np.where(junaeb2[a] > 0, 1, pca_df[a])
    sns.scatterplot('PC2', 'PC3', data=pca_df, hue=a)
```

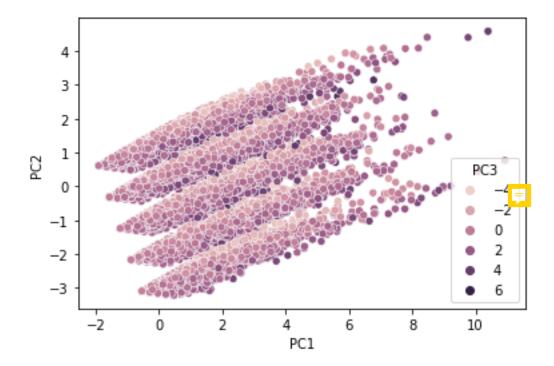
[69]: <AxesSubplot:xlabel='PC2', ylabel='PC3'>



```
[71]: pca_df['act_fisica'] = junaeb2['act_fisica']
sns.scatterplot('PC1', 'PC2', 'PC3', data=pca_df, hue='act_fisica')
```

warnings.warn(

[71]: <AxesSubplot:xlabel='PC1', ylabel='PC2'>



0.5 Pregunta 4

0.6 EFA: análisis factorial exploratorio

Análisis factorial separa cada variable observada en 2 elementos: variable latente+ruido. Usando la libreria semopy podemos inferir que variables corresponden a cada factor, basado en los "factor loadings" estimados.

Semopy levanta factores distintos que factor-analyser. La diferencia es dado que factor_analyser reporta factores hasta que los eigenvalores son irrelevantes (varianza explicada), mientras que semopy presenta un potencial EFA donde todos los coeficientes son estadisticamente significativos.

```
[33]: fa = FactorAnalyzer(rotation='promax') fa.fit(var_sk)
```

[33]: FactorAnalyzer(rotation_kwargs={})

Se determinó automaticamente que el número óptimo de componentes es 3, y a continuación se muestra un arreglo con los pesos relativos para cada variable.

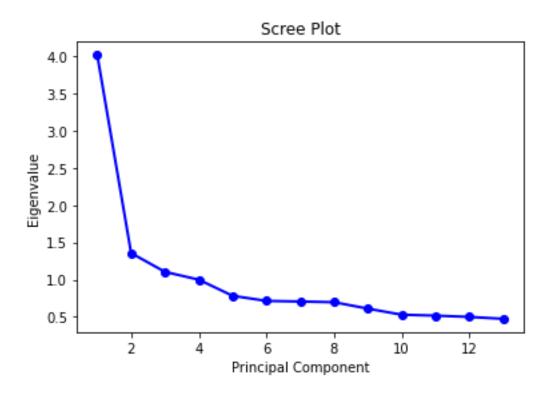
```
[34]: #Indica que factores pesan y en que dirección fa.loadings_
```

```
[0.00349246, 0.7396996, -0.03312391],
             [-0.14810408, -0.02621475, 0.862476],
             [0.00590849, 0.04188805, 0.51846545],
             [-0.01588018, -0.03990937, -0.13987395],
             [0.14617103, -0.10754942, 0.51519416],
             [ 0.48366606, 0.08146774, 0.05186671],
             [0.6196176, -0.03468374, -0.03260352],
             [0.696416, 0.03005479, 0.00609085],
             [ 0.56966766, -0.02274258, -0.00423132],
             [0.52730608, 0.01921561, -0.01143569]])
[35]: #a pesar de que estima 3 factores se calculan todos los eigenvalues
      fa.get eigenvalues()
[35]: (array([4.01421272, 1.35598674, 1.10382041, 0.99901701, 0.78245204,
             0.71417333, 0.70607397, 0.69653413, 0.60998972, 0.52854767,
             0.51665716, 0.49900826, 0.47352684]),
      array([ 3.41985323, 0.76542641, 0.5925844 , 0.20923866, 0.08734352,
              0.06289151, 0.03437131, 0.02794699, -0.02552849, -0.07612027,
             -0.09466115, -0.1133073 , -0.17534796]))
     Luego, en el Scree plot se observa la proporción de varianza que aporta cada componente.
[36]: values = np.arange(1,14)
      eigenvalues = pd.DataFrame(data=fa.get_eigenvalues())
      plt.plot(values, eigenvalues.loc[0], 'o-', linewidth=2, color='blue')
      plt.title('Scree Plot')
```

plt.xlabel('Principal Component')

plt.ylabel('Eigenvalue')

plt.show()



```
[37]: #matriz de varianza-covarianza
#3 elementos:
#-varianza de forma cruda
#-proporcion explicada de cada factor
#-proporción acumulada

fa.get_factor_variance()
```

```
[37]: (array([1.75115614, 1.60411344, 1.35942129]),
array([0.13470432, 0.12339334, 0.10457087]),
array([0.13470432, 0.25809766, 0.36266853]))
```

Usando semopy se obtiene la aproximación de la representación del modelo, que representa la relación entre un factor latente y las variables observadas.

```
[38]: print(semopy.efa.explore_cfa_model(var_sk, pval=0.05))

eta1 =~ sk11 + sk9 + sk10 + sk12

eta2 =~ sk6 + sk7

eta3 =~ sk4 + sk2 + sk11 + sk5 + sk3 + sk9 + sk1 + sk8 + sk12

eta4 =~ sk11 + sk12 + sk13
```

Se obtienen 4 factores, donde se observa que algunos tienen variables repetidas como: sk11, sk9, sk12 y sk6. Para decidir en que factor se consideran se observa la matriz de pesos relativos con

el fin de que cada variable sea representada por solo un factor, obteniendo finalmente el siguiente modelo:

```
eta1 =~ sk11 + sk9 + sk10 + sk12
eta2 =~ sk7
eta3 =~ sk4 + sk2 + sk5 + sk3 + sk1 + sk6 + sk8
eta4 =~ sk13
```

```
pca_vectors
[39]:
                                                 3
                                                                      5
                           1
                                      2
                                                            4
                                                                                 6
                                                                                     \
          0.104227
                     0.229226
                               0.169553
                                          0.185690
                                                     0.185365
                                                                0.252092 -0.341069
      0
      1
          0.007044
                     0.030471
                                0.062588
                                          0.053250
                                                     0.039207 -0.031085
                                                                          0.926760
```

```
2
    0.083509
              0.267293
                        0.183524
                                              0.297595
                                   0.190825
                                                         0.334215
                                                                   0.114564
3
    0.001749 - 0.023801 - 0.032407 - 0.027100 - 0.043243
                                                         0.003667
                                                                   0.035749
4
    0.151165 0.289807 0.313649
                                   0.305867 -0.016091
                                                         0.174138
                                                                   0.037738
   -0.057114 -0.216727 -0.098264 -0.105001 -0.083733 -0.263827 -0.059367
6
    0.124646 0.162650
                        0.327192
                                   0.283990 -0.108956 -0.771862 -0.062113
7
   -0.081896 -0.355100 -0.098948 -0.093933 -0.051283
                                                         0.215499
                                                                   0.019558
    0.072986 \quad 0.634788 \quad -0.486450 \quad -0.346262 \quad -0.010628 \quad -0.107930
8
                                                                   0.023817
  -0.038693 -0.336875 0.189905 0.135432 0.020610
                                                        0.045434 -0.001248
10 -0.051438 -0.140433 -0.158123
                                   0.013471
                                             0.915083 -0.259741 -0.016291
  0.136768 -0.088170 -0.640186 0.740566 -0.114801
                                                        0.016730
          7
                     8
                               9
                                          10
                                                    11
                                                               12
```

```
0
   0.292371
             0.240676
                       0.405647
                                  0.288246
                                            0.292983
                                                      0.426902
   0.099293
             0.085301
                       0.164018
                                  0.100167
                                            0.152525
1
                                                      0.231400
2
   0.477934
             0.078417 -0.389646 -0.000952 -0.090333 -0.493500
  -0.096266
             0.102175 0.698603
                                  0.144628
                                           0.016523 -0.682305
3
  -0.755708
4
             0.088409 -0.183365
                                  0.090231
                                            0.206599 -0.076589
5
   0.115752
             0.188724 -0.297210 0.189738
                                           0.793078 -0.215925
   0.138290
             0.231358 -0.025626
                                  0.126137 -0.262750 -0.023401
7
  -0.113267 0.717545 -0.169018
                                  0.345582 -0.348909
                                                      0.041222
  -0.058713 -0.050163 -0.105560
                                 0.445009 -0.087842
                                                      0.001135
   0.016876 -0.550041 -0.074429
                                  0.712220 -0.110550 -0.016539
10 -0.213600 0.023494 0.027786 -0.014547 -0.008616 0.010309
11 0.031282 -0.019351 -0.003397 -0.018053 0.001081 -0.002316
```

0.7 Pregunta 5

0.8 General CFA: análisis factorial confirmatorio

Basandose en los resultados de EFA implementamos CFA usando la libreria semopy.

```
[40]: Xf = var_sk

mod = """
    # measurement model
    eta1 =~ sk11 + sk9 + sk10 + sk12
```

```
eta2 =~ sk7
eta3 =~ sk4 + sk2 + sk5 + sk3 + sk1 + sk6 + sk8
eta4 =~ sk13
    """

model = semopy.Model(mod) #se entrega el modelo
out=model.fit(Xf)
print(out)

#output
#tipo de función utilizada
#algoritmo de optimización
#valor final de la función
#numero de iteraciones
#parametros igual a los pesos relativos
#para cada factor hay un parametro estimado
```

Name of objective: MLW Optimization method: SLSQP Optimization successful.

Optimization terminated successfully

Objective value: 0.304 Number of iterations: 35

Params: 0.796 1.091 0.892 1.153 0.871 0.913 0.566 0.981 1.009 0.279 0.435 0.240 0.183 0.596 1.083 0.211 0.203 0.216 0.406 0.098 0.691 0.553 0.133 -0.076 0.114 0.124 0.394 -0.075 -0.063 0.264 0.231 0.240

Se asigna un nombre a cada factor que representa el concepto comun entre todas las variables: * eta1: curiosidad * eta2: agresividad * eta3: inteligencia emocional * eta4: expresividad artística

WARNING:root:Fisher Information Matrix is not PD.Moore-Penrose inverse will be used instead of Cholesky decomposition. See 10.1109/TSP.2012.2208105.

```
[42]: imp_medida = a.iloc[:13] imp_medida
```

```
[42]: lval op rval Estimate Est. Std Std. Err z-value p-value 0 sk11 ~ eta1 1.000000 0.729736 - - - - - - sk9 ~ eta1 0.796446 0.586830 0.006923 115.048315 0.0
```

```
2
    sk10 ~
                   1.091185
                              0.561724
                                        0.009833
                                                   110.972999
                                                                  0.0
             eta1
3
    sk12
                   0.892402
                              0.544866
                                        0.008252
                                                   108.141334
                                                                  0.0
             eta1
4
     sk7
             eta2
                   1.000000
                              0.516651
5
     sk4
             eta3
                   1.000000
                              0.648956
6
     sk2
                   1.153444
                              0.651519
                                                  122.246019
                                                                  0.0
             eta3
                                        0.009435
7
     sk5
             eta3
                   0.870811
                              0.569520
                                        0.007895
                                                   110.304864
                                                                  0.0
8
                  0.913081
                              0.582814
                                        0.008127
                                                   112.351822
                                                                  0.0
     sk3
             eta3
                                                                  0.0
9
     sk1
             eta3 0.565921
                              0.549963
                                        0.005278
                                                   107.226906
10
     sk6
                  0.980967
                              0.490112
                                        0.010076
                                                    97.358183
                                                                  0.0
             eta3
11
                   1.009180
                                                    89.335968
     sk8
             eta3
                              0.443978
                                        0.011296
                                                                  0.0
12
                             0.525512
    sk13
             eta4
                   1.000000
```

Importancia mayor de cada medida (variable) a cada factor: * eta
1 -> sk11 * eta
2 -> sk7 * eta
3 -> sk4 * eta
4 -> sk13

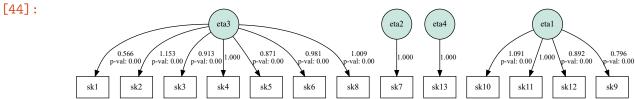
```
[43]: cor_medida = a.iloc[13:23] cor_medida
```

```
[43]:
          lval
                    rval
                          Estimate
                                     Est. Std
                                               Std. Err
                                                           z-value p-value
                op
      13
                    eta3
                          0.133305
                                     1.000000
                                               0.001711
                                                         77.888282
                                                                        0.0
          eta3
      14
          eta3
                    eta2 -0.075760 -0.330442
                                               0.002165 -34.994302
                                                                        0.0
      15
                    eta1
                                     0.648779
                                                                        0.0
          eta3
                          0.113780
                                               0.001308
                                                         86.975575
      16
          eta3
                    eta4
                          0.124418
                                     0.663524
                                               0.001883
                                                         66.074602
                                                                        0.0
      17
          eta2
                    eta2
                          0.394318
                                     1.000000
                                               0.004366
                                                          90.32026
                                                                        0.0
                                                                        0.0
      18
          eta2
                    eta1 -0.074914 -0.248365
                                                0.00291 -25.745546
      19
                    eta4 -0.062521 -0.193863
                                               0.004971 -12.576205
                                                                        0.0
          eta2
      20
                                                                        0.0
          eta4
                    eta4
                          0.263761
                                     1.000000
                                               0.002823
                                                         93.444966
                                                                        0.0
      21
                    eta1
                          0.230724
                                     1.000000
                                               0.002665
          eta1
                                                         86.567892
      22
                    eta4 0.240409
                                     0.974539
                                               0.002678
                                                         89.769007
                                                                        0.0
          eta1
```

La tabla anterior muestra la varianza-covarianza entre factores

```
[44]: #Representación gráfica: semopy.semplot(model, "model.png")
```

WARNING:root:Fisher Information Matrix is not PD.Moore-Penrose inverse will be used instead of Cholesky decomposition. See 10.1109/TSP.2012.2208105.



0.9 Pregunta 6

0.10 Complete SEM example

```
[45]: cor_act_fisica = junaeb2.corr().apply(lambda s: s.apply('{0:.3f}'.format))
      cor_act_fisica["act_fisica"]
[45]: sexo
                      0.047
      edad
                     -0.017
      imce
                     -0.020
      vive_padre
                     0.006
      vive_madre
                     -0.010
      sk1
                     -0.051
      sk2
                     -0.064
      sk3
                     -0.053
      sk4
                     -0.054
      sk5
                     -0.114
      sk6
                     -0.068
      sk7
                      0.005
      sk8
                     -0.175
      sk9
                     -0.077
      sk10
                     -0.068
      sk11
                     -0.098
      sk12
                     -0.089
      sk13
                     -0.092
      act_fisica
                     1.000
      area
                     -0.071
      educm
                     -0.004
      educp
                     -0.010
      madre_work
                     -0.019
      Name: act_fisica, dtype: object
```

Se considerarán las variables que mantengan una correlación mayor con act_fisica de 0.02 y menor a -0.02, por lo que se incluirán las variables sexo, imce y area.

```
[46]: # incluyendo imce, act_fisica y area
var_sk["sexo"] = junaeb2["sexo"]
var_sk["imce"] = junaeb2["imce"]
var_sk["act_fisica"] = junaeb2["act_fisica"]
var_sk["area"] = junaeb2["area"]

<ipython-input-46-269e1b52e53d>:2: SettingWithCopyWarning:
    A value is trying to be set on a copy of a slice from a DataFrame.
    Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
    var_sk["sexo"] = junaeb2["sexo"]
<ipython-input-46-269e1b52e53d>:3: SettingWithCopyWarning:
```

A value is trying to be set on a copy of a slice from a DataFrame. Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy var_sk["imce"] = junaeb2["imce"]

<ipython-input-46-269e1b52e53d>:4: SettingWithCopyWarning:

A value is trying to be set on a copy of a slice from a DataFrame.

Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy var_sk["act_fisica"] = junaeb2["act_fisica"]

<ipython-input-46-269e1b52e53d>:5: SettingWithCopyWarning:

A value is trying to be set on a copy of a slice from a DataFrame.

Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy var_sk["area"] = junaeb2["area"]

[47]: var_sk

[47]:		sk1	sk2	sk3	sk4	sk5	sk6	sk7	sk8	sk9	sk10	sk11	sk12	sk13	\
	1	1	1	1	1	1	1	2	1	1	1	1	1	1	
	3	1	1	1	1	1	1	4	1	1	1	1	1	1	
	4	1	1	1	1	1	1	3	1	1	1	1	1	1	
	5	1	2	1	1	1	1	2	1	1	1	1	1	1	
	6	1	1	1	2	2	2	3	2	3	3	3	2	2	
					•••		•••	•••							
	59994	1	3	1	2	2	1	5	3	2	2	2	1	1	
	59995	1	1	2	2	1	1	5	2	1	3	2	1	4	
	59996	1	1	1	1	1	1	5	1	1	3	1	1	1	
	59997	1	1	1	1	2	2	5	2	1	2	1	1	2	
	59998	2	2	1	1	1	1	1	1	1	1	1	1	1	

	sexo	imce	act_fisica	area
1	0	0.71	5.0	0
3	1	2.05	2.0	1
4	0	1.05	1.0	1
5	0	1.39	4.0	0
6	1	2.75	2.0	1
•••			•••	
59994	0	1.63	2.0	1
59995	1	2.57	3.0	1
59996	0	2.12	3.0	1
59997	1	-0.43	2.0	1

59998 0 -0.55 1.0 1

[57247 rows x 17 columns]

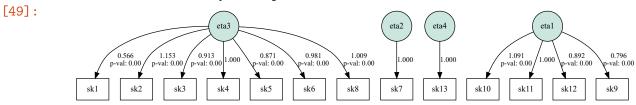
WARNING:root:Fisher Information Matrix is not PD.Moore-Penrose inverse will be used instead of Cholesky decomposition. See 10.1109/TSP.2012.2208105.

	lval	op	rval	Estimate	Std. Err	z-value	p-value
0	sk11	~	eta1	1.000000	_	_	_
1	sk9	~	eta1	0.796446	0.006923	115.048315	0.0
2	sk10	~	eta1	1.091185	0.009833	110.972999	0.0
3	sk12	~	eta1	0.892402	0.008252	108.141334	0.0
4	sk7	~	eta2	1.000000	_	_	_
5	sk4	~	eta3	1.000000	_	-	_
6	sk2	~	eta3	1.153444	0.009435	122.246019	0.0
7	sk5	~	eta3	0.870811	0.007895	110.304864	0.0
8	sk3	~	eta3	0.913081	0.008127	112.351822	0.0
9	sk1	~	eta3	0.565921	0.005278	107.226906	0.0
10	sk6	~	eta3	0.980967	0.010076	97.358183	0.0
11	sk8	~	eta3	1.009180	0.011296	89.335968	0.0
12	sk13	~	eta4	1.000000	-	-	_
13	eta3	~~	eta3	0.133305	0.001711	77.888282	0.0
14	eta3	~ ~	eta2	-0.075760	0.002165	-34.994302	0.0
15	eta3	~~	eta1	0.113780	0.001308	86.975575	0.0
16	eta3	~~	eta4	0.124418	0.001883	66.074602	0.0
17	eta2	~~	eta2	0.394318	0.004366	90.32026	0.0
18	eta2	~ ~	eta1	-0.074914	0.00291	-25.745546	0.0
19	eta2	~ ~	eta4	-0.062521	0.004971	-12.576205	0.0
20	eta4	~ ~	eta4	0.263761	0.002823	93.444966	0.0
21	eta1	~~	eta1	0.230724	0.002665	86.567892	0.0
22	eta1	~ ~	eta4	0.240409	0.002678	89.769007	0.0
23	sk9	~ ~	sk9	0.278638	0.001962	142.040133	0.0
24	sk12	~~	sk12	0.435175	0.00295	147.504237	0.0

```
25
                      0.240462
                                 0.001754
                                             137.104395
                                                              0.0
     sk2
                 sk2
                                                              0.0
26
     sk4
           ~ ~
                 sk4
                      0.183225
                                 0.001332
                                             137.541821
27
    sk10
                sk10
                      0.595931
                                 0.004097
                                             145.456602
                                                              0.0
           ~ ~
28
                                 0.004366
                                              248.04936
                                                              0.0
     sk7
                 sk7
                      1.082927
                      0.210570
29
     sk5
           ~ ~
                 sk5
                                 0.001419
                                             148.384934
                                                              0.0
                sk11
                      0.202548
                                 0.001847
                                             109.659592
                                                              0.0
30
    sk11
           ~ ~
31
     sk3
                 sk3
                      0.216054
                                 0.001471
                                             146.881956
                                                              0.0
32
     sk6
                 sk6
                      0.405749
                                 0.002609
                                             155.535146
                                                              0.0
33
                      0.098460
                                 0.000655
                                             150.415787
                                                              0.0
     sk1
                sk1
34
    sk13
           ~ ~
               sk13
                      0.691334
                                 0.002823
                                             244.924655
                                                              0.0
35
     sk8
                      0.552983
                                 0.003487
                                             158.601911
                                                              0.0
                 sk8
```

```
[49]: semopy.semplot(mod, "semmodel.png")
```

WARNING:root:Fisher Information Matrix is not PD.Moore-Penrose inverse will be used instead of Cholesky decomposition. See 10.1109/TSP.2012.2208105.



Ejemplo SEM considerando la parte de medidas y la parte estructural en semopy (data y modelo entregada en https://semopy.com/tutorial.html). Este ejemplo presenta un modelo donde 3 factories son estimados para la data, donde cada medida corresponde a solo 1 factor. La primera parte del modelo se muestra en la sección 6 (medidas solamente). La segunda parte (regresiones) entrega las relaciones estructurales entre los factores, y la última parte entrega las poteniales correlaciones entre el error en cada medida (esto se puede usar en la sección 6 para mejorar el modelo final).

Tarea 4

Instrucciones

Los resultados de los ejericicios propuestos se deben entregar como un notebook por correo electronico a juancaros@udec.cl el dia 6/12 hasta las 21:00. Utilizar la base de datos junaeb2.csv. La base corresponde a observaciones tomadas de estudiantes de colegio. Las variables tienen la siguiente descripcion:

*sk1-sk13 se usan para el análisis factorial.

- sexo: sexo del estudiante
- edad: edad del estudiante (meses)
- imce: indice de masa corporal estandarizado
- vive_padre: si el padre vive en el hogar
- vive madre: si la madre vive en el hogar
- area: urbana=1, rural=0
- sk1: muestra afecto a padres (1: siempre 5: nunca)

- sk2: muestra afecto a sus pares (1: siempre 5: nunca)
- sk3: expresa sus sentimientos (1: siempre 5: nunca)
- sk4: usa gestos para mostrar sentimientos (1: siempre 5: nunca)
- sk5: juega con otros (1: siempre 5: nunca)
- sk6: comparte sus cosas con otros (1: siempre 5: nunca)
- sk7: es agresivo (1: siempre 5: nunca)
- sk8: participa en juegos grupales (1: siempre 5: nunca)
- sk9: hace preguntas a adultos (1: siempre 5: nunca)
- sk10: tiene interes por libros (1: siempre 5: nunca)
- sk11: tiene interes por su entorno (1: siempre 5: nunca)
- sk12: juega a armar y desarmar cosas (1: siempre 5: nunca)
- sk13: tiene expresiones artisticas (1: siempre 5: nunca)
- act_fisica: frecuencia actividad fisica (1: nunca 5: 5 o mas veces a la semana)
- educm: años de escolaridad de la madre
- educp: años de escolaridad del padre
- madre_work: si la madre trabaja (-1: labor domestica, 0: desempleada, 1: empleada)

Preguntas:

- 1. Cargue la base de datos y realice los ajustes necesarios para su uso (missing values, recodificar variables, etcetera). Identifique los tipos de datos que se encuentran en la base, realice estadisticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario.
- 2. Usando las variables sk1-sk13 realice un PCA. En particular, identifique los valores propios y determine el numero optimo de componentes. Luego estime y grafique la distribucion de los componentes. Ademas discuta la importancia relativa de las variables sobre cada uno de los componentes estimados. Que se puede concluir de este analisis?
- 3. Con los resultados de la Pregunta 2, mantenga los primeros 3 componentes principales. Graficamente indique si existen diferencias significativas entre grupos usando las siguientes variables: sexo, area, madre_work y act_fisica. Que puede concluir de los resultados? (gráfico de puntitos)
- 4. A partir del mismo set de variables sk1-sk13 realice un EFA. En particular determine el numero optimo de factores y las variables que se asocian a cada factor. Tambien discuta si existen variables que no son informativas (Hint: para realizar un EFA, todas las variables deben estar representatadas en el mismo sentido logico. Si una carateristica es negativa debe ser invertida en la escala, de tal forma que todas las variables representen aspectos positivos).
- 5. Con los resultados obtenidos en la Pregunta 4, proponga un CFA donde cada variable solo se asocia con un factor. Entregue un nombre a cada factor que representa el concepto comun entre todas las variables. Reporte la importancia de cada medida (variable) a cada factor e indique la correlacion entre factores. (solo la parte de medida)
- 6. Finalmente, implemente un SEM completo usando la estructura propuesta en la Pregunta 5. En particular, estime un modelo donde los factores explican el nivel de actividad fisica, junto con otras variables que existen en la base de datos. Ademas utilice otras variables relevantes de la base de datos para explicar los factores latentes. Las variables a incluir en el modelo final deben tener sustento teorico y el modelo final debe optimizar el ajuste a los datos, en base a los criterios vistos en clase. Que puede concluir en base a sus resultados?

(Con las medidas se generan los factores, y los factores predicen un resultado y además usan otras variables asociadas a los factores). Incluir otras var que puedan influir en la actividad física (ej: escolaridad puede explicar la var resultado de actividad física como los factores). Numero de regresiones: una para cada factor y una para la var resultado. No es necesario declarar las correlaciones residuales. Interpretación: los factores afectan la actividad física o no, cambia si se agregan var independientes?, dar nombre a los factores (que podría representar?)