Tarea4_Jara_Retamal_ (1)

December 19, 2022

Section 6: Structural Equation Modelling

Tarea 4 Integrantes:

- Francisca Carolina Jara Yévenes
- Luis Fernando Retamal Fuentes

Fecha: 6 de diciembre de 2022

Bibliotecas requeridas

[ ]:
```
%pip install linearmodels
%pip install semopy
%pip install factor_analyzer
import numpy as np
import pandas as  pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
import statsmodels.formula.api as smf
import sklearn
import scipy
import matplotlib.pyplot as plt
from scipy.linalg import eigh, cholesky
from scipy.stats import norm
import linearmodels.panel as lmp
from pylab import plot, show, axis, subplot, xlabel, ylabel, grid
import semopy
import seaborn as sns
from factor_analyzer import FactorAnalyzer
from sklearn.decomposition import PCA
import seaborn as sns
%matplotlib inline
%pip install graphviz
```

```
Looking in indexes: https://pypi.org/simple, https://us-python.pkg.dev/colab-
wheels/public/simple/
Collecting linearmodels
  Downloading
linearmodels-4.27-cp38-cp38-manylinux_2_17_x86_64.manylinux2014_x86_64.whl (1.5
MB)
```

```
     |                 | 1.5 MB 4.8 MB/s
Requirement already satisfied: scipy>=1.2 in
/usr/local/lib/python3.8/dist-packages (from linearmodels) (1.7.3)
Requirement already satisfied: pandas>=0.24 in /usr/local/lib/python3.8/dist-
packages (from linearmodels) (1.3.5)
Requirement already satisfied: statsmodels>=0.11 in
/usr/local/lib/python3.8/dist-packages (from linearmodels) (0.12.2)
Collecting pyhdfe>=0.1
  Downloading pyhdfe-0.1.1-py3-none-any.whl (18 kB)
Collecting setuptools-scm<7.0.0,>=6.4.2
  Downloading setuptools_scm-6.4.2-py3-none-any.whl (37 kB)
Requirement already satisfied: Cython>=0.29.21 in /usr/local/lib/python3.8/dist-
packages (from linearmodels) (0.29.32)
Requirement already satisfied: numpy>=1.16 in /usr/local/lib/python3.8/dist-
packages (from linearmodels) (1.21.6)
Collecting formulaic~=0.3.2
  Downloading formulaic-0.3.4-py3-none-any.whl (68 kB)
     |                 | 68 kB 2.1 MB/s
Collecting mypy-extensions>=0.4
  Downloading mypy_extensions-0.4.3-py2.py3-none-any.whl (4.5 kB)
Collecting property-cached>=1.6.3
  Downloading property_cached-1.6.4-py2.py3-none-any.whl (7.8 kB)
Collecting interface-meta<2.0.0,>=1.2.0
  Downloading interface_meta-1.3.0-py3-none-any.whl (14 kB)
Requirement already satisfied: astor>=0.8 in /usr/local/lib/python3.8/dist-
packages (from formulaic~=0.3.2->linearmodels) (0.8.1)
Requirement already satisfied: wrapt>=1.0 in /usr/local/lib/python3.8/dist-
packages (from formulaic~=0.3.2->linearmodels) (1.14.1)
Requirement already satisfied: pytz>=2017.3 in /usr/local/lib/python3.8/dist-
packages (from pandas>=0.24->linearmodels) (2022.6)
Requirement already satisfied: python-dateutil>=2.7.3 in
/usr/local/lib/python3.8/dist-packages (from pandas>=0.24->linearmodels) (2.8.2)
Requirement already satisfied: six>=1.5 in /usr/local/lib/python3.8/dist-
packages (from python-dateutil>=2.7.3->pandas>=0.24->linearmodels) (1.15.0)
Requirement already satisfied: setuptools in /usr/local/lib/python3.8/dist-
packages (from setuptools-scm<7.0.0,>=6.4.2->linearmodels) (57.4.0)
Requirement already satisfied: tomli>=1.0.0 in /usr/local/lib/python3.8/dist-
packages (from setuptools-scm<7.0.0,>=6.4.2->linearmodels) (2.0.1)
Requirement already satisfied: packaging>=20.0 in /usr/local/lib/python3.8/dist-
packages (from setuptools-scm<7.0.0,>=6.4.2->linearmodels) (21.3)
Requirement already satisfied: pyparsing!=3.0.5,>=2.0.2 in
/usr/local/lib/python3.8/dist-packages (from packaging>=20.0->setuptools-
scm<7.0.0,>=6.4.2->linearmodels) (3.0.9)
Requirement already satisfied: patsy>=0.5 in /usr/local/lib/python3.8/dist-
packages (from statsmodels>=0.11->linearmodels) (0.5.3)
Installing collected packages: interface-meta, setuptools-scm, pyhdfe, property-
cached, mypy-extensions, formulaic, linearmodels
Successfully installed formulaic-0.3.4 interface-meta-1.3.0 linearmodels-4.27
```

```
mypy-extensions-0.4.3 property-cached-1.6.4 pyhdfe-0.1.1 setuptools-scm-6.4.2
Looking in indexes: https://pypi.org/simple, https://us-python.pkg.dev/colab-
wheels/public/simple/
Collecting semopy
  Downloading semopy-2.3.9.tar.gz (1.6 MB)
     |                 | 1.6 MB 5.8 MB/s
Requirement already satisfied: scipy in /usr/local/lib/python3.8/dist-
packages (from semopy) (1.7.3)
Requirement already satisfied: numpy in /usr/local/lib/python3.8/dist-packages
(from semopy) (1.21.6)
Requirement already satisfied: pandas in /usr/local/lib/python3.8/dist-packages
(from semopy) (1.3.5)
Requirement already satisfied: sympy in /usr/local/lib/python3.8/dist-packages
(from semopy) (1.7.1)
Collecting sklearn
  Downloading sklearn-0.0.post1.tar.gz (3.6 kB)
Requirement already satisfied: statsmodels in /usr/local/lib/python3.8/dist-
packages (from semopy) (0.12.2)
Requirement already satisfied: pytz>=2017.3 in /usr/local/lib/python3.8/dist-
packages (from pandas->semopy) (2022.6)
Requirement already satisfied: python-dateutil>=2.7.3 in
/usr/local/lib/python3.8/dist-packages (from pandas->semopy) (2.8.2)
Requirement already satisfied: six>=1.5 in /usr/local/lib/python3.8/dist-
packages (from python-dateutil>=2.7.3->pandas->semopy) (1.15.0)
Requirement already satisfied: patsy>=0.5 in /usr/local/lib/python3.8/dist-
packages (from statsmodels->semopy) (0.5.3)
Requirement already satisfied: mpmath>=0.19 in /usr/local/lib/python3.8/dist-
packages (from sympy->semopy) (1.2.1)
Building wheels for collected packages: semopy, sklearn
  Building wheel for semopy (setup.py) … done
  Created wheel for semopy: filename=semopy-2.3.9-py3-none-any.whl size=1657804
sha256=a68c578e43ab0473689c50a448b70b8269ee467528f8314ca90d3e36e81ab9ed
  Stored in directory: /root/.cache/pip/wheels/aa/d5/83/afbfa4fe06d08c0ec7849e93
aa71843aa514684b3f22e3a694
  Building wheel for sklearn (setup.py) … done
  Created wheel for sklearn: filename=sklearn-0.0.post1-py3-none-any.whl
size=2344
sha256=0b3295239d69b30fe3154d62c9e06ae40780c17db960bfdabf82a269360d85a2
  Stored in directory: /root/.cache/pip/wheels/14/25/f7/1cc0956978ae479e75140219
088deb7a36f60459df242b1a72
Successfully built semopy sklearn
Installing collected packages: sklearn, semopy
Successfully installed semopy-2.3.9 sklearn-0.0.post1
Looking in indexes: https://pypi.org/simple, https://us-python.pkg.dev/colab-
wheels/public/simple/
Collecting factor_analyzer
  Downloading factor_analyzer-0.4.1.tar.gz (41 kB)
     |                 | 41 kB 614 kB/s
```

```
  Installing build dependencies … done
  Getting requirements to build wheel … done
    Preparing wheel metadata … done
Collecting pre-commit
  Downloading pre_commit-2.20.0-py2.py3-none-any.whl (199 kB)
     |                 | 199 kB 14.5 MB/s
Requirement already satisfied: numpy in /usr/local/lib/python3.8/dist-
packages (from factor_analyzer) (1.21.6)
Requirement already satisfied: scipy in /usr/local/lib/python3.8/dist-packages
(from factor_analyzer) (1.7.3)
Requirement already satisfied: pandas in /usr/local/lib/python3.8/dist-packages
(from factor_analyzer) (1.3.5)
Requirement already satisfied: scikit-learn in /usr/local/lib/python3.8/dist-
packages (from factor_analyzer) (1.0.2)
Requirement already satisfied: python-dateutil>=2.7.3 in
/usr/local/lib/python3.8/dist-packages (from pandas->factor_analyzer) (2.8.2)
Requirement already satisfied: pytz>=2017.3 in /usr/local/lib/python3.8/dist-
packages (from pandas->factor_analyzer) (2022.6)
Requirement already satisfied: six>=1.5 in /usr/local/lib/python3.8/dist-
packages (from python-dateutil>=2.7.3->pandas->factor_analyzer) (1.15.0)
Collecting cfgv>=2.0.0
  Downloading cfgv-3.3.1-py2.py3-none-any.whl (7.3 kB)
Collecting identify>=1.0.0
  Downloading identify-2.5.9-py2.py3-none-any.whl (98 kB)
     |                 | 98 kB 7.1 MB/s
Collecting virtualenv>=20.0.8
  Downloading virtualenv-20.17.1-py3-none-any.whl (8.8 MB)
     |                 | 8.8 MB 22.0 MB/s
Collecting nodeenv>=0.11.1
  Downloading nodeenv-1.7.0-py2.py3-none-any.whl (21 kB)
Requirement already satisfied: pyyaml>=5.1 in /usr/local/lib/python3.8/dist-
packages (from pre-commit->factor_analyzer) (6.0)
Requirement already satisfied: toml in /usr/local/lib/python3.8/dist-packages
(from pre-commit->factor_analyzer) (0.10.2)
Requirement already satisfied: setuptools in /usr/local/lib/python3.8/dist-
packages (from nodeenv>=0.11.1->pre-commit->factor_analyzer) (57.4.0)
Requirement already satisfied: filelock<4,>=3.4.1 in
/usr/local/lib/python3.8/dist-packages (from virtualenv>=20.0.8->pre-
commit->factor_analyzer) (3.8.0)
Requirement already satisfied: platformdirs<3,>=2.4 in
/usr/local/lib/python3.8/dist-packages (from virtualenv>=20.0.8->pre-
commit->factor_analyzer) (2.5.4)
Collecting distlib<1,>=0.3.6
  Downloading distlib-0.3.6-py2.py3-none-any.whl (468 kB)
     |                 | 468 kB 43.7 MB/s
Requirement already satisfied: joblib>=0.11 in
/usr/local/lib/python3.8/dist-packages (from scikit-learn->factor_analyzer)
(1.2.0)
```

```
Requirement already satisfied: threadpoolctl>=2.0.0 in
/usr/local/lib/python3.8/dist-packages (from scikit-learn->factor_analyzer)
(3.1.0)
Building wheels for collected packages: factor-analyzer
  Building wheel for factor-analyzer (PEP 517) … done
  Created wheel for factor-analyzer:
filename=factor_analyzer-0.4.1-py2.py3-none-any.whl size=42034
sha256=837a47596b42f0364ed6f660dae6e503127d70f4c9c6549f47c283e0ea9995ea
  Stored in directory: /root/.cache/pip/wheels/f5/8f/2e/a689c21bc4bf04f84ceebf4b
1f5846cacc04bfe179e7ad5ab0
Successfully built factor-analyzer
Installing collected packages: distlib, virtualenv, nodeenv, identify, cfgv,
pre-commit, factor-analyzer
Successfully installed cfgv-3.3.1 distlib-0.3.6 factor-analyzer-0.4.1
identify-2.5.9 nodeenv-1.7.0 pre-commit-2.20.0 virtualenv-20.17.1
Looking in indexes: https://pypi.org/simple, https://us-python.pkg.dev/colab-
wheels/public/simple/
Requirement already satisfied: graphviz in /usr/local/lib/python3.8/dist-
packages (0.10.1)
```

Pregunta 1 Cargue la base de datos y realice los ajustes necesarios para su uso (missing values, recodificar variables, etcetera). Identifique los tipos de datos que se encuentran en la base, realice estadisticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario.

[ ]:
```python
junaeb2 = pd.read_csv('junaeb2.csv')
junaeb2.dropna(inplace=True) ##remueve faltantes
junaeb2.reset_index(drop=True, inplace=True) ##resetea indices
junaeb2.describe() ##muestra principales estadisticas
```

[ ]:
```
               sexo          edad          imce    vive_padre    vive_madre  \
count  57357.000000  57357.000000  57357.000000  57357.000000  57357.000000
mean       0.535349     81.880032      1.018703      0.721464      0.976481
std        0.498753      3.767887      1.367474      0.449137      0.161354
min        0.000000     62.000000     -5.020000      0.000000      0.000000
25%        0.000000     80.000000      0.110000      0.000000      1.000000
50%        1.000000     81.000000      0.980000      1.000000      1.000000
75%        1.000000     83.000000      1.930000      1.000000      1.000000
max        1.000000    107.000000      5.040000      2.000000      2.000000

                sk1           sk2           sk3           sk4           sk5  \
count  57357.000000  57357.000000  57357.000000  57357.000000  57357.000000
mean       1.106439      1.385550      1.253500      1.246823      1.263699
std        0.375685      0.646275      0.572033      0.562731      0.558155
min        1.000000      1.000000      1.000000      1.000000      1.000000
25%        1.000000      1.000000      1.000000      1.000000      1.000000
50%        1.000000      1.000000      1.000000      1.000000      1.000000
75%        1.000000      2.000000      1.000000      1.000000      1.000000
```

```
max        5.000000      5.000000      5.000000      5.000000      5.000000

       …           sk9          sk10          sk11          sk12  \
count  …  57357.000000  57357.000000  57357.000000  57357.000000
mean   …      1.322576      1.845651      1.376972      1.489304
std    …      0.651805      0.933007      0.658345      0.786647
min    …      1.000000      1.000000      1.000000      1.000000
25%    …      1.000000      1.000000      1.000000      1.000000
50%    …      1.000000      2.000000      1.000000      1.000000
75%    …      1.000000      2.000000      2.000000      2.000000
max    …      5.000000      5.000000      5.000000      5.000000

               sk13    act_fisica          area         educm         educp  \
count  57357.000000  57357.000000  57357.000000  57357.000000  57357.000000
mean       1.683474      2.559461      0.907213     13.084175     12.988807
std        0.977397      1.070257      0.290137      3.321205      3.420867
min        1.000000      1.000000      0.000000      0.000000      0.000000
25%        1.000000      2.000000      1.000000     12.000000     11.000000
50%        1.000000      2.000000      1.000000     13.000000     13.000000
75%        2.000000      3.000000      1.000000     15.000000     14.000000
max        5.000000      5.000000      1.000000     22.000000     22.000000

         madre_work
count  57357.000000
mean       0.102498
std        0.941063
min       -1.000000
25%       -1.000000
50%        0.000000
75%        1.000000
max        1.000000

[8 rows x 23 columns]
```

Se analizan las variables con datos que no corresponden por ejemplo la variable binaria vive_padre. Según la información dada hay datos donde vive_padre=2 por lo tanto se eliminan dichos datos.

[ ]:
```
junaeb2 = junaeb2.drop(junaeb2[junaeb2['vive_padre']==2].index)
junaeb2 = junaeb2.drop(junaeb2[junaeb2['vive_madre']==2].index)
```

Datatypes Se identifican los principales tipos de datos presentes en la base de datos.

[ ]:
```
junaeb2.dtypes
```

[ ]:
```
sexo              int64
edad              int64
imce            float64
vive_padre        int64
```

```
vive_madre      int64
sk1             int64
sk2             int64
sk3             int64
sk4             int64
sk5             int64
sk6             int64
sk7             int64
sk8             int64
sk9             int64
sk10            int64
sk11            int64
sk12            int64
sk13            int64
act_fisica    float64
area            int64
educm         float64
educp           int64
madre_work      int64
dtype: object
```

Outliers

[ ]:
```
boxplot = junaeb2.boxplot(grid=True,rot=90, fontsize=20,figsize =(20, 5))
plt.title('Análisis outliers dataframe')
```

[ ]:
```
Text(0.5, 1.0, 'Análisis outliers dataframe')
```

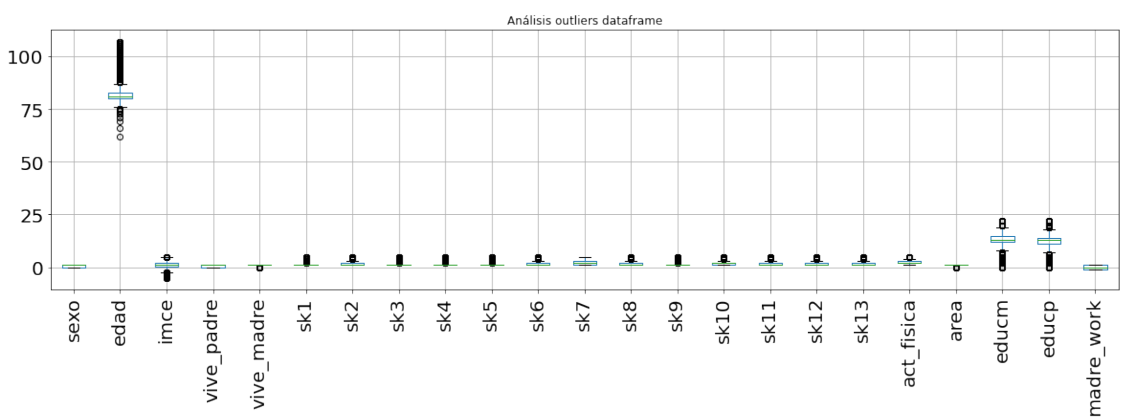

Se analizan los puntos atípicos en el anexo 2, para cada una de las variables. Y se eliminan del dataframe.

[ ]:
```
junaeb2 = junaeb2.drop(junaeb2[junaeb2['edad']<77].index)
junaeb2 = junaeb2.drop(junaeb2[junaeb2['imce']<-3.4].index)
```

```
junaeb2 = junaeb2.drop(junaeb2[junaeb2['educp']<2].index)
junaeb2 = junaeb2.drop(junaeb2[junaeb2['educm']<2].index)
```

Pregunta 2 Usando las variables sk1-sk13 realice un PCA. En particular, identifique los valores propios y determine el numero optimo de componentes. Luego estime y grafique la distribucion de los componentes. Ademas discuta la importancia relativa de las variables sobre cada uno de los componentes estimados. Que se puede concluir de este analisis?

En primer lugar se crea una copia del dataframe original para poder realizar las modificaciones necesarias. Posteriormente se mantienen solo las variables que seran utilizadas para el análisis de componentes principales.

```
[ ]: junaeb=junaeb2
     junaeb=junaeb.
      ↪drop(['sexo','edad','imce','vive_padre','vive_madre','act_fisica','area','educm','educp','m
      ↪axis=1)
```

```
[ ]: junaeb3=junaeb
```

```
[ ]: junaeb4=junaeb2
```

Matriz de covarianzas

```
[ ]: cov_mat = junaeb.cov()
```

```
[ ]: evals, evecs = eigh(cov_mat)
     print(evals)
```

```
[0.09431962 0.15725569 0.18658041 0.22026655 0.24292338 0.32829119
 0.38883165 0.4792948  0.49798753 0.59555034 0.75011716 1.40884446
 2.1387159 ]
```

Número de componentes

```
[ ]: pca = PCA(n_components='mle')
     pca_features = pca.fit_transform(junaeb)
     print(pca.explained_variance_ratio_)
```

```
[0.28558178 0.18812238 0.10016281 0.07952357 0.06649605 0.06400002
 0.05192052 0.04383658 0.03243745 0.02941209 0.024914   0.02099828]
```

```
[ ]: #scree plot using explained variance proportion

     PC_values = np.arange(pca.n_components_) + 1
     plt.plot(PC_values, pca.explained_variance_ratio_, 'o-', linewidth=2,␣
      ↪color='blue')
     plt.title('Scree Plot')
     plt.xlabel('Principal Component')
     plt.ylabel('Variance Explained')
```

```python
plt.show()
```

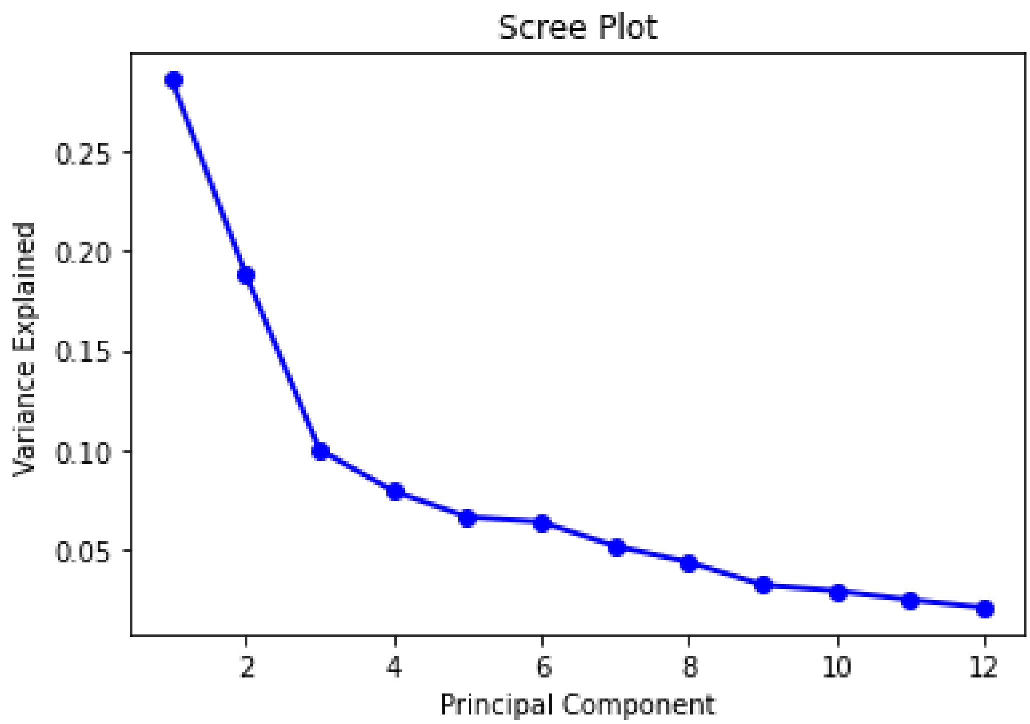

[ ]:
```python
pca_vectors = pd.DataFrame(data = pca.components_)
pca_vectors.head()
```

[ ]:

	0	1	2	3	4	5	6
0	0.103114	0.228291	0.168511	0.184532	0.185546	0.252601	0.345430
1	0.007136	0.031170	0.062702	0.053515	0.039694	-0.030137	-0.925045
2	0.083152	0.266199	0.183683	0.190855	0.297749	0.334707	-0.115595
3	0.001087	-0.024209	-0.033307	-0.027283	-0.042926	0.004597	-0.035205
4	0.150304	0.293709	0.313977	0.306309	-0.013573	0.184262	-0.039079

	7	8	9	10	11	12
0	0.293430	0.239209	0.405149	0.286881	0.292054	0.426828
1	0.100524	0.085439	0.166887	0.101584	0.153978	0.233893
2	0.478245	0.077155	-0.390723	0.000451	-0.087625	-0.492950
3	-0.095019	0.102984	0.697987	0.144889	0.018434	-0.682864
4	-0.757964	0.084334	-0.175872	0.085949	0.194917	-0.071698

[ ]:
```python
pca_df = pd.DataFrame(data=pca_features,columns=['PC1', 'PC2', 'PC3','PC4',␣
↪'PC5', 'PC6','PC7', 'PC8', 'PC9','PC10', 'PC11', 'PC12'])
pca_df.describe().apply(lambda s: s.apply('{0:.3f}'.format))
```

[ ]:
```
             PC1        PC2        PC3        PC4        PC5        PC6  \
count  56857.000  56857.000  56857.000  56857.000  56857.000  56857.000
mean      -0.000      0.000      0.000      0.000     -0.000     -0.000
std        1.462      1.187      0.866      0.772      0.706      0.692
min       -1.903     -3.217     -4.112     -3.460     -3.813     -3.917
25%       -1.095     -0.720     -0.469     -0.243     -0.286     -0.396
50%       -0.267      0.191      0.005     -0.091      0.098      0.033
75%        0.787      0.814      0.455      0.516      0.332      0.272
max       10.909      4.629      5.755      3.692      5.174      4.565

             PC7        PC8        PC9       PC10       PC11       PC12
count  56857.000  56857.000  56857.000  56857.000  56857.000  56857.000
mean      -0.000      0.000     -0.000      0.000     -0.000      0.000
std        0.624      0.573      0.493      0.469      0.432      0.397
min       -4.586     -4.370     -4.210     -3.560     -2.440     -3.102
25%       -0.313     -0.289     -0.213     -0.191     -0.217     -0.054
50%        0.062      0.027     -0.018      0.039      0.049      0.019
75%        0.309      0.193      0.207      0.117      0.113      0.040
max        4.708      5.221      4.459      3.789      3.832      3.272
```

[ ]:
```python
pca_df.corr().apply(lambda s: s.apply('{0:.3f}'.format))
```

[ ]:
```
         PC1     PC2     PC3     PC4     PC5     PC6     PC7     PC8     PC9  \
PC1    1.000   0.000   0.000   0.000  -0.000   0.000  -0.000   0.000  -0.000
PC2    0.000   1.000  -0.000   0.000  -0.000   0.000  -0.000  -0.000   0.000
PC3    0.000  -0.000   1.000  -0.000   0.000  -0.000   0.000   0.000   0.000
PC4    0.000   0.000  -0.000   1.000  -0.000  -0.000   0.000  -0.000   0.000
PC5   -0.000  -0.000   0.000  -0.000   1.000  -0.000  -0.000   0.000  -0.000
PC6    0.000   0.000  -0.000  -0.000  -0.000   1.000  -0.000  -0.000   0.000
PC7   -0.000  -0.000   0.000   0.000  -0.000  -0.000   1.000   0.000  -0.000
PC8    0.000  -0.000   0.000  -0.000   0.000  -0.000   0.000   1.000   0.000
PC9   -0.000   0.000   0.000   0.000  -0.000   0.000  -0.000   0.000   1.000
PC10   0.000  -0.000   0.000   0.000  -0.000  -0.000  -0.000  -0.000   0.000
PC11   0.000  -0.000   0.000  -0.000  -0.000  -0.000  -0.000   0.000   0.000
PC12  -0.000   0.000   0.000   0.000   0.000  -0.000   0.000   0.000   0.000

        PC10    PC11    PC12
PC1    0.000   0.000  -0.000
PC2   -0.000  -0.000   0.000
PC3    0.000   0.000   0.000
PC4    0.000  -0.000   0.000
PC5   -0.000  -0.000   0.000
PC6   -0.000  -0.000  -0.000
PC7   -0.000  -0.000   0.000
PC8   -0.000   0.000   0.000
PC9    0.000   0.000   0.000
PC10   1.000   0.000  -0.000
```

```
PC11    0.000    1.000    0.000
PC12   -0.000    0.000    1.000
```

Pregunta 3 Con los resultados de la Pregunta 2, mantenga los primeros 3 componentes principales. Graficamente indique si existen diferencias significativas entre grupos usando las siguientes variables: sexo, area, madre_work y act_fisica. Que puede concluir de los resultados?

[ ]:
```
pca = PCA(n_components=3)
pca_features = pca.fit_transform(junaeb)
print(pca.explained_variance_ratio_)
```

```
[0.28558178 0.18812238 0.10016281]
```

[ ]:
```
pca_vectors = pd.DataFrame(data = pca.components_)
pca_vectors.head()
```

[ ]:
```
          0         1         2         3         4         5         6  \
0  0.103114  0.228291  0.168511  0.184532  0.185546  0.252601  0.345430
1  0.007136  0.031170  0.062702  0.053515  0.039694 -0.030137 -0.925045
2  0.083152  0.266199  0.183683  0.190855  0.297749  0.334707 -0.115595

          7         8         9        10        11        12
0  0.293430  0.239209  0.405149  0.286881  0.292054  0.426828
1  0.100524  0.085439  0.166887  0.101584  0.153978  0.233893
2  0.478245  0.077155 -0.390723  0.000451 -0.087625 -0.492950
```

[ ]:
```
pca_df = pd.DataFrame(data=pca_features,columns=['PC1', 'PC2', 'PC3'])
pca_df.describe().apply(lambda s: s.apply('{0:.3f}'.format))
```

[ ]:
```
             PC1        PC2        PC3
count  56857.000  56857.000  56857.000
mean      -0.000      0.000     -0.000
std        1.462      1.187      0.866
min       -1.903     -3.217     -4.112
25%       -1.095     -0.720     -0.469
50%       -0.267      0.191      0.005
75%        0.787      0.814      0.455
max       10.909      4.629      5.755
```

[ ]:
```
pca_df.corr().apply(lambda s: s.apply('{0:.3f}'.format))
```

[ ]:
```
        PC1     PC2    PC3
PC1   1.000  -0.000  0.000
PC2  -0.000   1.000  0.000
PC3   0.000   0.000  1.000
```

[ ]:
```
#scatterplot for PC1, PC2, PC3

figure, axes = plt.subplots(3, sharex=False, figsize=(10,30))

axes[0].set_title('PC3 Removed')
axes[1].set_title('PC1 Removed')
axes[2].set_title('PC2 Removed')

sns.scatterplot('PC1', 'PC2', ax=axes[0], data=pca_df)
sns.scatterplot('PC2', 'PC3', ax=axes[1], data=pca_df)
sns.scatterplot('PC1', 'PC3', ax=axes[2], data=pca_df)
```

```
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
```

[ ]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x7fb2745c0820>
```

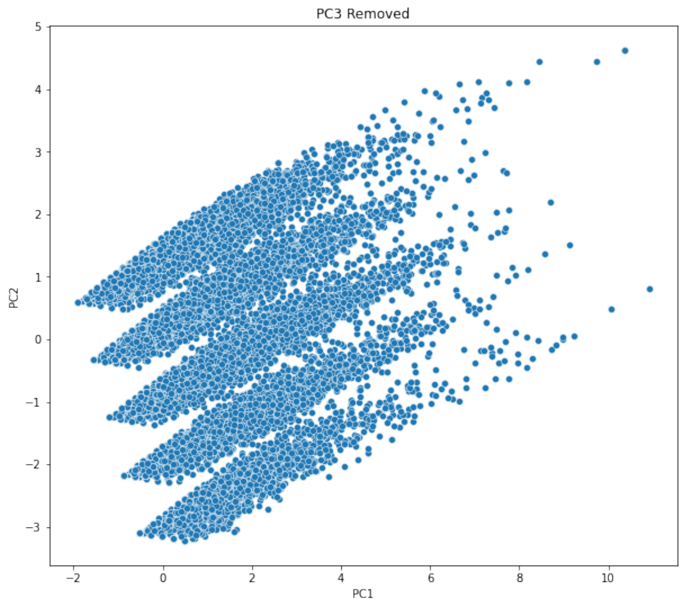
PC3 Removed
PC2
PC1
5
4
3
2
1
0
−1
−2
−3
−2
0
2
4
6
8
10

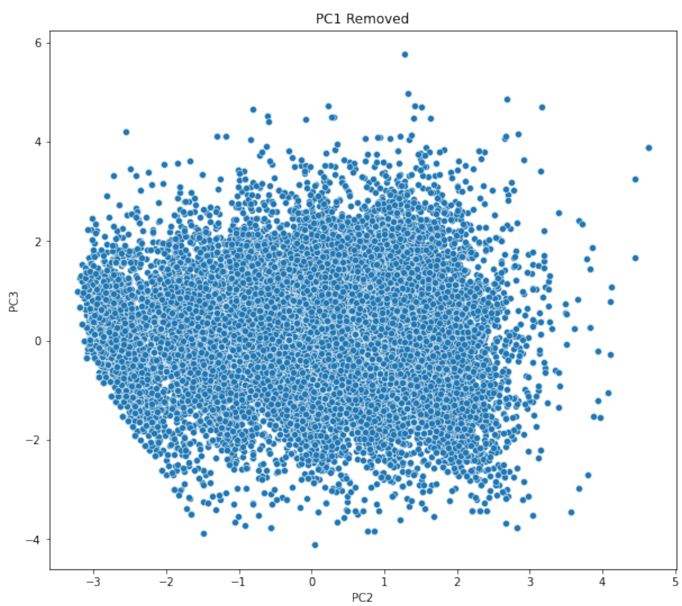
PC1 Removed
PC3
PC2
6
4
2
0
−2
−4
−3
−2
−1
0
1
2
3
4
5


PC2 Removed
PC3
PC1
6
4
2
0
−2
−4
−2
0
2
4
6
8
10

PC1 tiende a ser positivo. PC2 y PC3 parecieran distribuirse similarmente con respecto al origen.

[ ]:
```
#scatterplot for PC1, PC2, PC3 against binary partition of sexo

figure, axes = plt.subplots(3, sharex=False, figsize=(10, 30))
figure.suptitle('SEXO')

pca_df['sexo'] = 0
pca_df['sexo'] = np.where(junaeb2['sexo'] > 0, 1, pca_df['sexo'])

axes[0].set_title('PC3 Removed')
axes[1].set_title('PC1 Removed')
axes[2].set_title('PC2 Removed')

sns.scatterplot('PC1', 'PC2', ax=axes[0], data=pca_df, hue='sexo')
sns.scatterplot('PC2', 'PC3', ax=axes[1], data=pca_df, hue='sexo')
sns.scatterplot('PC1', 'PC3', ax=axes[2], data=pca_df, hue='sexo')
```

```
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
```

[ ]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x7fb2740f91f0>
```

SEXO

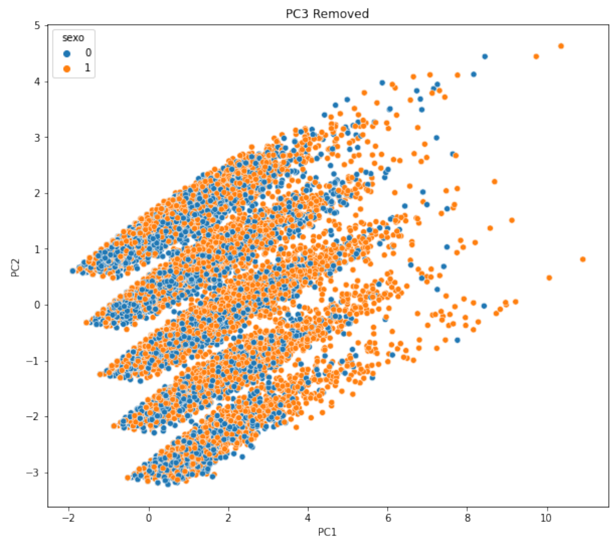
PC3 Removed
sexo
0
1
PC1
PC2


PC1 Removed
sexo
0
1
PC2
PC3


PC2 Removed
sexo
0
1
PC1
PC3

Se observa que no hay claridad en la formación de clusters.

Entre los componentes PC1 y PC3, se puede interpretar que si sexo = 1, PC3 suele ser negativo y PC1 positivo. En cambio, si sexo = 0, PC3 es positivo, al igual que PC1. Una situación similiar se observa cuando se evalúan los componentes PC2 y PC3. Si sexo = 0, PC3 toma un valor positivo. En caso contrario, PC3 toma un valor negativo. Se concluye que, a pesar de no ser clusters perfectamente definidos, el PC3 pareciera explicar la variación de la variable sexo.

[ ]:
```
#scatterplot for PC1, PC2, PC3 against binary partition of area

figure, axes = plt.subplots(3, sharex=False, figsize=(10, 30))
figure.suptitle('AREA')

pca_df['area'] = 0
pca_df['area'] = np.where(junaeb2['area'] > 0, 1, pca_df['area'])

axes[0].set_title('PC3 Removed')
axes[1].set_title('PC1 Removed')
axes[2].set_title('PC2 Removed')

sns.scatterplot('PC1', 'PC2', ax=axes[0], data=pca_df, hue='area')
sns.scatterplot('PC2', 'PC3', ax=axes[1], data=pca_df, hue='area')
sns.scatterplot('PC1', 'PC3', ax=axes[2], data=pca_df, hue='area')
```

```
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
```

[ ]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x7fb274798b20>
```

AREA

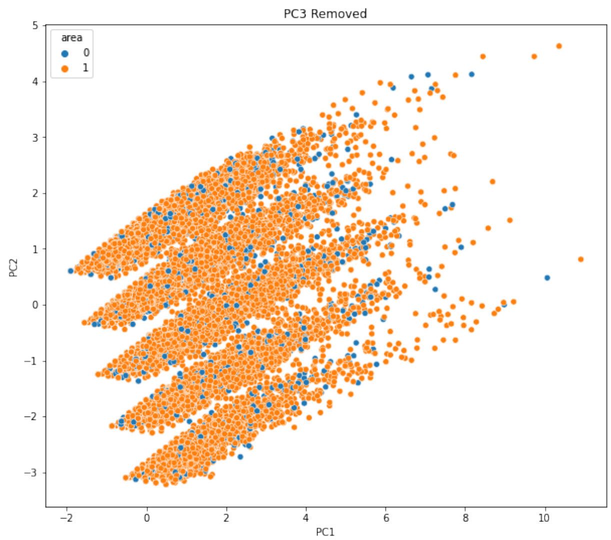
PC3 Removed
area
0
1
PC2
PC1

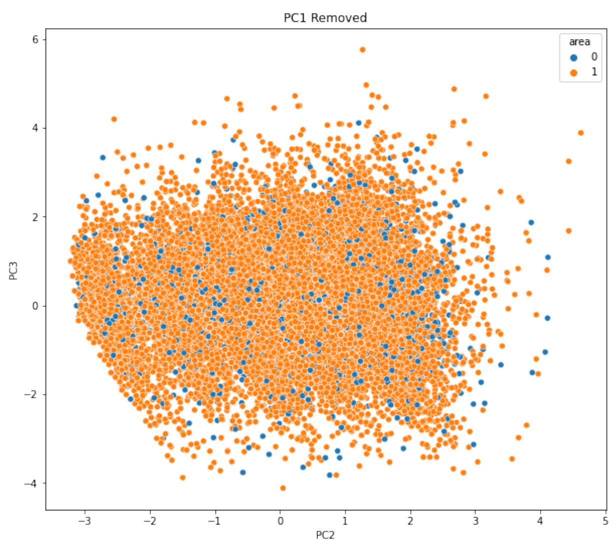
PC1 Removed
area
0
1
PC3
PC2


PC2 Removed
area
0
1
PC3
PC1

La diferencia entre los valores de las observaciones, es decir, entre los area = 1 y area = 0, dificulta la interpretación de la relación entre los componentes. Esto debido a que hay una mayor cantidad de datos con el valor 1, por lo que pareciera ser un cluster. Los pocos datos con el valor 0 parecen estar sueltos en comparación.

[ ]:
```
#scatterplot for PC1, PC2, PC3 against binary partition of madre_work

figure, axes = plt.subplots(3, sharex=False, figsize=(10,30))
figure.suptitle('MADRE_WORK')

pca_df['madre_work'] = 0
pca_df['madre_work'] = np.where(junaeb2['madre_work'] == -1, -1,␣
  ↪pca_df['madre_work'])
pca_df['madre_work'] = np.where(junaeb2['madre_work'] == 1, 1,␣
  ↪pca_df['madre_work'])

axes[0].set_title('PC3 Removed')
axes[1].set_title('PC1 Removed')
axes[2].set_title('PC2 Removed')

sns.scatterplot('PC1', 'PC2', ax=axes[0], data=pca_df, hue='madre_work')
sns.scatterplot('PC2', 'PC3', ax=axes[1], data=pca_df, hue='madre_work')
sns.scatterplot('PC1', 'PC3', ax=axes[2], data=pca_df, hue='madre_work')
```

```
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
```

[ ]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x7fb26c0f2a90>
```

MADRE_WORK

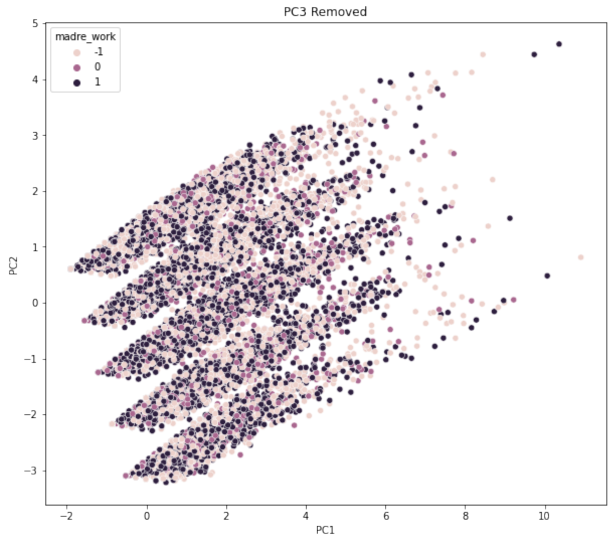
PC3 Removed
madre_work
-1
0
1
PC1
PC2

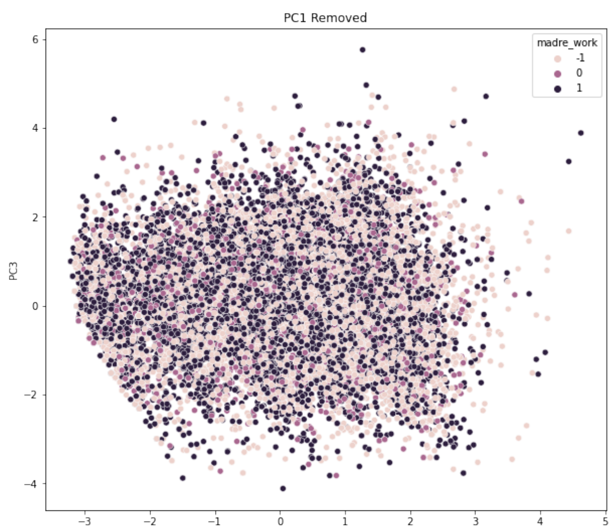
PC1 Removed
madre_work
-1
0
1
PC2
PC3

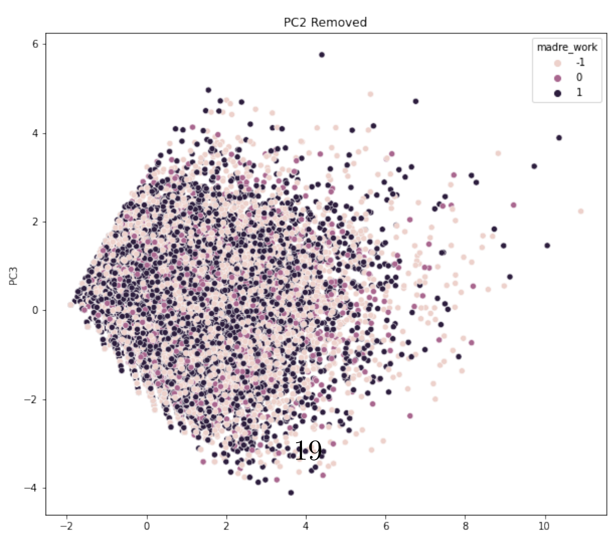
PC2 Removed
madre_work
-1
0
1
PC1
PC3

No existe una clasificación. No se observa separación de grupos. Se concluye que ninguno de estos componentes explica la variable madre_work.

[ ]:
```
#scatterplot for PC1, PC2, PC3 against discrete partition of act_fisica

figure, axes = plt.subplots(3, sharex=False, figsize=(10, 30))
figure.suptitle('ACT_FISICA')

pca_df['act_fisica'] = 0
pca_df['act_fisica'] = np.where(junaeb2['act_fisica'] == 1, 1,␣
 ↪pca_df['act_fisica'])
pca_df['act_fisica'] = np.where(junaeb2['act_fisica'] == 2, 2,␣
 ↪pca_df['act_fisica'])
pca_df['act_fisica'] = np.where(junaeb2['act_fisica'] == 3, 3,␣
 ↪pca_df['act_fisica'])
pca_df['act_fisica'] = np.where(junaeb2['act_fisica'] == 4, 4,␣
 ↪pca_df['act_fisica'])
pca_df['act_fisica'] = np.where(junaeb2['act_fisica'] == 5, 5,␣
 ↪pca_df['act_fisica'])

axes[0].set_title('PC3 Removed')
axes[1].set_title('PC1 Removed')
axes[2].set_title('PC2 Removed')

sns.scatterplot('PC1', 'PC2', ax=axes[0], data=pca_df, hue='act_fisica')
sns.scatterplot('PC2', 'PC3', ax=axes[1], data=pca_df, hue='act_fisica')
sns.scatterplot('PC1', 'PC3', ax=axes[2], data=pca_df, hue='act_fisica')
```

```
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
/usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning:
Pass the following variables as keyword args: x, y. From version 0.12, the only
valid positional argument will be `data`, and passing other arguments without an
explicit keyword will result in an error or misinterpretation.
  warnings.warn(
```

[ ]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x7fb2742347c0>
```

ACT_FISICA

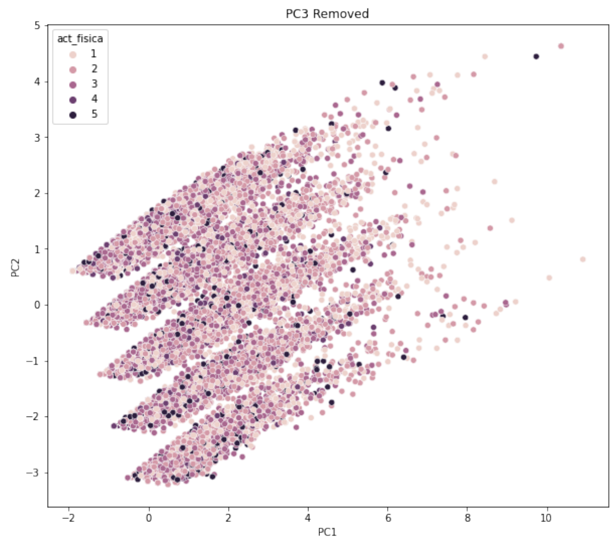
PC3 Removed
act_fisica
1
2
3
4
5
PC1
PC2

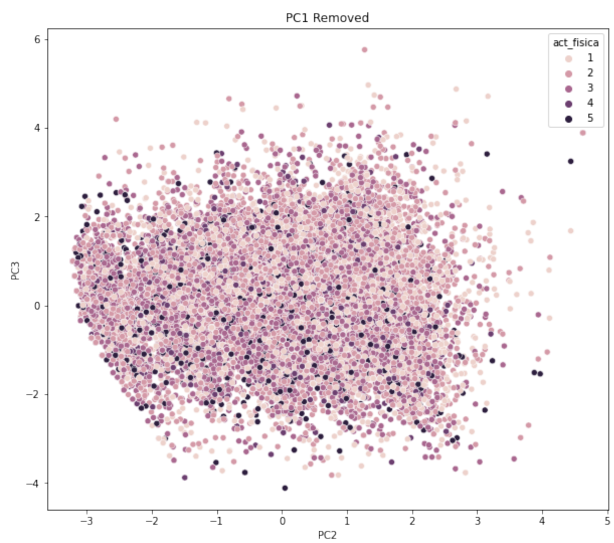
PC1 Removed
act_fisica
1
2
3
4
5
PC2
PC3

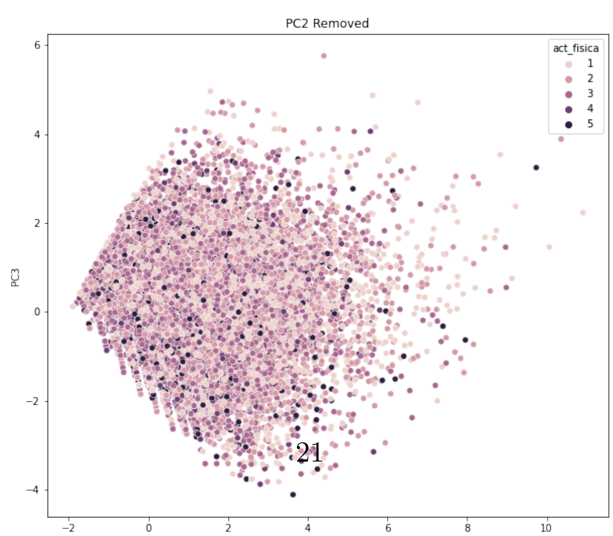
PC2 Removed
act_fisica
1
2
3
4
5
PC1
PC3

Situación similar a la varible madre_work. No hay una clara separación de grupos, por lo que no se puede hacer una interpretación. Ninguno de los componentes explica la variable act_fisica.

Como los componentes principales PC1, PC2 y PC3 fueron calculados sin la presencia de las variables sexo, area, madre_work y act_fisica, la relación de los componentes no explica con claridad visual la variación de estas. Si se utilizara alguna de las variables sk1-13, con las que se determinaron los componentes, los gráficos mostrarían con mayor claridad los clusters para cada valor.

[ ]:
```
pca_df1=pca_df.corr()
pca_df1=pca_df1.drop(['PC1', 'PC2', 'PC3'], axis=1)
pca_df1=pca_df1.drop(['sexo', 'area', 'madre_work', 'act_fisica'], axis=0)

plt.figure(figsize=(6,8))
sns.heatmap(pca_df1, annot = True, fmt='.3f', cbar_kws={"orientation":
 ↪"horizontal"})
```

[ ]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x7fb27467f280>
```

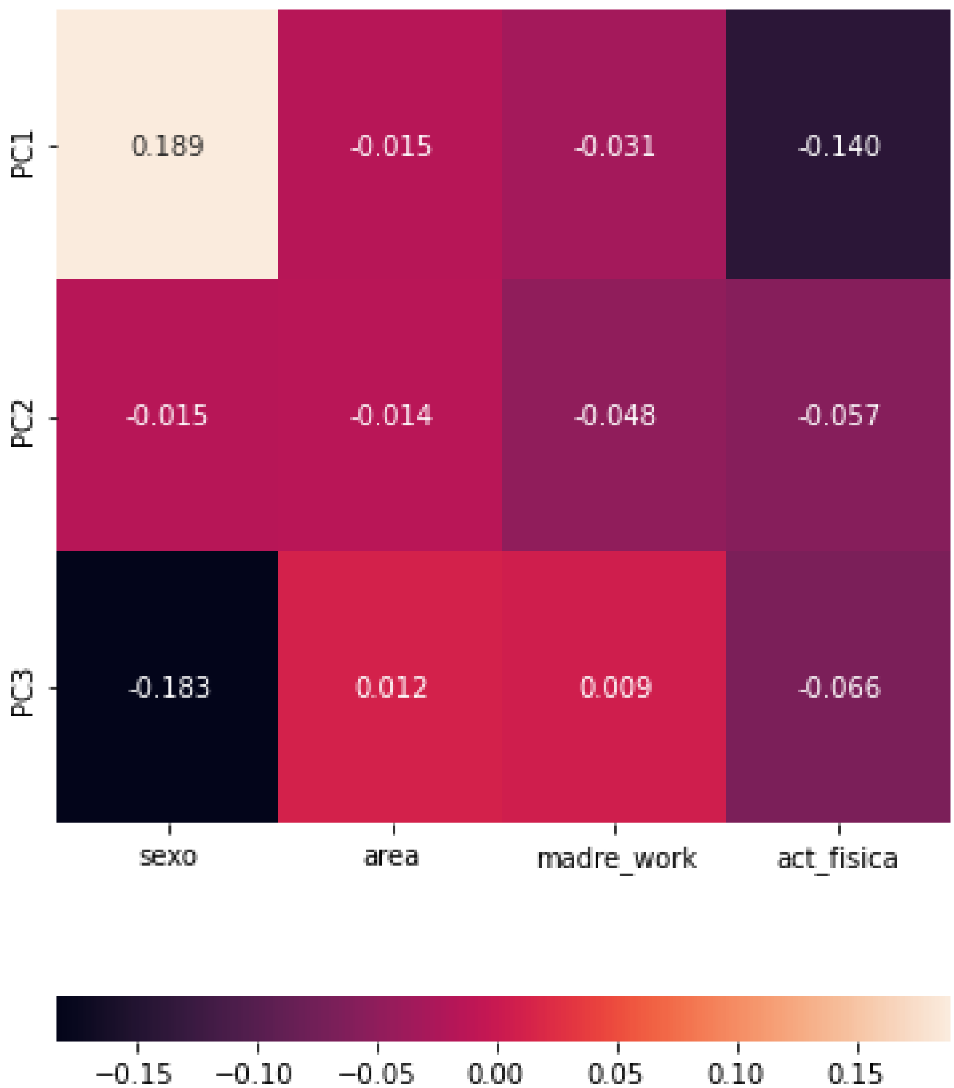

El heatmap muestra la correlación entre las variables sexo, area, madre_work y act_fisica, con los componentes PC1, PC2 y PC3. Como se puede observar, la correlación entre las variables y los componentes es bastante baja. La correlación más alta es entre la variable sexo con los componentes PC1 (positva) y PC3 (negativa). Con este heatmap se confirma la interpretación de los gráficos de puntos.

Pregunta 4 A partir del mismo set de variables sk1-sk13 realice un EFA. En particular determine el numero optimo de factores y las variables que se asocian a cada factor. Tambien discuta si existen variables que no son informativas (Hint: para realizar un EFA, todas las variables deben estar representatadas en el mismo sentido logico. Si una carateristica es negativa debe ser invertida en la escala, de tal forma que todas las variables representen aspectos positivos).

Dado que todas las variables deben estar representatadas en el mismo sentido lógico, se analizan las 13 variables involucradas. En este caso la variable sk7 tiene una connotación negativa repecto al resto de variables por lo que se invierte su valor y es re definida como:

sk7: No es agresivo (1: siempre - 5: nunca).

[ ]:
```
junaeb3.reset_index(drop=True, inplace=True)
```

[ ]:
```
largo=junaeb3.sk1.count()
list1=[]
for i in range(largo):
  if (junaeb3.sk7[i]==5):
    list1.append(1)
  elif (junaeb3.sk7[i]==4):
    list1.append(2)
  elif (junaeb3.sk7[i]==3):
    list1.append(3)
  elif (junaeb3.sk7[i]==2):
    list1.append(4)
  elif (junaeb3.sk7[i]==1):
    list1.append(5)
junaeb3=junaeb3.drop(columns=['sk7'])
junaeb3.insert(6,"sk7",list1,False)
```

[ ]:
```
fig, ax = plt.subplots(figsize=(9,7))
sns.heatmap(junaeb3.corr(), cmap='RdYlGn',linewidth=.5,annot_kws={'size': 30})
```

[ ]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x7fb26be86af0>
```

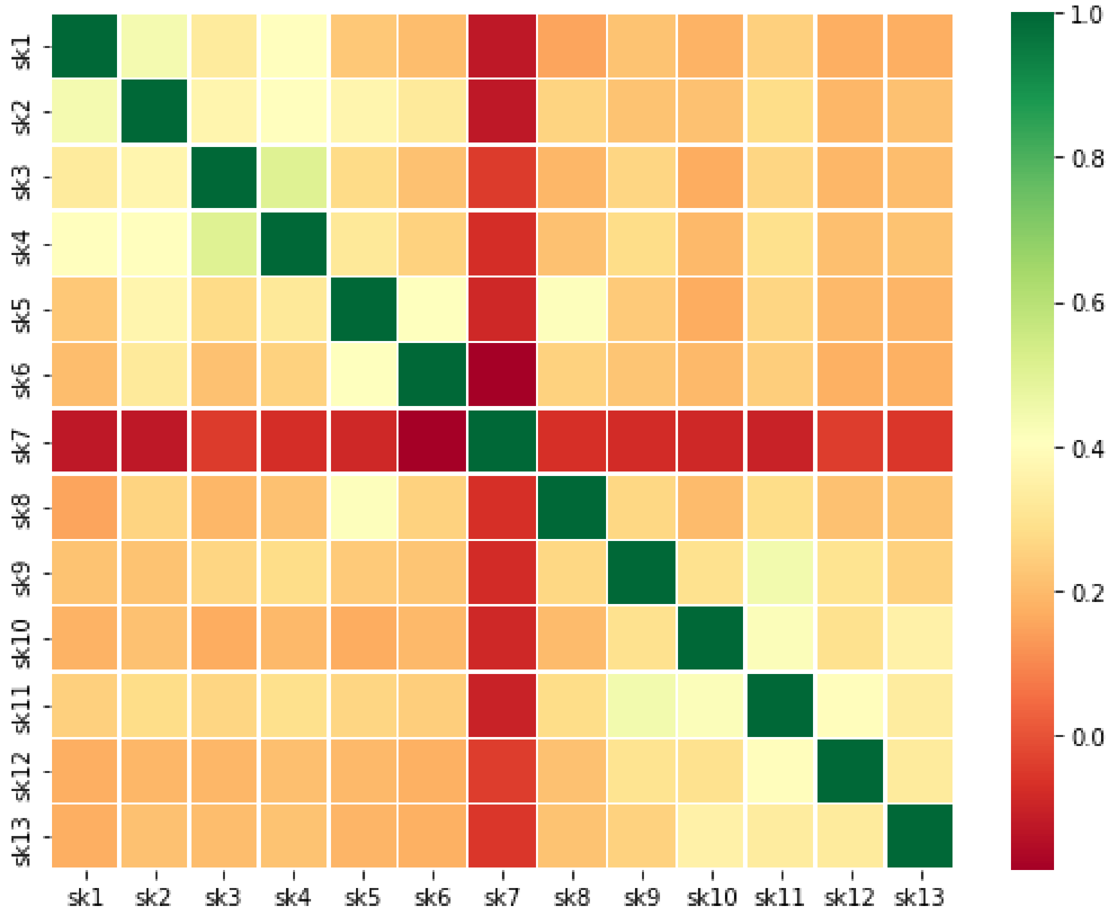

Dado que no se produjo el cambio necesario en la variable sk7 respecto al resto de variables, y sigue teniendo una correlacion en un sentido contrario, entonces es excluida de la data.

[ ]:
```
junaeb3=junaeb3.drop(['sk7'], axis=1)
```

[ ]:
```
junaeb3.head(3)
```

[ ]:

	sk1	sk2	sk3	sk4	sk5	sk6	sk8	sk9	sk10	sk11	sk12	sk13
0	1	1	1	1	1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1	1	1	1	1	1
2	1	1	1	2	2	2	2	3	3	3	2	2

[ ]:
```
fig, ax = plt.subplots(figsize=(9,7))
sns.heatmap(junaeb3.corr(), cmap='RdYlGn',linewidth=.5,annot_kws={'size': 30})
```

[ ]: <matplotlib.axes._subplots.AxesSubplot at 0x7fb27342a220>

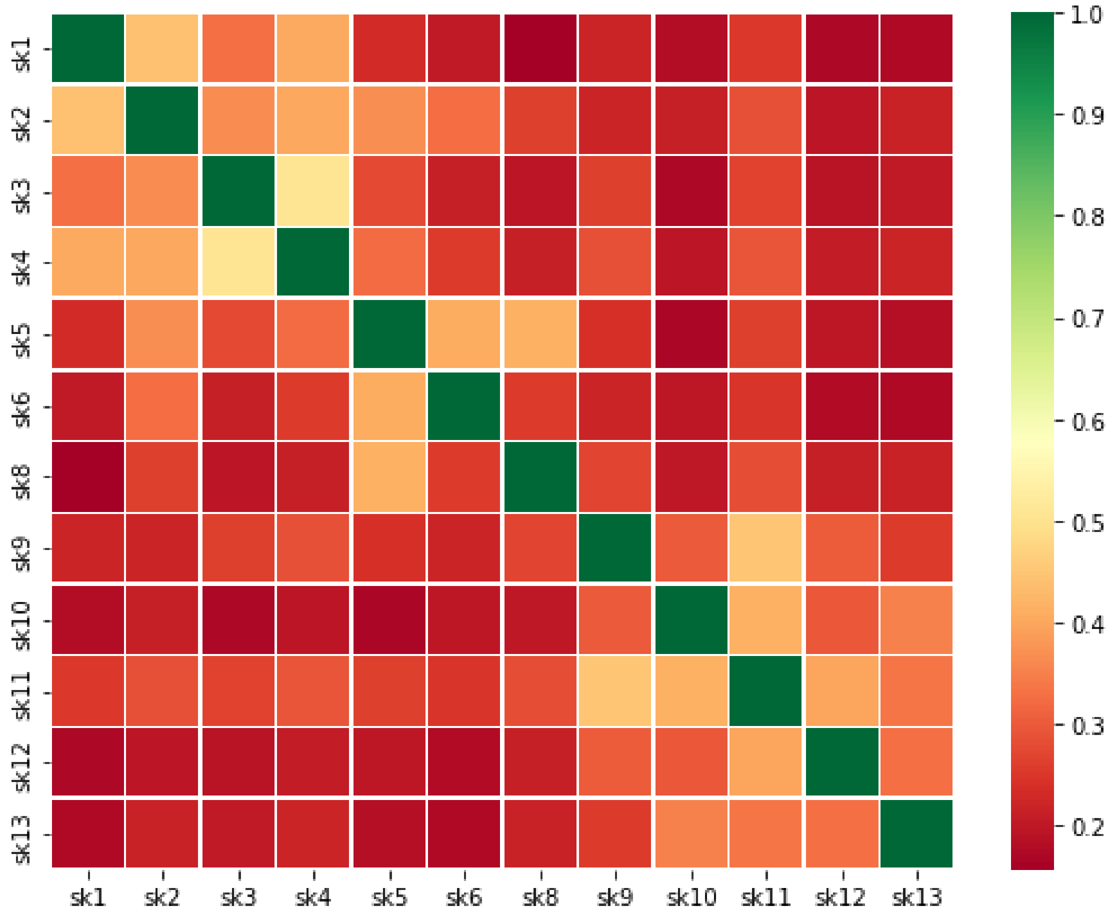

Se utiliza el análisis factorial incluyendo una rotación promax, para determinar la variable que pertenece a cada uno de los factores.

[ ]:
```
fa = FactorAnalyzer(rotation='promax')
fa.fit(junaeb3)
```

[ ]:
```
FactorAnalyzer(rotation_kwargs={})
```

Se procede a determinar la carga factorial para cada una de las variables.

[ ]:
```
fa.loadings_
```

[ ]:
```
array([[ 1.71190755e-02,  6.09036608e-01, -4.92604238e-02],
       [-2.39684004e-02,  5.15607493e-01,  2.00349173e-01],
       [ 1.90795172e-02,  6.41512599e-01, -3.34829721e-02],
       [ 4.61240517e-04,  7.33821478e-01, -2.63591229e-02],
       [-1.60568272e-01, -1.14854342e-02,  9.00443009e-01],
       [ 3.42486634e-02,  8.30212678e-02,  4.48174244e-01],
       [ 1.61091204e-01, -7.73518293e-02,  4.83330557e-01],
```

```
[ 4.87977896e-01,  8.27723571e-02,  4.35928634e-02],
[ 6.22881817e-01, -3.41077996e-02, -4.16988964e-02],
[ 6.98808354e-01,  2.97967371e-02,  4.56304122e-04],
[ 5.67475441e-01, -2.55404549e-02, -3.49514811e-04],
[ 5.25622343e-01,  1.88995601e-02, -1.11508448e-02]])
```

De este análisis se determina que variable informa a cada factor. En este caso el número de factores necesarios es determinado de forma óptima, debido a la utilización de la rotacion promax que permite que los factores estén correlacionados y un mayor grado de significancia.

Por lo tanto según este análisis de determina que el caso óptimo incluye la utilización de 3 factores.

Además se determina que para el primer factor está asociada la variable: sk9, sk10, sk11, sk12, sk13. Para el segundo factor se determina que estará asociada la variable: sk1, sk2, sk3, sk4. Para el tercer factor estará asociada la variable: sk5, sk6, sk8. Esto se determina debido a que cada una de las variables tiene una mayor carga factorial para cada uno de los factores mencionados. Por ejemplo para la variable sk1 evidentemente la carga asociada al segundo factor es la mayor de las 3.

Se determinan los valores propios.

[ ]:
```
fa.get_eigenvalues()
```

[ ]:
```
(array([3.96880782, 1.3543897 , 1.08115685, 0.79877207, 0.74511776,
        0.71492343, 0.69722711, 0.61332529, 0.5303692 , 0.51946822,
        0.50096316, 0.47547939]),
 array([ 3.3802477 ,  0.77993834,  0.61417727,  0.1512012 ,  0.0850587 ,
         0.04933503,  0.0221119 , -0.02824064, -0.03317337, -0.07859931,
        -0.09862045, -0.17341348]))
```

A pesar de determinar solo 3 factores se calculan todos los valores propios de la matriz.

[ ]:
```
values = np.arange(1,13)
eigenvalues = pd.DataFrame(data=fa.get_eigenvalues())
plt.figure(figsize=(9,5))
plt.plot(values, eigenvalues.loc[0], 'o-', linewidth=1, color='green')
plt.title('Scree Plot')
plt.xlabel('Componente principal')
plt.ylabel('Valores propios')

plt.show()
```

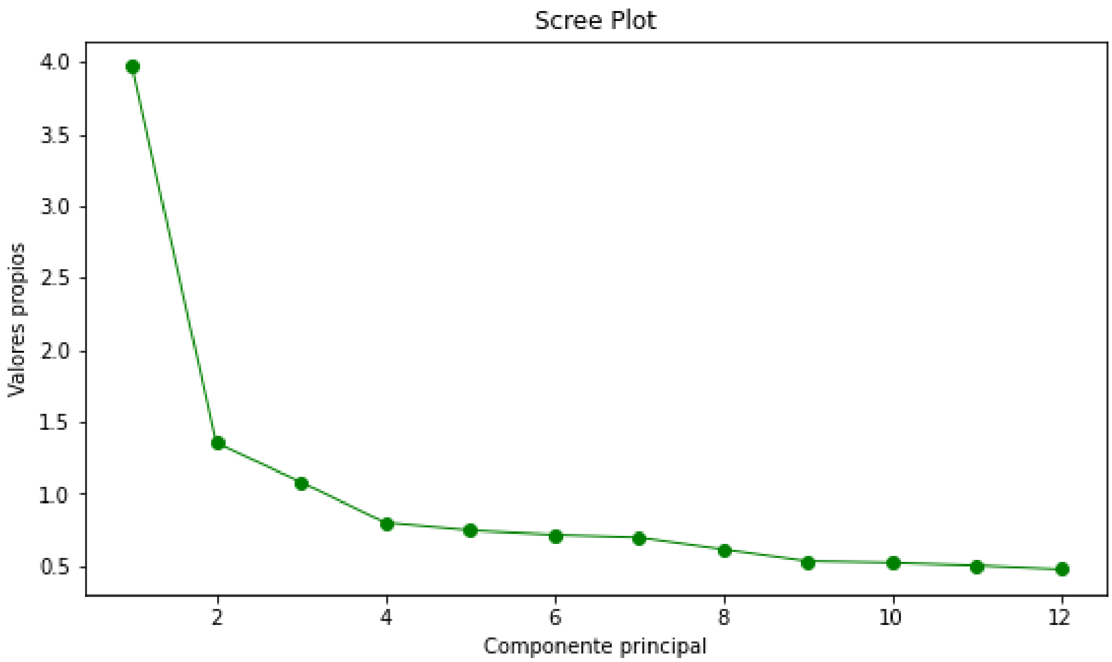

En este caso despues del cuarto factor la contribución relativa disminuye drásticamente. Pero de forma óptima se determinaron solo 3 factores.

Se agrega matriz de varianza y covarianza. Donde el primer array corresponde a la varianza de forma cruda, luego se agrega un array de proporción explicada de cada factor y un tercer array que corresponde a la proporción acumulada de cada factor.

[ ]:
```
fa.get_factor_variance()
```

[ ]:
```
(array([1.76688183, 1.60972876, 1.29341229]),
 array([0.14724015, 0.13414406, 0.10778436]),
 array([0.14724015, 0.28138422, 0.38916857]))
```

Se agrega además el análisis factorial exploratorio usando semopy. Este análisis da una idea del posible modelo. Es necesario notar que se repiten variables entre los factores, pero solo porque tienen alguna implicancia, y son significativas, con p=0,05.

[ ]:
```
print(semopy.efa.explore_cfa_model(junaeb3, pval=0.05))
```

```
eta1 =~ sk11 + sk9 + sk10 + sk12
eta2 =~ sk4 + sk2 + sk11 + sk3 + sk5 + sk1 + sk9 + sk6 + sk12
eta3 =~ sk11 + sk12 + sk13 + sk6
eta4 =~ sk5 + sk8 + sk9 + sk6
```

Pregunta 5 Con los resultados obtenidos en la Pregunta 4, proponga un CFA donde cada variable solo se asocia con un factor. Entregue un nombre a cada factor que representa el concepto comun entre todas las variables. Reporte la importancia de cada medida (variable) a cada factor e indique la correlacion entre factores.

Se utiliza el mismo dataframe juneb3. Utilizando el modelo obtenido anteriormente.

eta1 =~ sk9 + sk10 + sk11 + sk12 + sk13

eta2 =~ sk1 + sk2 + sk3 +sk4

eta3 =~ sk5 + sk6 + sk8

Si recurrimos a la definición de cada una de las variables o preguntas podemos notar que las variables sk9 a sk13 corresponden a preguntas a adultos, intereses, y expresiones artisticas en general. Por ende se define el primer factor como Intereres Personales. El segundo factor se define en base a las variables sk1 a sk4, las cuales representan la expresion de afectividad de una persona, por ende el segundo factor se le denomina afectividad. El tercer factor está relacionado con el grado de socialización de una persona, por ende el tercer factor le llamaremos socialización.

[ ]:
```
Xf=junaeb3

mod = """
# measurement model
Intereses_Personales =~ sk9 + sk10 + sk11 + sk12 + sk13
Afectividad =~ sk1 + sk2 + sk3 +sk4
Socialización =~ sk5 + sk6 + sk8
"""

model = semopy.Model(mod)
out=model.fit(Xf)
print(out)
```

```
Name of objective: MLW
Optimization method: SLSQP
Optimization successful.
Optimization terminated successfully
Objective value: 0.140
Number of iterations: 43
Params: 1.370 1.252 1.124 1.322 1.913 1.643 1.800 1.019 1.145 0.203 0.433 0.197
0.241 0.277 0.151 0.477 0.092 0.367 0.161 0.700 0.596 0.160 0.047 0.049 0.057
0.145 0.088
```

Se obtiene un modelo mediante la función maxima verosimilitud ponderada. El valor óptimo de la función es de 0,140. Se realizaron 43 iteraciones. Luego se entregan los parámetros que para cada factor hay un parámetro estimado.

Se analiza la importancia de cada medida a los factores correspondientes. Para ello se normaliza uno de los pesos relativos en este caso sk9 (su peso es 1) para el primer factor. Luego cada una de las demás variables tendrá un grado de importancia para el factor relativa a sk9. En este caso la variable que presenta una mayor importancia es sk10. Para el segundo factor la variable que se normalizó es sk1, donde la variable de mayor importancia es sk2. Y para el tercer factor la variable que se normalizó es sk5, y la variable con mayor importancia es sk8.

Luego se entrega la correlación entre los factores, en esta caso entre el factor socialización e intereses personales es de 0.580060. Luego entre socialización y afectividad es de 0.652928. Finalmente entre intereses personales y afectividad es de 0.591167. Notar que en los tres casos es bajísima esta correlación.

[ ]:
```
model.inspect(mode='list', what="names", std_est=True)
```

[ ]:
```
                   lval  op                 rval  Estimate  Est. Std  \
0                   sk9   ~  Intereses_Personales  1.000000  0.585656
1                  sk10   ~  Intereses_Personales  1.370172  0.559402
2                  sk11   ~  Intereses_Personales  1.251958  0.726183
3                  sk12   ~  Intereses_Personales  1.124168  0.544700
4                  sk13   ~  Intereses_Personales  1.321629  0.515012
5                   sk1   ~           Afectividad  1.000000  0.583347
6                   sk2   ~           Afectividad  1.913176  0.646890
7                   sk3   ~           Afectividad  1.643261  0.627762
8                   sk4   ~           Afectividad  1.800482  0.698943
9                   sk5   ~         Socialización  1.000000  0.717447
10                  sk6   ~         Socialización  1.019402  0.558280
11                  sk8   ~         Socialización  1.145240  0.552680
12        Socialización  ~~         Socialización  0.160010  1.000000
13          Afectividad  ~~           Afectividad  0.047447  1.000000
14          Afectividad  ~~  Intereses_Personales  0.048967  0.591167
15          Afectividad  ~~         Socialización  0.056891  0.652928
16 Intereses_Personales  ~~  Intereses_Personales  0.144605  1.000000
17 Intereses_Personales  ~~         Socialización  0.088235  0.580060
18                 sk11  ~~                  sk11  0.203152  0.472659
19                 sk12  ~~                  sk12  0.433185  0.703302
20                  sk3  ~~                   sk3  0.196990  0.605915
21                  sk2  ~~                   sk2  0.241343  0.581534
22                  sk9  ~~                   sk9  0.276993  0.657007
23                  sk5  ~~                   sk5  0.150852  0.485270
24                  sk8  ~~                   sk8  0.477194  0.694545
25                  sk1  ~~                   sk1  0.091983  0.659707
26                  sk6  ~~                   sk6  0.367221  0.688324
27                  sk4  ~~                   sk4  0.161039  0.511479
28                 sk13  ~~                  sk13  0.699705  0.734762
29                 sk10  ~~                  sk10  0.596057  0.687070

    Std. Err     z-value p-value
0          -           -       -
1   0.013871   98.782266     0.0
2   0.010954  114.293269     0.0
3   0.011593   96.968045     0.0
4   0.014189   93.141585     0.0
5          -           -       -
6   0.017591  108.755881     0.0
7    0.01538  106.841209     0.0
```

```
8   0.015901  113.230677     0.0
9          -           -       -
10  0.010365   98.348758     0.0
11  0.011721   97.707603     0.0
12  0.002069    77.32881     0.0
13  0.000709   66.924665     0.0
14  0.000674   72.643395     0.0
15  0.000713   79.782194     0.0
16  0.002161   66.909082     0.0
17  0.001182   74.627526     0.0
18  0.001826  111.248228     0.0
19  0.002946  147.052214     0.0
20  0.001448  136.080468     0.0
21  0.001821  132.531636     0.0
22  0.001954  141.790919     0.0
23  0.001576   95.725984     0.0
24  0.003441  138.659001     0.0
25  0.000643  142.954132     0.0
26  0.002666  137.719367     0.0
27  0.001335  120.603773     0.0
28  0.004658   150.22248     0.0
29  0.004102  145.294168     0.0
```

Luego se entregan las principales estadísticas del modelo, donde encontramos RMSEA que es un índice de ajuste que funciona correctamente independientemente del número de factores. Notamos que el valor es cercano a 0,05 por lo que se considera que el modelo se ajusta de forma adecuada a la muestra.

```
[ ]: a=semopy.calc_stats(model)
```

```
[ ]: print(a)
```

```
       DoF  DoF Baseline         chi2  chi2 p-value  chi2 Baseline       CFI  \
Value   51            66  7969.115166           0.0  151689.610826  0.947778

            GFI      AGFI       NFI       TLI     RMSEA        AIC  \
Value  0.947464  0.932013  0.947464  0.932418  0.052256  53.719679

              BIC    LogLik
Value  295.323633  0.140161
```

Finalmente se presenta de forma gráfica cada uno de los factores y las variables que representan a cada factor.

```
[ ]: semopy.semplot(model, "model.png")
```

```
[ ]:
```

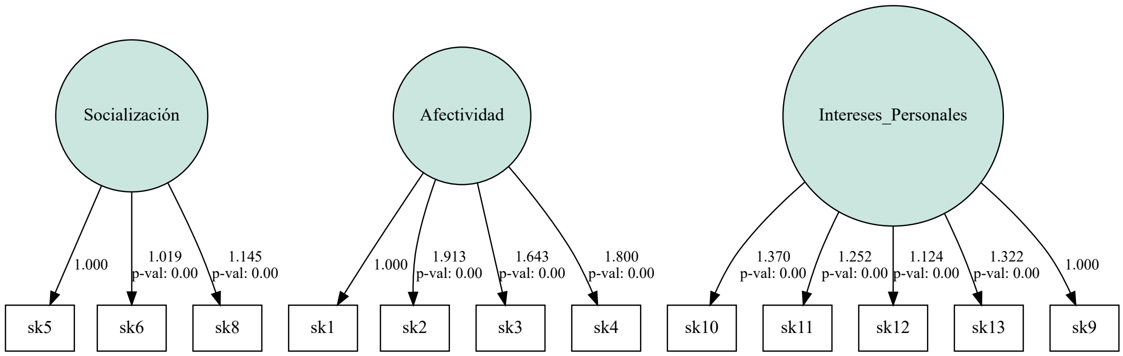

Pregunta 6 Finalmente, implemente un SEM completo usando la estructura propuesta en la Pregunta 5. En particular, estime un modelo donde los factores explican el nivel de actividad fisica, junto con otras variables que existen en la base de datos. Ademas utilice otras variables relevantes de la base de datos para explicar los factores latentes. Las variables a incluir en el modelo final deben tener sustento teorico y el modelo final debe optimizar el ajuste a los datos, en base a los criterios vistos en clase. Que puede concluir en base a sus resultados?

[ ]:
```
junaeb4.head(3)
```

[ ]:
```
   sexo  edad  imce  vive_padre  vive_madre  sk1  sk2  sk3  sk4  sk5  …  \
1     1    84  2.05           1           1    1    1    1    1    1  …
2     0    86  1.05           1           1    1    1    1    1    1  …
4     1    91  2.75           1           1    1    1    1    2    2  …

   sk9  sk10  sk11  sk12  sk13  act_fisica  area  educm  educp  madre_work
1    1     1     1     1     1         2.0     1   16.0     12          -1
2    1     1     1     1     1         1.0     1   17.0     15           0
4    3     3     3     2     2         2.0     1   20.0     19           1

[3 rows x 23 columns]
```

Para la implementación del SEM completo se utilizará la data junaeb4. En primer lugar es necesario recordar la estructura obtenida anteriormente.

Intereses_Personales =~ sk9 + sk10 + sk11 + sk12 + sk13

Afectividad =~ sk1 + sk2 + sk3 +sk4

Socialización =~ sk5 + sk6 + sk8

Para la parte estructural del modelo de ecuaciones estructurales, se analizaron los factores y se estableció una dependencia entre la afecttividad respecto a la socialización y los intereses personales. Además se estableció una dependencia entre la socialización respecto a los intereses personales.

[ ]:
```
import semopy
import pandas as pd
Xf=junaeb4
```

```
mod1 = """
# measurement model
Intereses_Personales =~ sk9 + sk10 + sk11 + sk12 + sk13
Afectividad =~ sk1 + sk2 + sk3 +sk4
Socialización =~ sk5 + sk6 + sk8

# regressions
Afectividad ~ Socialización + Intereses_Personales
Socialización ~ Intereses_Personales
act_fisica ~ Intereses_Personales + Afectividad + Socialización
"""

model1= semopy.Model(mod1)
out=model1.fit(Xf)
print(out)
```

```
Name of objective: MLW
Optimization method: SLSQP
Optimization successful.
Optimization terminated successfully
Objective value: 0.150
Number of iterations: 46
Params: 1.370 1.251 1.126 1.323 1.914 1.644 1.801 1.018 1.171 0.256 0.183 0.609
-0.218 0.449 -0.543 0.104 0.433 0.277 0.153 0.092 0.370 0.596 0.203 1.098 0.699
0.241 0.197 0.024 0.471 0.161 0.145
```

Dada la optimización del modelo se obtuvo que un valor objetivo de 0.152 en 46 iteraciones.

Posteriormente se determinó que para el factor afectividad habían otras variables que lo explicaban. Estas variables son vive_padre, vive_madre y madre_work. Para el caso de la variable actividad física, existían variables que la explicaban tales como el imce y el sexo.

Con estas suposiciones se estableció el modelo. Se realizó la optimización mediante semopy y se registran a continuación los resultados.

[ ]:
```
import semopy
import pandas as pd
Xf=junaeb4

mod = """
# measurement model
Intereses_Personales =~ sk9 + sk10 + sk11 + sk12 + sk13
Afectividad =~ sk1 + sk2 + sk3 +sk4 + vive_padre + vive_madre + madre_work
Socialización =~ sk5 + sk6 + sk8

# regressions
Afectividad ~ Socialización + Intereses_Personales
Socialización ~ Intereses_Personales
```

```
act_fisica ~ Intereses_Personales + Afectividad + Socialización + imce + sexo
"""

model= semopy.Model(mod)
out=model.fit(Xf)
print(out)
```

```
Name of objective: MLW
Optimization method: SLSQP
Optimization successful.
Optimization terminated successfully
Objective value: 0.306
Number of iterations: 50
Params: 1.371 1.251 1.125 1.325 1.914 1.643 1.798 -0.077 -0.026 -0.165 1.018
1.170 0.256 0.183 0.609 -0.251 0.439 -0.528 -0.016 0.138 0.024 0.884 0.104 0.433
0.277 0.153 0.092 0.370 0.596 0.204 1.093 0.698 0.241 0.197 0.024 0.471 0.161
0.201 0.145
```

[ ]:
```
res = model.fit(Xf)
```

Se obtiene un resumen del modelo producido. En este caso los coeficientes representan un cambio de una unidad de una variable estandarizada a otra unidad de una variable estandarizada. Notar que en la matriz de varianza y covarianza se obtuvieron estimadores para cada una de las variables que tienen valor distinto de cero. Además dados los valores p que son menores a 0,05 para cada uno de los casos del modelo por ende las variables son significativas.
Además se obtuvo una mejor significativa en el valor objetivo pasando de 0.152 a 0.306.

[ ]:
```
model.inspect(mode='list', what="names", std_est=True)
```

[ ]:
```
                 lval  op                  rval  Estimate  Est. Std  \
0         Afectividad   ~         Socialización  0.255940  0.466923
1         Afectividad   ~  Intereses_Personales  0.183384  0.320015
2       Socialización   ~  Intereses_Personales  0.609153  0.582678
3                 sk9   ~  Intereses_Personales  1.000000  0.585397
4                sk10   ~  Intereses_Personales  1.370578  0.559402
5                sk11   ~  Intereses_Personales  1.250849  0.725362
6                sk12   ~  Intereses_Personales  1.125490  0.545147
7                sk13   ~  Intereses_Personales  1.324703  0.516196
8                 sk1   ~           Afectividad  1.000000  0.583514
9                 sk2   ~           Afectividad  1.913588  0.647066
10                sk3   ~           Afectividad  1.643105  0.627781
11                sk4   ~           Afectividad  1.798201  0.698204
12         vive_padre   ~           Afectividad -0.076663 -0.037260
13         vive_madre   ~           Afectividad -0.025783 -0.036296
14         madre_work   ~           Afectividad -0.164518 -0.038096
15                sk5   ~         Socialización  1.000000  0.712890
16                sk6   ~         Socialización  1.018344  0.554140
```

17	sk8	~	Socialización	1.169838	0.560950
18	act_fisica	~	Intereses_Personales	-0.251212	-0.089188
19	act_fisica	~	Afectividad	0.439450	0.089406
20	act_fisica	~	Socialización	-0.528077	-0.196002
21	act_fisica	~	imce	-0.016009	-0.020140
22	act_fisica	~	sexo	0.138102	0.064325
23	Socialización	~~	Socialización	0.104335	0.660486
24	Afectividad	~~	Afectividad	0.023990	0.505443
25	Intereses_Personales	~~	Intereses_Personales	0.144534	1.000000
26	vive_madre	~~	vive_madre	0.023919	0.998683
27	madre_work	~~	madre_work	0.883853	0.998549
28	sk12	~~	sk12	0.432978	0.702814
29	sk9	~~	sk9	0.277230	0.657311
30	sk5	~~	sk5	0.152861	0.491788
31	sk1	~~	sk1	0.091933	0.659511
32	sk6	~~	sk6	0.369660	0.692928
33	sk10	~~	sk10	0.596117	0.687070
34	sk11	~~	sk11	0.203663	0.473850
35	act_fisica	~~	act_fisica	1.093002	0.953201
36	sk13	~~	sk13	0.698238	0.733542
37	sk2	~~	sk2	0.241299	0.581306
38	sk3	~~	sk3	0.196998	0.605892
39	sk8	~~	sk8	0.470837	0.685335
40	sk4	~~	sk4	0.161349	0.512511
41	vive_padre	~~	vive_padre	0.200651	0.998612

	Std. Err	z-value	p-value
0	0.004676	54.735728	0.0
1	0.004356	42.095012	0.0
2	0.007423	82.06653	0.0
3	-	-	-
4	0.013867	98.837299	0.0
5	0.010937	114.368228	0.0
6	0.011594	97.077049	0.0
7	0.014191	93.347428	0.0
8	-	-	-
9	0.017587	108.807947	0.0
10	0.015374	106.876166	0.0
11	0.015883	113.217047	0.0
12	0.009802	-7.820816	0.0
13	0.003384	-7.61881	0.0
14	0.020575	-7.996071	0.0
15	-	-	-
16	0.010343	98.457029	0.0
17	0.011786	99.253825	0.0
18	0.020533	-12.234428	0.0
19	0.040803	10.769969	0.0

```
20  0.023724  -22.259135       0.0
21  0.003282   -4.878232  0.000001
22  0.008864   15.580383       0.0
23   0.00162   64.387812       0.0
24  0.000417   57.553151       0.0
25   0.00216    66.92163       0.0
26  0.000142  168.543409       0.0
27  0.005244  168.536881       0.0
28  0.002943  147.096555       0.0
29  0.001953  141.949993       0.0
30  0.001557   98.183029       0.0
31  0.000643  142.945846       0.0
32  0.002663   138.82793       0.0
33    0.0041  145.398505       0.0
34  0.001822  111.755435       0.0
35  0.006657  164.196537       0.0
36  0.004649  150.185823       0.0
37  0.001821  132.519947       0.0
38  0.001447  136.097086       0.0
39  0.003419  137.693654       0.0
40  0.001335  120.832452       0.0
41  0.001191  168.539953       0.0
```

[ ]:
```
b=semopy.calc_stats(model)
print(b)
```

```
       DoF  DoF Baseline         chi2  chi2 p-value  chi2 Baseline      CFI  \
Value  132           155  17420.41143           0.0  163330.515895  0.89405

            GFI      AGFI       NFI       TLI     RMSEA       AIC        BIC  \
Value  0.893343  0.874758  0.893343  0.875589  0.047996  77.38722  426.37071

        LogLik
Value  0.30639
```

Se analizan estadísticas del modelo. El RMSEA dado es inferior a 0.05 por lo que se considera que el modelo se ajusta de forma adecuada a la muestra. El CFI debe estar en torno a 0.95 para considerar que el modelo se ajusta adecuadamente a los datos, en este caso es 0.89 lo que es bastante cercano. Para el caso de GFI (Goodness of Fit Index), debe ser igual a superior a 0.9 y en este caso da como resultado 0.89. En general se puede concluir que el modelo se ajusta de forma adecuada a los datos, ya que a pesar de no tener estadísticas de forma óptima son bastante cercanas. Además las suposiciones realizadas en un comienzo respecto a la explicación de los factores y variables se cumplieron según los resultados del resumen del modelo.

[ ]:
```
semopy.semplot(model, "semmodel.png")
```

[ ]:

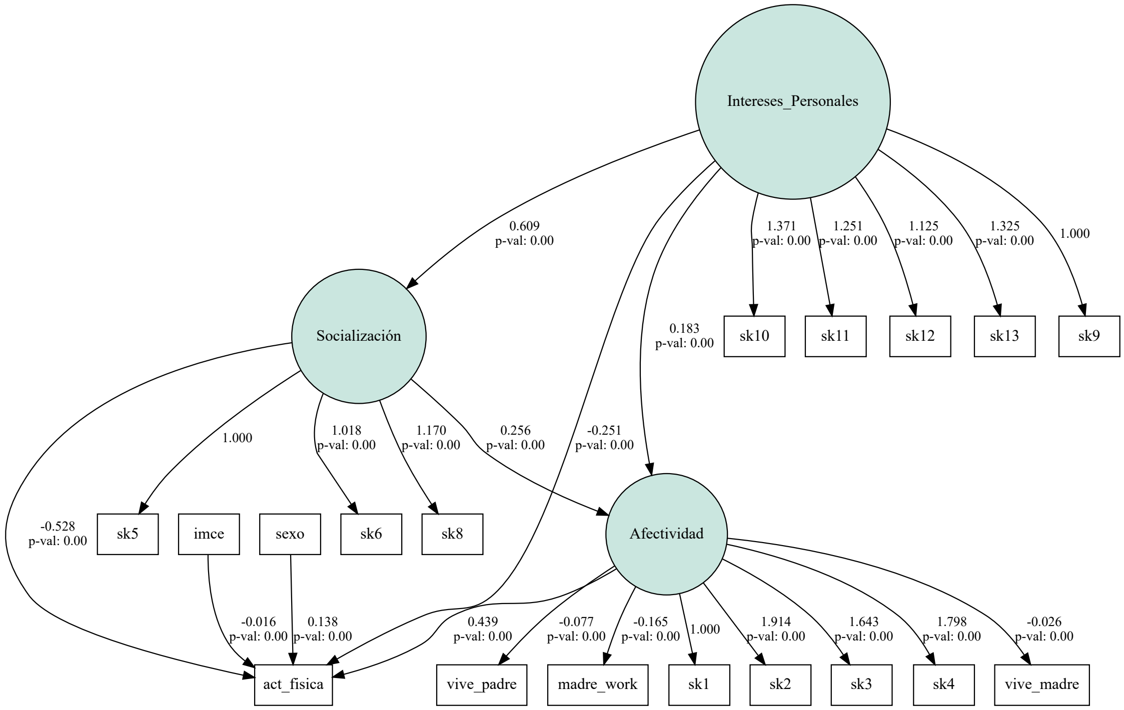

Anexos

Anexo 1: Distribuciones de variables

[ ]:
```
plt.hist(junaeb2.sexo)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Sexo de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.edad)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.imce)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Imce de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.vive_padre)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Padre vive')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.vive_madre)
```

```
plt.title(junaeb2.columns.values[0])
plt.xlabel('Madre vive')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.area)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Area donde vive')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.sk1)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Muestra afecto a padres')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.sk2)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.sk3)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.sk4)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.sk5)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.sk6)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.sk7)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.sk9)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
```

```
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.sk10)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.sk11)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.sk12)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.sk13)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.act_fisica)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.educm)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.educp)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
plt.hist(junaeb2.educm)
plt.title(junaeb2.columns.values[0])
plt.xlabel('Edad de la persona')
plt.ylabel('cantidad de personas')
plt.show()
```

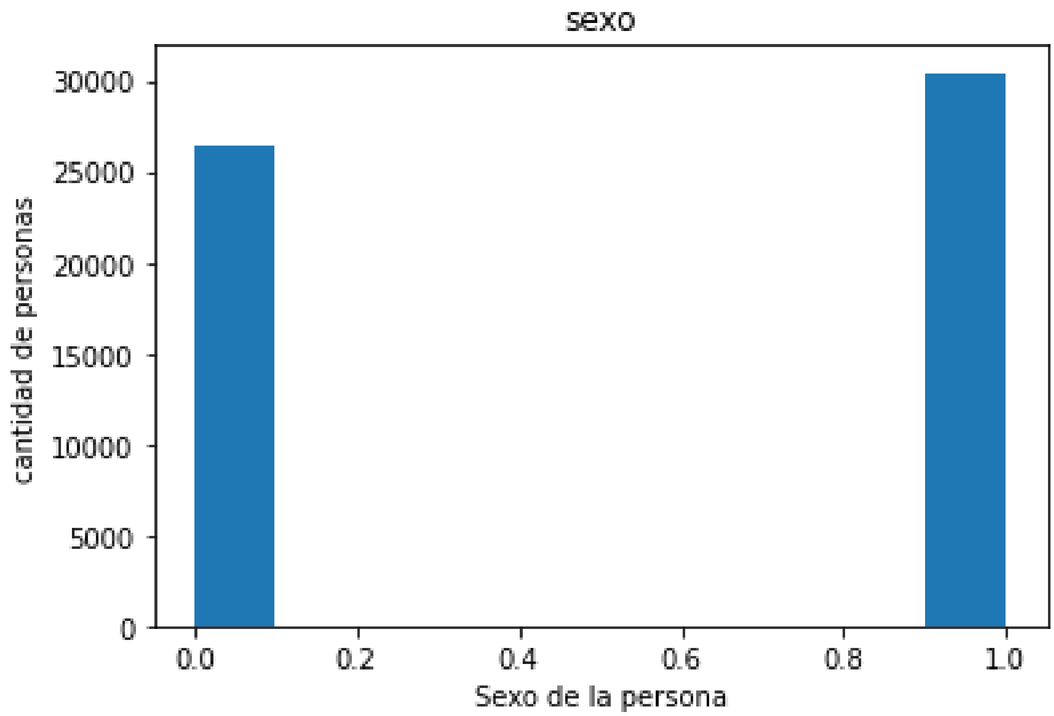
sexo
cantidad de personas
30000
25000
20000
15000
10000
5000
0
0.0
0.2
0.4
0.6
0.8
1.0
Sexo de la persona

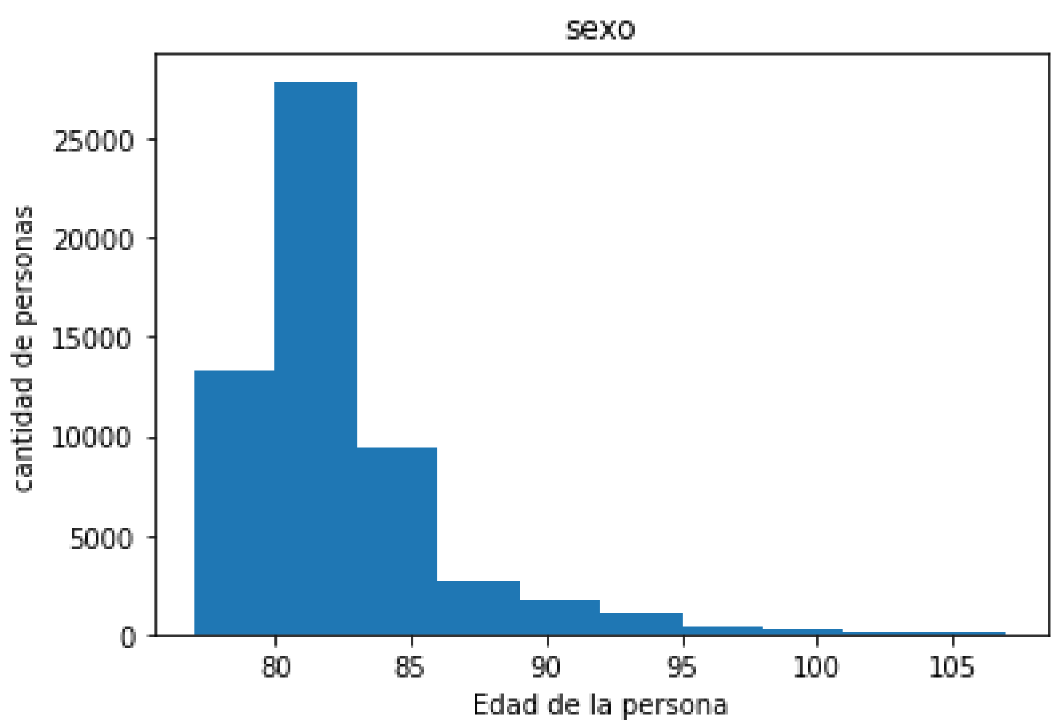
sexo
cantidad de personas
25000
20000
15000
10000
5000
0
80
85
90
95
100
105
Edad de la persona

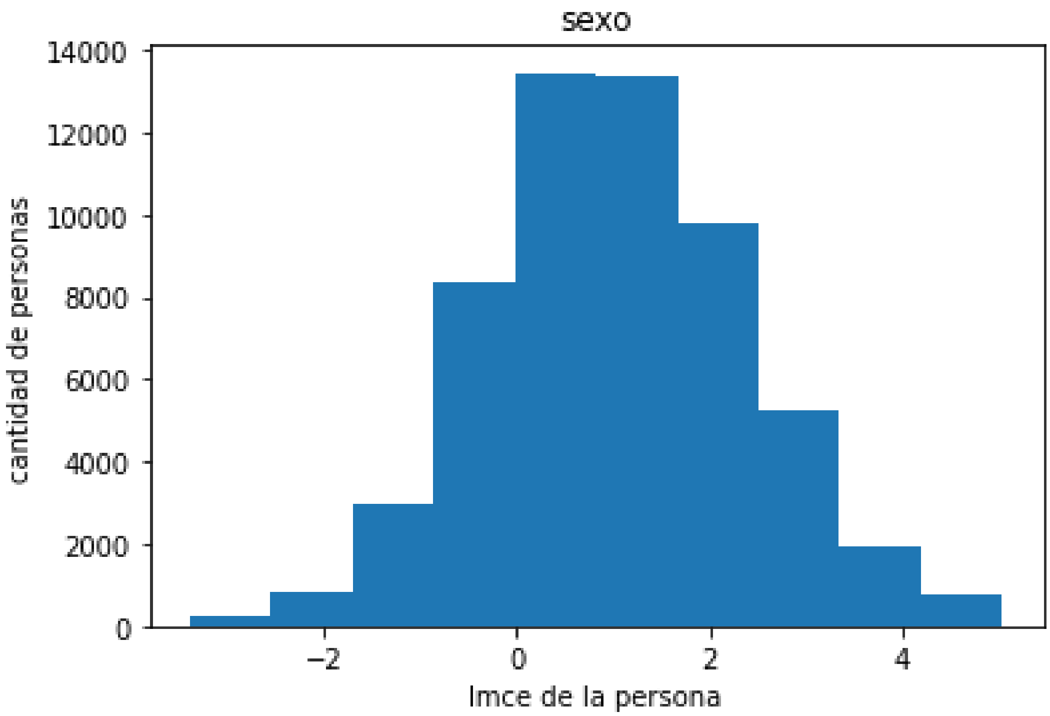
sexo
cantidad de personas
Imce de la persona

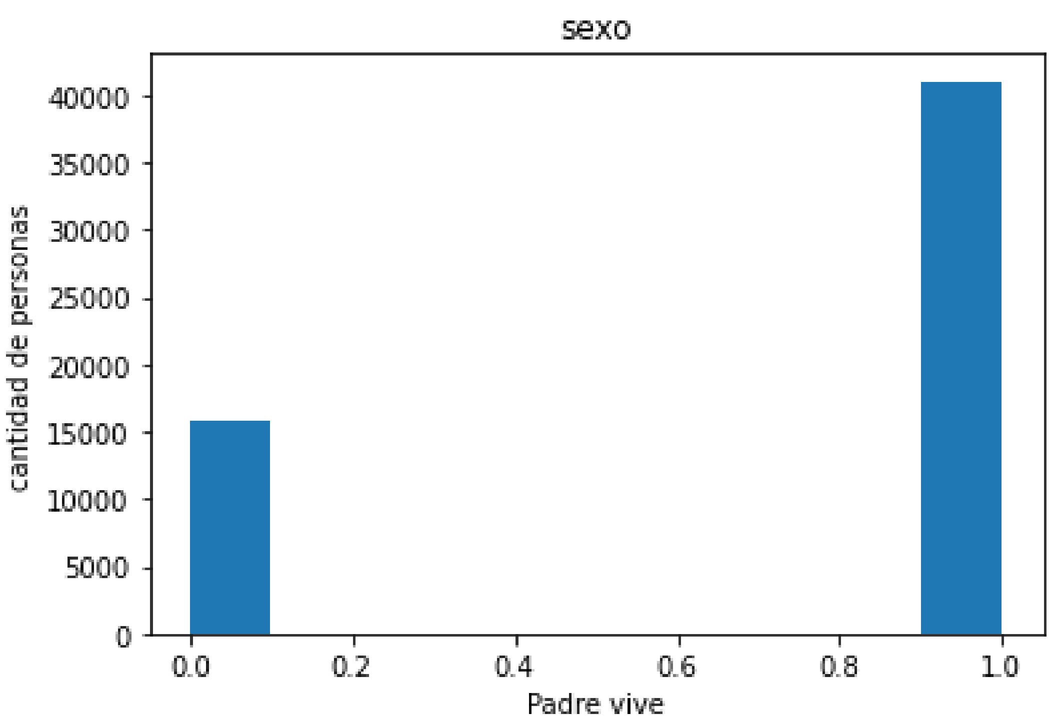
sexo
cantidad de personas
Padre vive

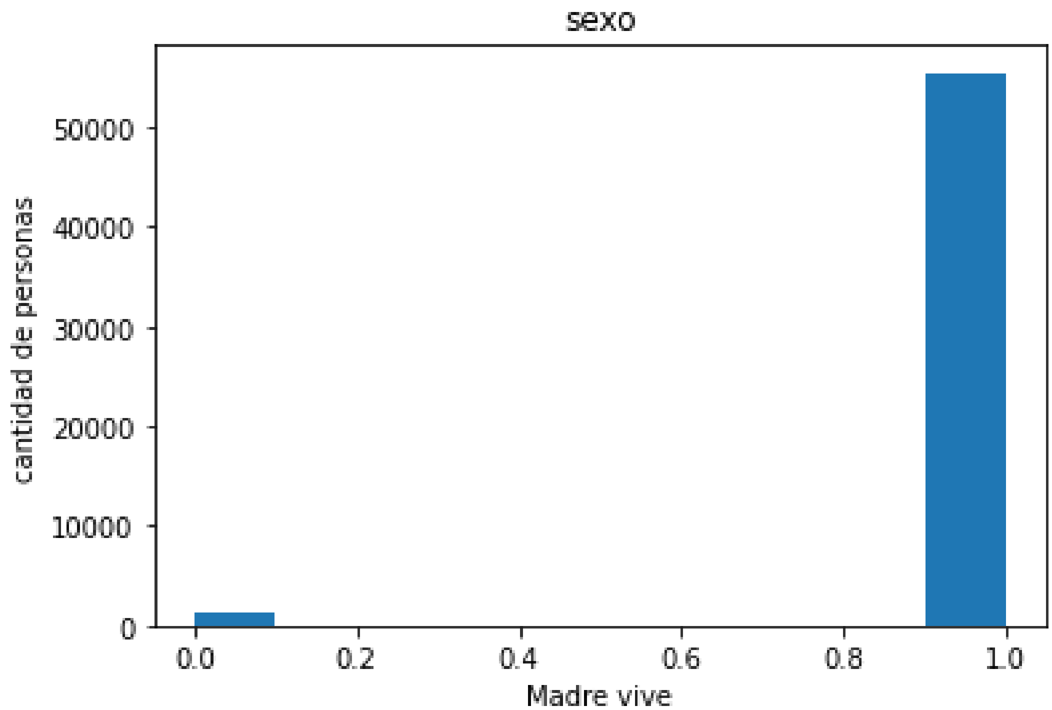
sexo
cantidad de personas
50000
40000
30000
20000
10000
0
0.0
0.2
0.4
0.6
0.8
1.0
Madre vive

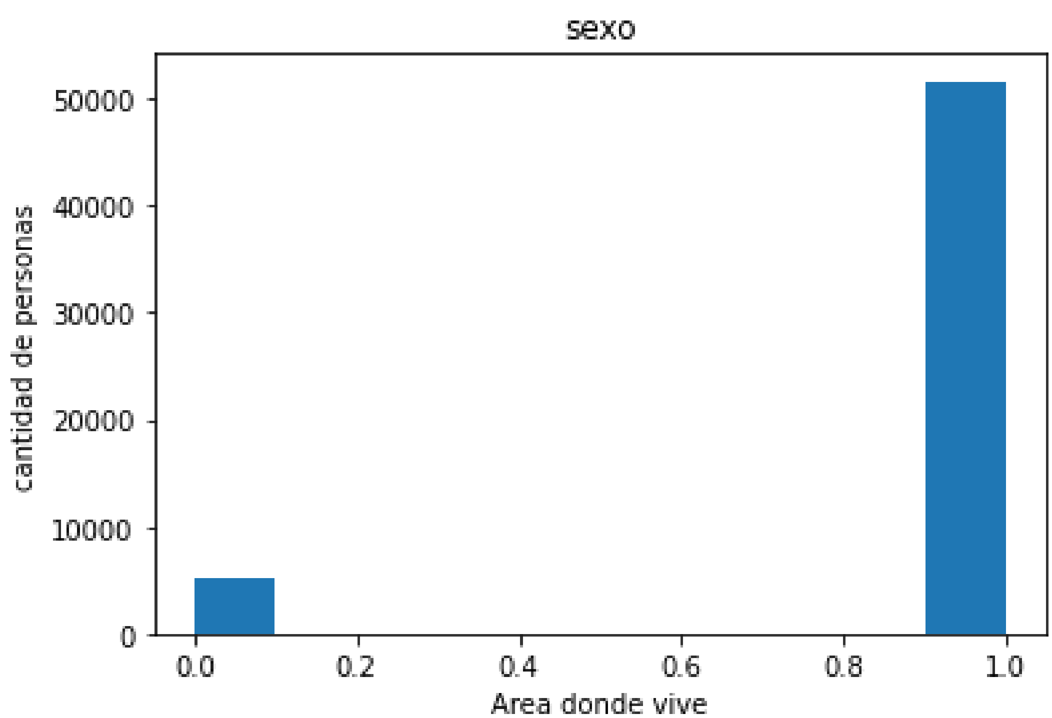
sexo
cantidad de personas
50000
40000
30000
20000
10000
0
0.0
0.2
0.4
0.6
0.8
1.0
Area donde vive

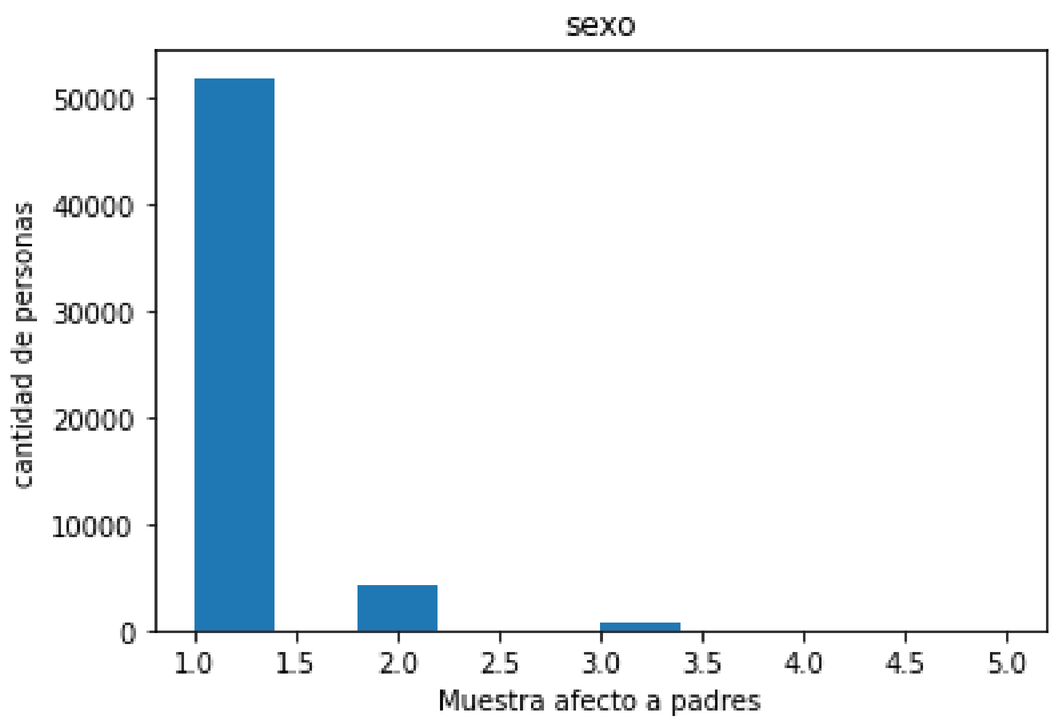
sexo
cantidad de personas
0
10000
20000
30000
40000
50000
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0
Muestra afecto a padres

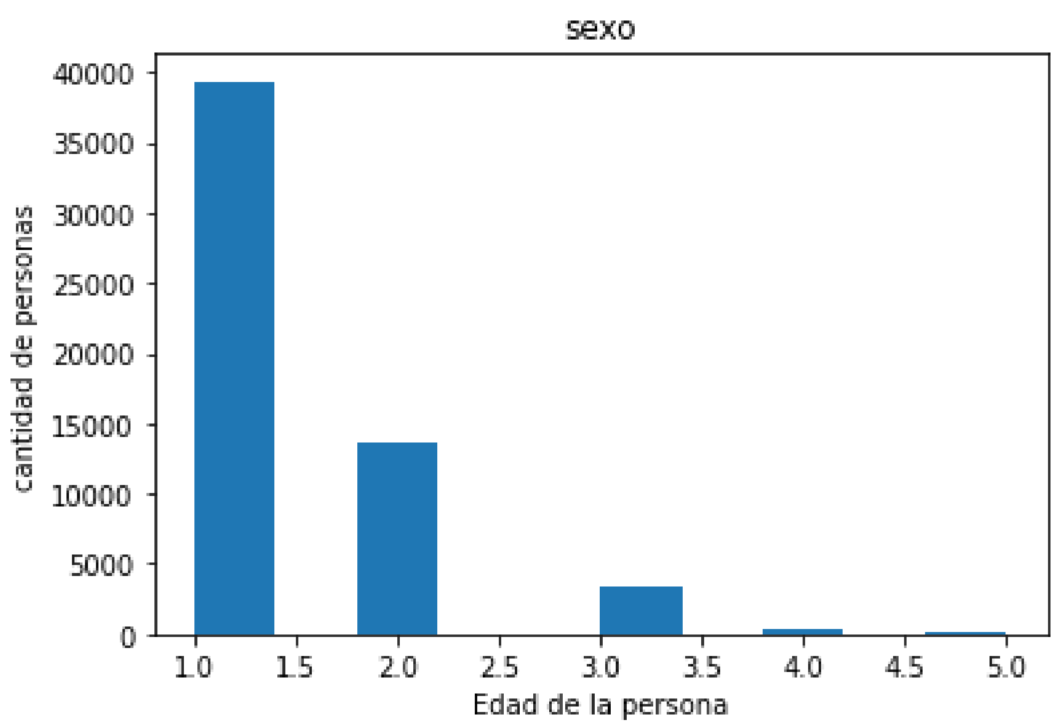
sexo
cantidad de personas
0
5000
10000
15000
20000
25000
30000
35000
40000
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0
Edad de la persona

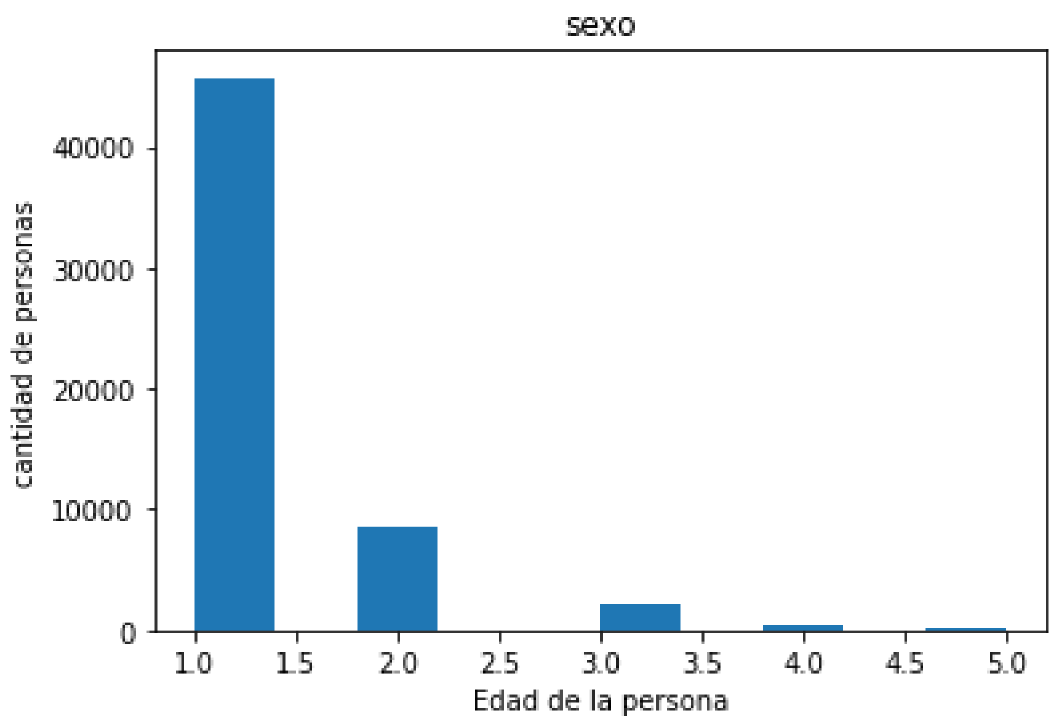
sexo
40000
30000
20000
10000
0
cantidad de personas
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0
Edad de la persona

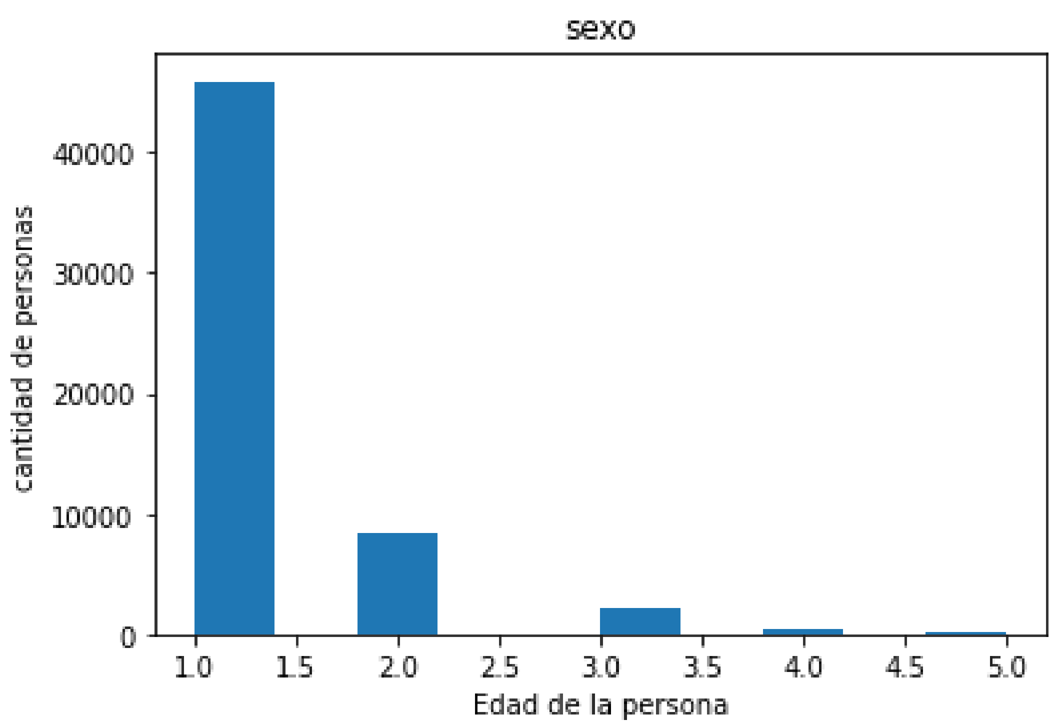
sexo
40000
30000
20000
10000
0
cantidad de personas
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0
Edad de la persona

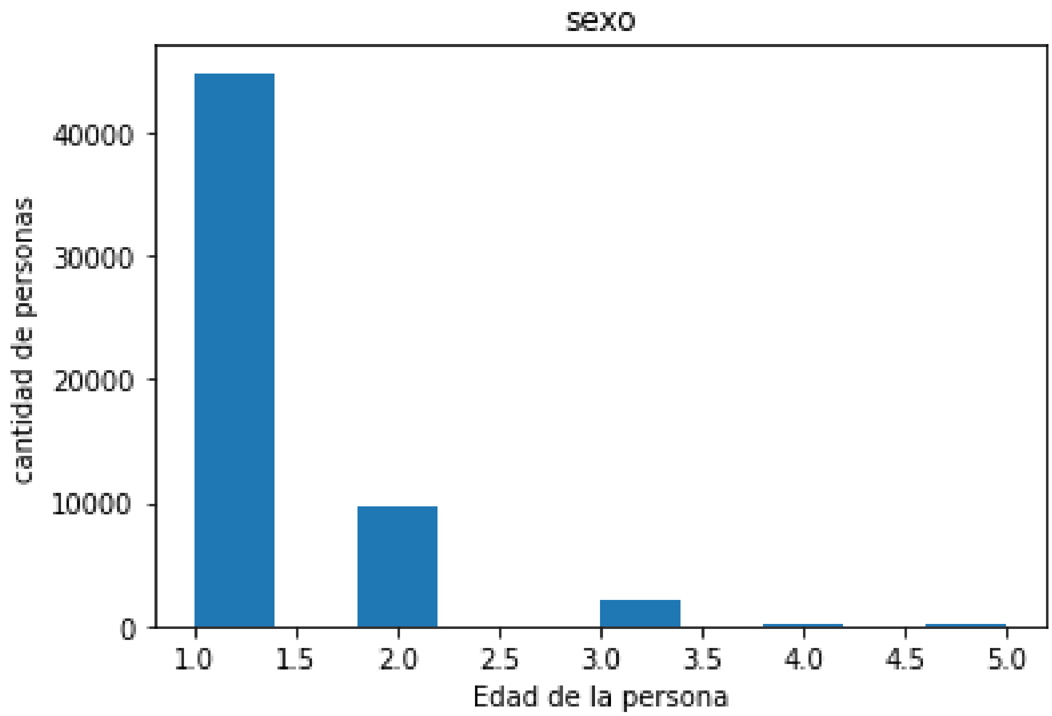
sexo
cantidad de personas
40000
30000
20000
10000
0
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0
Edad de la persona

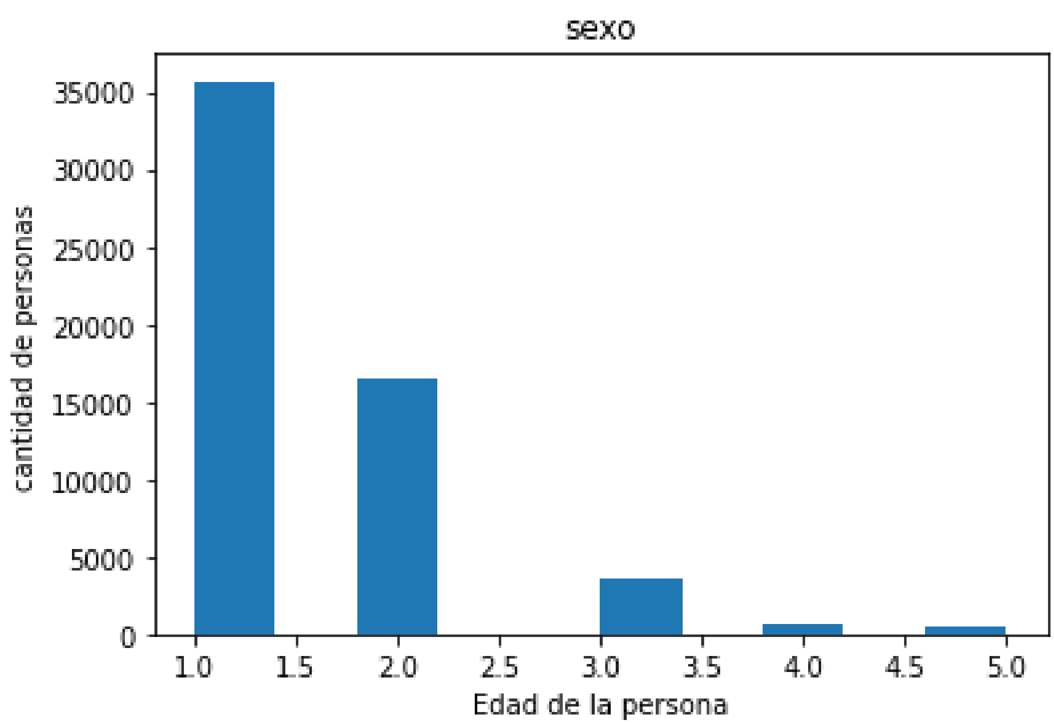
sexo
cantidad de personas
35000
30000
25000
20000
15000
10000
5000
0
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0
Edad de la persona

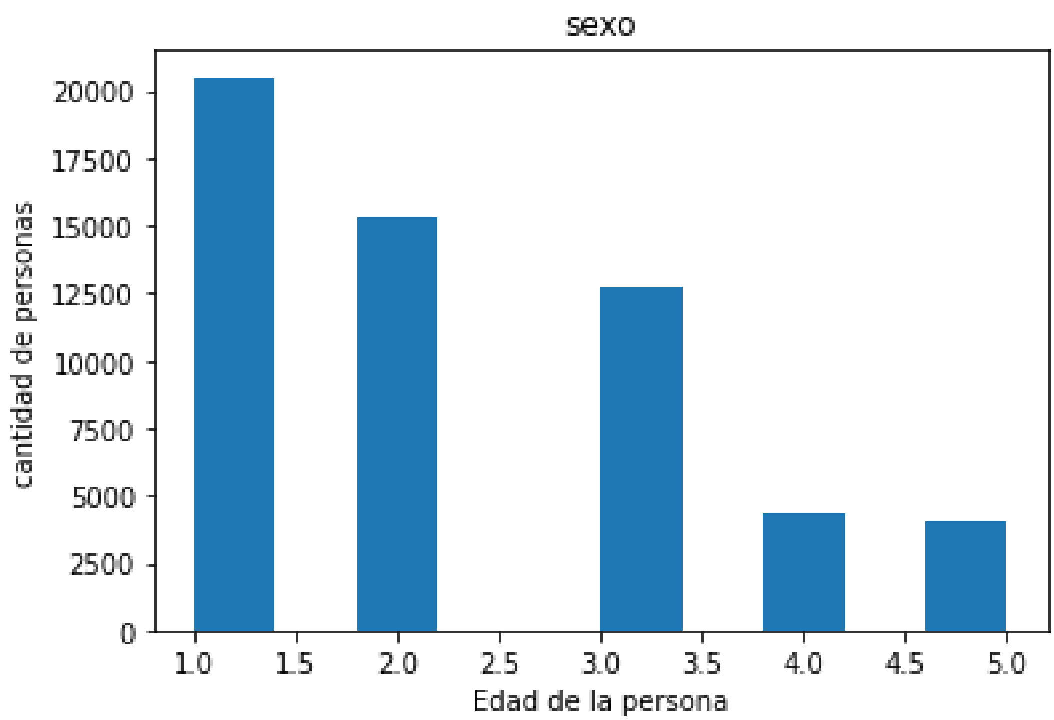
sexo
20000
17500
15000
12500
10000
7500
5000
2500
0
cantidad de personas
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0
Edad de la persona

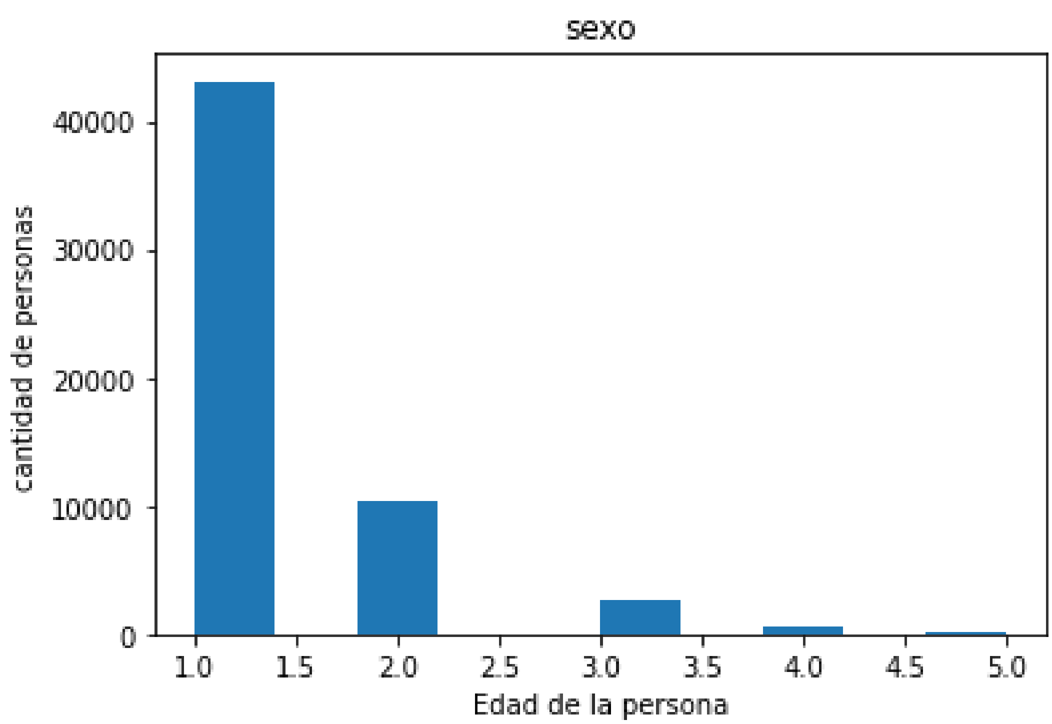
sexo
40000
30000
20000
10000
0
cantidad de personas
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0
Edad de la persona

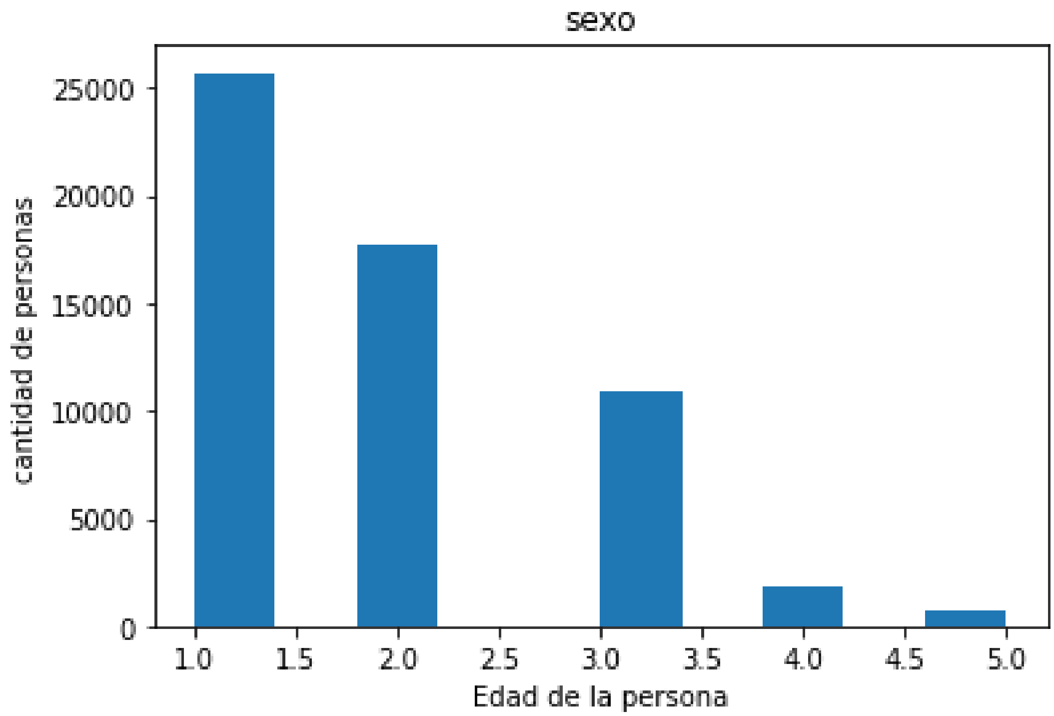
sexo
25000
20000
15000
10000
5000
0
cantidad de personas
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0
Edad de la persona

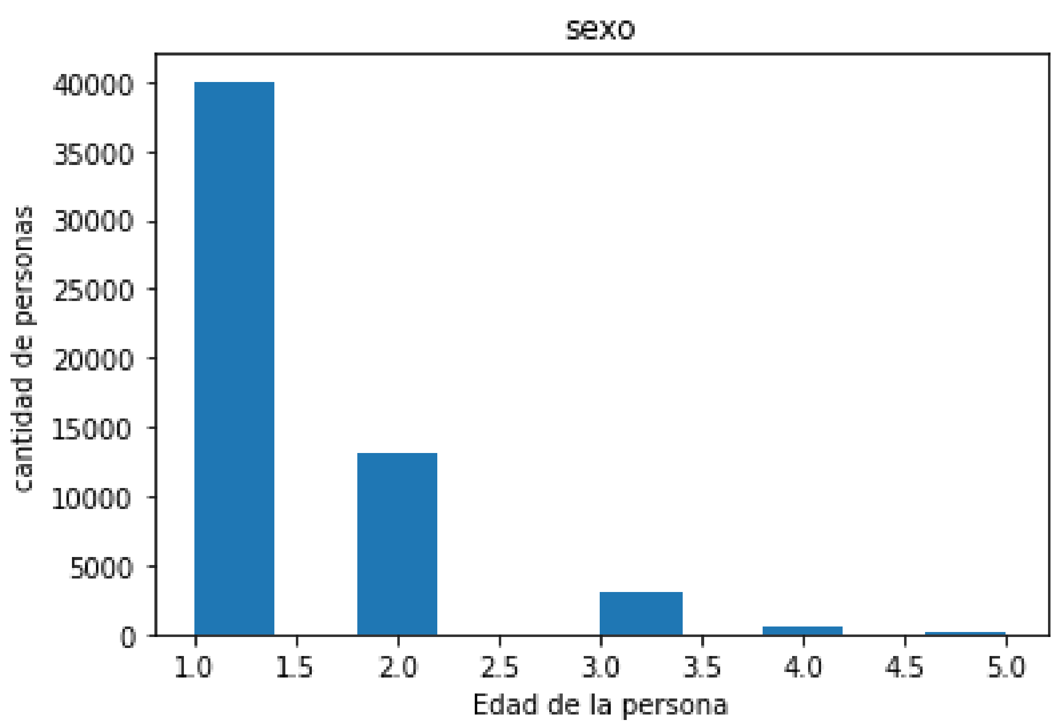
sexo
40000
35000
30000
25000
20000
15000
10000
5000
0
cantidad de personas
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0
Edad de la persona

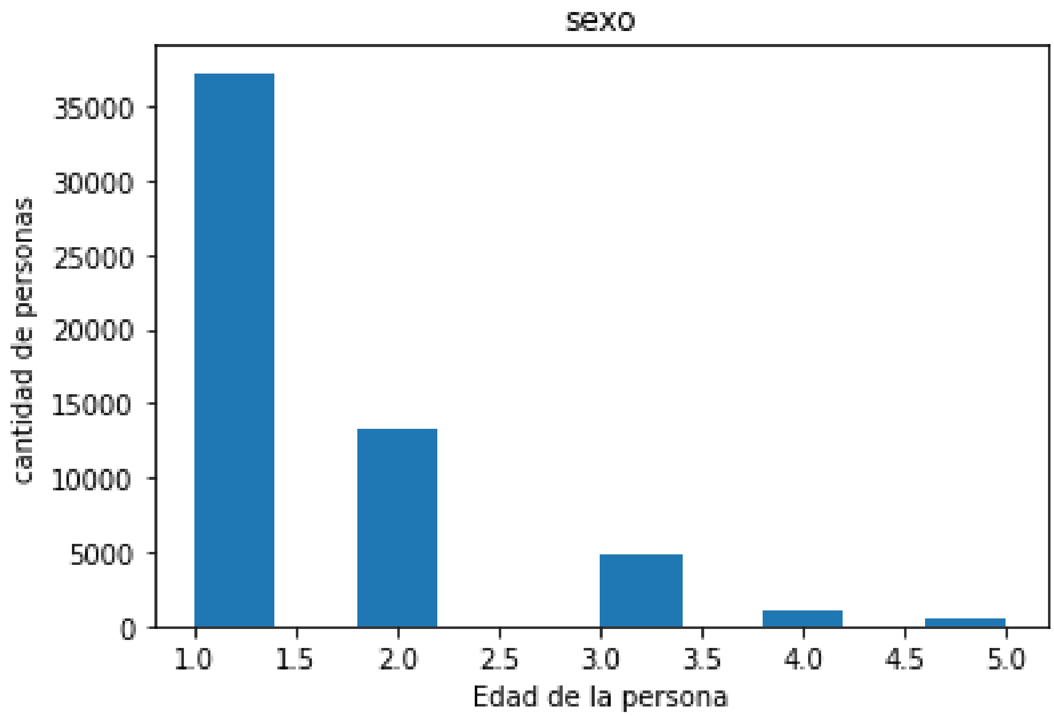
sexo
cantidad de personas
Edad de la persona
0
5000
10000
15000
20000
25000
30000
35000
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0

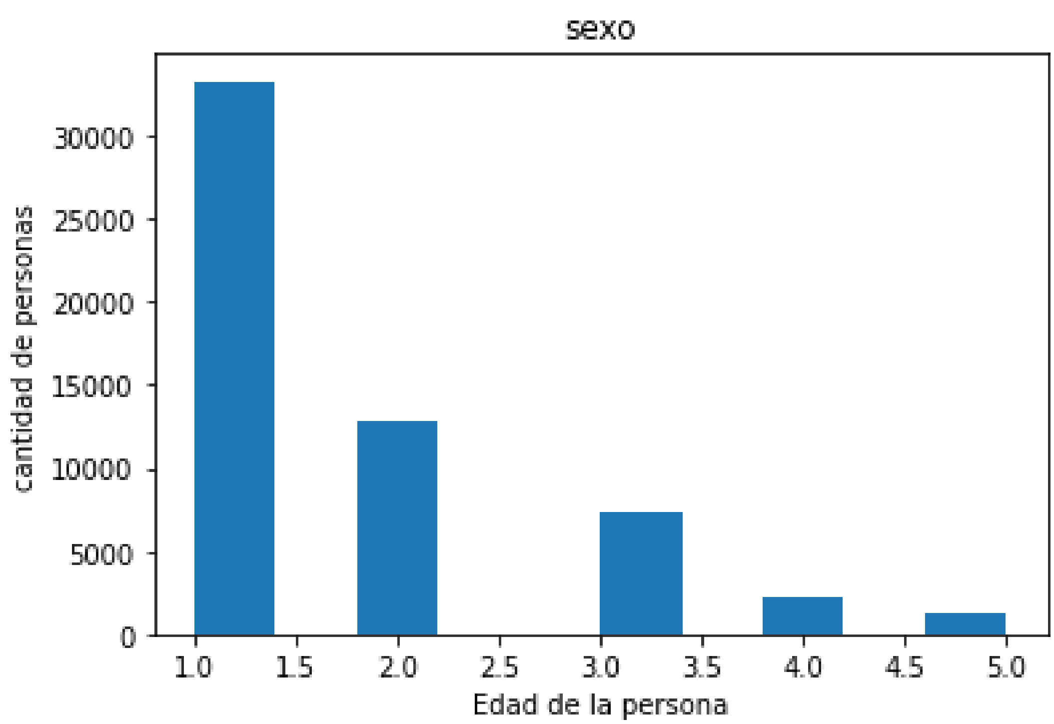
sexo
cantidad de personas
Edad de la persona
0
5000
10000
15000
20000
25000
30000
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0

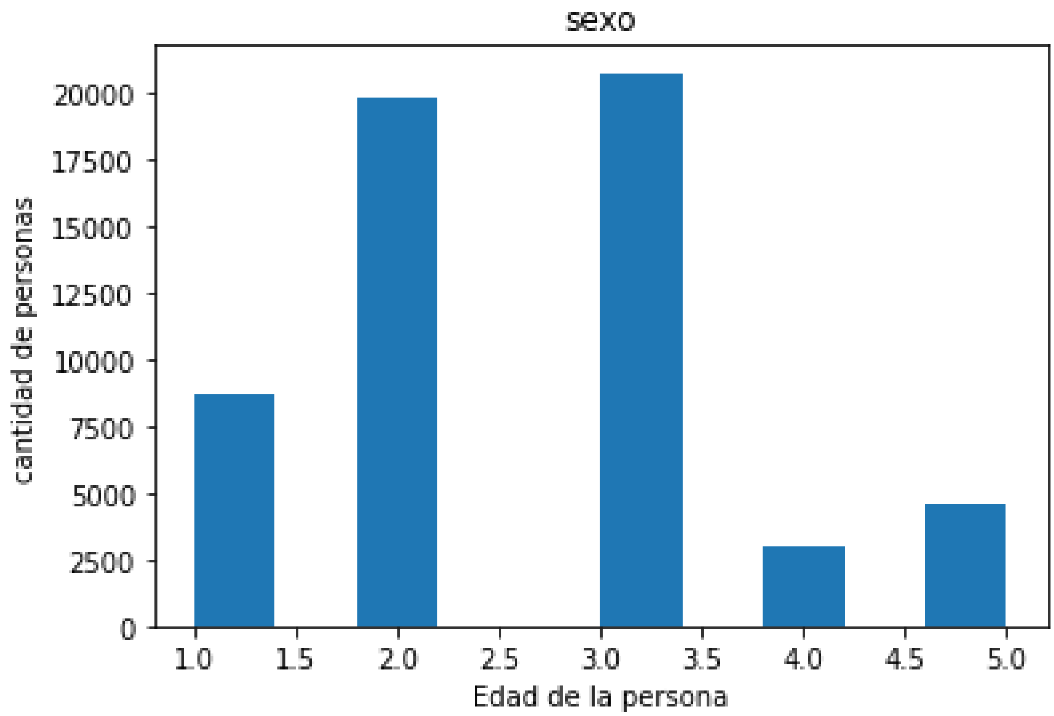
sexo
cantidad de personas
Edad de la persona
0
2500
5000
7500
10000
12500
15000
17500
20000
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0

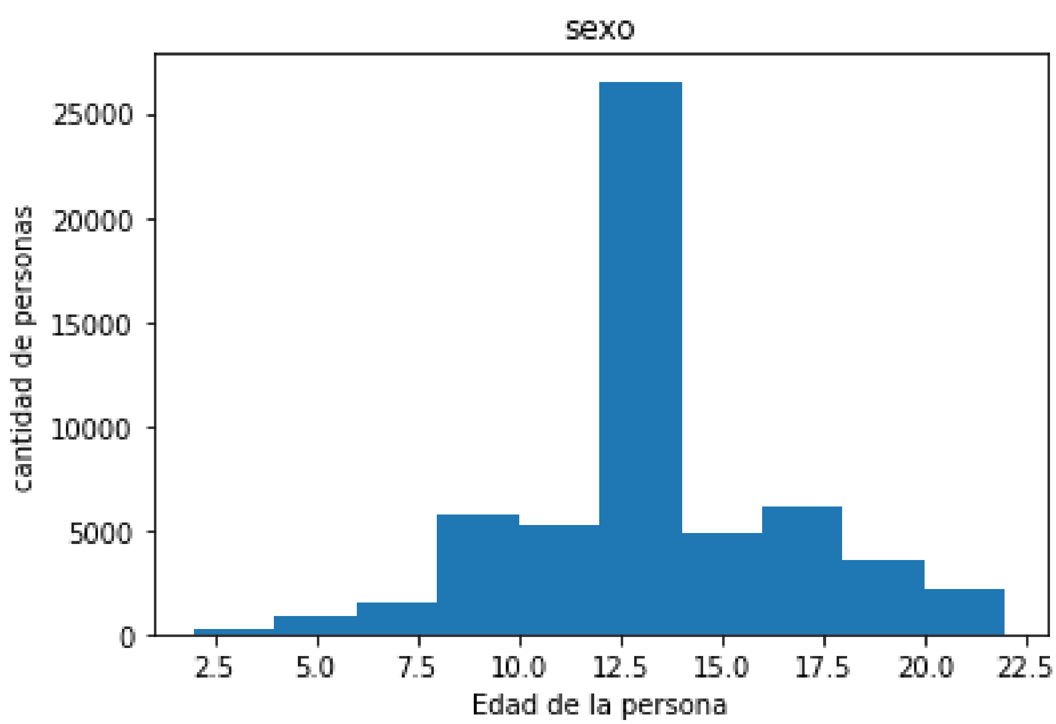
sexo
cantidad de personas
Edad de la persona
0
5000
10000
15000
20000
25000
2.5
5.0
7.5
10.0
12.5
15.0
17.5
20.0
22.5

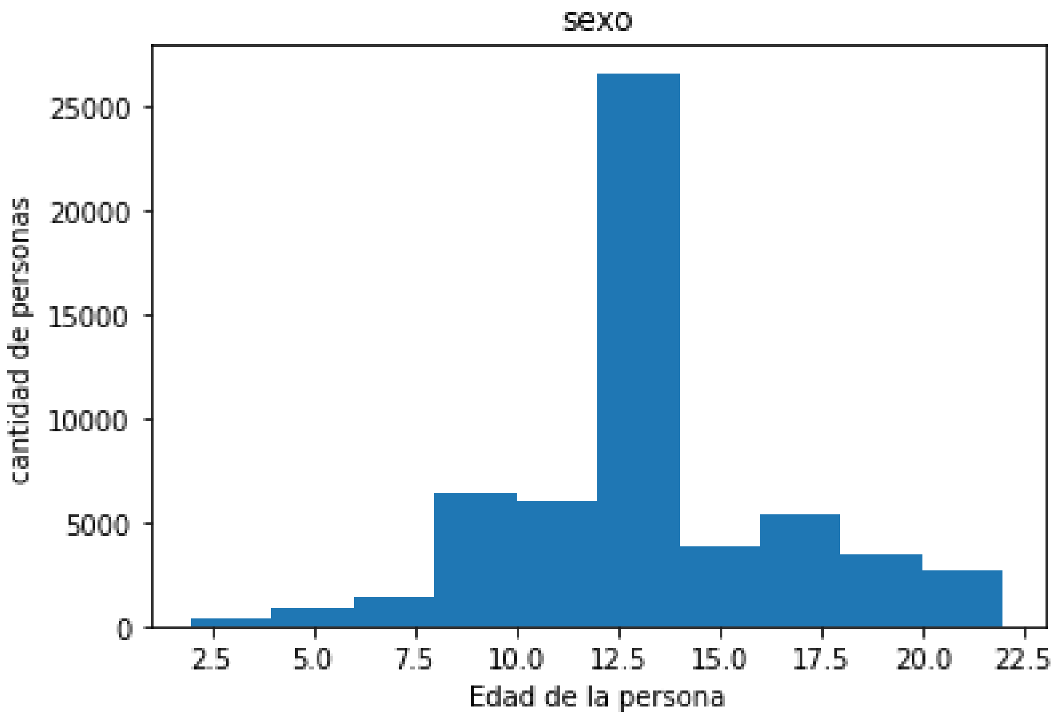
sexo
cantidad de personas
0
5000
10000
15000
20000
25000
2.5
5.0
7.5
10.0
12.5
15.0
17.5
20.0
22.5
Edad de la persona

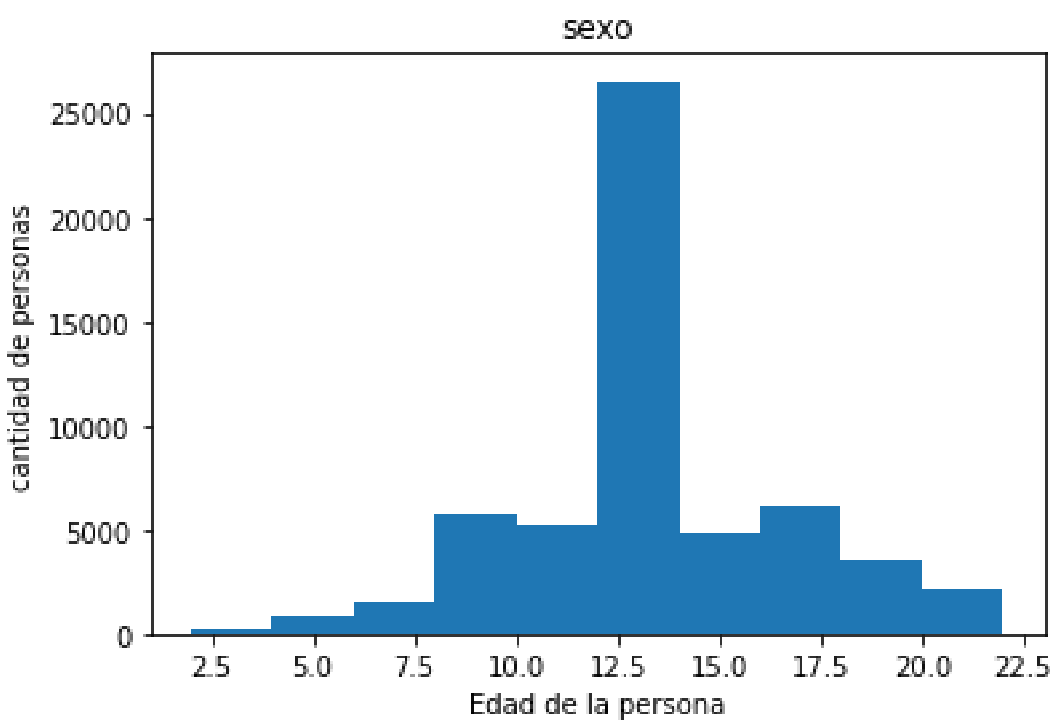
sexo
cantidad de personas
0
5000
10000
15000
20000
25000
2.5
5.0
7.5
10.0
12.5
15.0
17.5
20.0
22.5
Edad de la persona

Anexo 2: Outliers

```
[ ]: import plotly.express as px
fig1 = px.histogram(junaeb2, x="sexo",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig1.show()
fig2 = px.histogram(junaeb2, x="edad",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig2.show()
fig3 = px.histogram(junaeb2, x="imce",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig3.show()
fig4 = px.histogram(junaeb2, x="vive_padre",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig4.show()
fig5 = px.histogram(junaeb2, x="vive_madre",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig5.show()
fig6 = px.histogram(junaeb2, x="sk1",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig6.show()
fig7 = px.histogram(junaeb2, x="sk2",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig7.show()
fig8 = px.histogram(junaeb2, x="sk3",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig8.show()
fig9 = px.histogram(junaeb2, x="sk4",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig9.show()
fig10 = px.histogram(junaeb2, x="sk5",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig10.show()
fig11= px.histogram(junaeb2, x="sk6",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig11.show()
fig12 = px.histogram(junaeb2, x="sk7",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig12.show()
fig13 = px.histogram(junaeb2, x="sk8",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig13.show()
fig14 = px.histogram(junaeb2, x="sk9",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig14.show()
fig15 = px.histogram(junaeb2, x="sk10",␣
 ↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
```

```
fig15.show()
fig16 = px.histogram(junaeb2, x="sk11",␣
↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig16.show()
fig17 = px.histogram(junaeb2, x="sk12",␣
↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig17.show()
fig18 = px.histogram(junaeb2, x="sk13",␣
↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig18.show()
fig19 = px.histogram(junaeb2, x="act_fisica",␣
↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig19.show()
fig20 = px.histogram(junaeb2, x="area",␣
↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig20.show()
fig21 = px.histogram(junaeb2, x="educm",␣
↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig21.show()
fig22 = px.histogram(junaeb2, x="educp",␣
↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig22.show()
fig23 = px.histogram(junaeb2, x="madre_work",␣
↪marginal="box",color_discrete_sequence=['green'],height=500,width=700)
fig23.show()
```

[ ]:

```
```